

Material de cátedra

Técnicas cuantitativas para el Management y los Negocios
(Carrera Contador Público Nacional)

Técnicas cuantitativas para el Management y los Negocios I
(Carrera Licenciado en Administración)

Módulo I: Estadística Descriptiva

Autores

María del Carmen Romero

Silvina Etcheverría

**Facultad de Ciencias Económicas
Universidad Nacional del Centro de la Provincia de
Buenos Aires**



Tabla de contenido

1	Introducción	2
2	Conceptos básicos	3
3	Tipos de variables. Escalas de medición	6
4	Organización de los datos	8
4.1	Tablas de distribución de frecuencias	8
4.1.1	Tabla de distribución de frecuencias para variables cualitativas.....	9
4.1.2	Tabla de distribución de frecuencias para variables cuantitativas	10
4.1.3	Organización de datos para análisis bivariado	18
4.2	Gráficos	21
4.2.1	Gráficos para datos cualitativos	21
4.2.2	Gráficos para variables cuantitativas	25
4.2.3	Gráficos para datos bivariados.....	28
5	Indicadores	32
5.1	Indicadores de tendencia central y posición	32
5.1.1	Media aritmética.....	32
5.1.2	Moda o modo	34
5.1.3	Mediana, Cuartiles, Deciles y Percentiles	34
5.1.4	Selección del indicador de posición adecuado	37
5.1.5	Box-plot o diagrama de caja.....	37
5.2	Indicadores de dispersión	39
5.2.1	Recorrido o rango.....	39
5.2.2	Recorrido intercuartílico	39
5.2.3	Varianza	39
5.2.4	Desviación estándar.....	40
5.2.5	Coeficiente de variación.....	40
6	Medidas de asociación	41
6.1	Covarianza	41
6.2	Correlación	43
7	Conclusiones	44
8	Bibliografía.....	45

1 Introducción

La Estadística es una rama de la Matemática que estudia la recolección, análisis e interpretación de datos ya sea para ayudar en la toma de decisiones o para explicar condiciones regulares o irregulares de algún fenómeno o estudio aplicado.

La noción de Estadística se derivó originalmente del vocablo estado, porque ha sido función tradicional de los gobiernos centrales llevar registros de población, nacimientos, defunciones, cosechas, impuestos y muchos otros objetos, sujetos y actividades. En el año 2000 a.C. ya se realizaba en China el primer censo del que se tenga conocimiento, en 1602 había en Francia organismos dedicados a la estadística.

Debido a lo extenso y variado del campo cubierto por la estadística es difícil proponer una definición precisa del concepto. No obstante, todos los estadísticos están de acuerdo en clasificarla en dos tipos: la estadística descriptiva y la estadística inferencial. Ambas desempeñan funciones distintas pero complementarias en el análisis estadístico.

La **Estadística descriptiva** brinda una serie de procedimientos diseñados para organizar y resumir los datos. El análisis se limita en sí mismo a los datos recolectados. Si bien la descripción de dichos datos es a veces en sí misma un fin, en la mayoría de los análisis estadísticos se está más al comienzo de la tarea que al término de la misma. La **Estadística inferencial** engloba una serie de estrategias que permiten generalizar las propiedades del conjunto de datos empíricos al conjunto total de datos a los que representan.

La Estadística es una disciplina transversal aplicada en una amplia variedad de áreas:

- ✓ Administración
- ✓ Antropología (antropometría)
- ✓ Agronomía (biometría)
- ✓ Economía (econometría)
- ✓ Geología (geoestadística)
- ✓ Psicología (psicometría)
- ✓ Física, medicina, veterinaria, educación, etc.

En particular, la economía moderna se ha tornado tan compleja que la incertidumbre en cuanto a las futuras operaciones de la empresa se acrecienta; sin embargo, las firmas empresariales deben tomar decisiones frente a tales incertidumbres. La decisión sólida y razonada exige análisis e interpretación cuidadosos de la información sobre hechos, y a este respecto las técnicas estadísticas han demostrado ser especialmente útiles.

Así, por ejemplo, son áreas de aplicación dentro de la administración y la economía:

- ✓ Estudios de mercado
- ✓ Control estadístico de procesos
- ✓ Auditorías
- ✓ Medición de satisfacción de clientes
- ✓ Medición de satisfacción laboral

- ✓ Pronósticos de demandas
- ✓ Previsión de tendencias macro y microeconómicas

2 Conceptos básicos

La **población** se define como un conjunto de elementos (sujetos, objetos, entidades abstractas, etc.) que poseen una o más características específicas en común. En general, este término hace referencia al conjunto total de elementos que se desea estudiar, de manera que una población queda definida cuando se hace explícita la característica (características) que esos elementos comparten. Cada elemento de la población se denomina **individuo**. Todos los individuos de una población poseen características que pueden tomar diferentes valores para cada uno. Se llama **variables** o **atributos** a estas características y cada uno de los resultados posibles se denominan **categoría** o **valor**.

Una **muestra** es un subconjunto de elementos de una población. Para poder describir con exactitud las propiedades de una población cualquiera sería necesario examinar cada uno de los elementos que la componen.



Pero dado que las poblaciones que habitualmente interesa estudiar son tan grandes que normalmente resulta difícil, costoso o imposible tener acceso a todos los elementos, se debe utilizar la información suministrada por una muestra para inferir conclusiones acerca de toda la población. Para que esto sea posible es necesario que la muestra utilizada sea representativa de la población.

Además de cuestiones de dinero y de tiempo (menor costo y mayor rapidez en la obtención de los resultados), suele trabajarse con muestras en los siguientes casos:

- cuando la población sea infinita o tan grande que el censo exceda las posibilidades del investigador,
- cuando la población sea suficientemente uniforme desde cierto punto de vista lo que hará que cualquier muestra dé una buena representación de la población – con lo cual, carecerá de sentido examinar la población completa,
- cuando el proceso de medida o investigación pueda ser destructivo, por ejemplo: se quiere hacer un estudio sobre la cantidad de fósforos que vienen fallados. Para poder medir esta variable es necesario prender cada uno de los fósforos – lo cual provoca la “destrucción” de los mismos.

El problema del muestreo consiste entonces en cómo seleccionar una muestra de modo tal de obtener la máxima aproximación a los parámetros poblacionales compatible con las restricciones de costo y de tiempo existentes.

Trabajar con muestras tiene un riesgo asociado, Por lo tanto, es deseable contar con muestras que sean representativas, esto es, que la muestra presente una variabilidad lo más parecida posible a la existente en la población (respecto de las variables que se quieren relevar) y de esta manera, poder generalizar los resultados de la población a partir de la muestra.

Para ello, es necesario tener en cuenta cuestiones tales como:

- Tamaño de la muestra
- Tipo de muestreo utilizado – “forma” en la cual se seleccionan los elementos de la muestra.

Determinar el tamaño adecuado para una muestra no es una tarea fácil y, además, es una elección crucial ya que una mala elección puede traer consecuencias negativas. Está claro que, si una muestra es demasiado grande, se habrá realizado una inversión inútil; mientras que, si es demasiado pequeña, no servirá a los propósitos de la investigación.

Lamentablemente, no existe ninguna regla general del estilo “tomar un 10% de la población” que asegure el éxito. Cada caso y situación particular merece un análisis detallado. El tamaño de muestra se calcula considerando el máximo error que se está dispuesto a cometer (en la estimación), la confianza que se desea tener y la variabilidad de la variable que se quiere relevar.

Respecto del tipo de muestreo, desde el punto de vista teórico, existen solamente dos grandes categorías de muestras:

Muestras probabilísticas o “al azar”

Muestras no probabilísticas

Las primeras (muestras probabilísticas) se caracterizan porque permiten especificar la probabilidad (posibilidad) que tiene cada elemento de la población de ser incluido en la muestra. En el caso más sencillo, cada uno de los elementos tiene la misma probabilidad de integrar la muestra, pero ésta no es una condición necesaria. Lo que sí es necesario, es que, para cada elemento, se debe poder especificar cuál es la probabilidad de inclusión.

En cuanto a las muestras no probabilísticas, no existe forma de determinar la probabilidad que tiene cada elemento de ser seleccionado, y ni siquiera se tiene la seguridad de que cada elemento tenga alguna posibilidad de ser seleccionado.

El muestreo probabilístico es el único que posibilita que el investigador pueda calcular el grado en el cual los resultados basados en la muestra tienden a diferir de lo que habría obtenido si hubiera trabajado con toda la población. Esto es, este tipo de muestreo “permite” que se estimen características poblacionales a partir de las muestrales.

Cuando se utiliza el muestreo probabilístico, se puede especificar el tamaño de la muestra que se necesita si se quiere tener un cierto grado de certeza de que los resultados de la muestra no difieran en más de una determinada cantidad de aquellos que habría producido un estudio de la población total.

Las principales ventajas del muestreo no probabilístico son la comodidad y la economía, ventajas que pueden superar los riesgos supuestos en la no utilización del muestreo probabilístico. Sin embargo, es necesario no perder de vista que, si se trabaja con

muestras no probabilísticas, no hay manera de generalizar a la población los resultados obtenidos a partir de la muestra.

En el Módulo 3 se profundizarán los conceptos vinculados con los tipos de muestreo.

Volviendo al concepto de población, la definición de la población a estudiar está estrechamente ligada con la investigación que se desea realizar. Si se quiere analizar el rendimiento académico de los alumnos de Estadística del año 2014 de la Facultad de Ciencias Económicas de la UNICEN, se tendrá una población, mientras que si se quiere estudiar el rendimiento académico de los alumnos de Estadística del año 2014 de todas las facultades de Ciencias Económicas del país, la población será otra.

La misma situación se presenta para la definición de las variables que deban ser relevadas. Dependen de lo que se desea investigar.

Por ejemplo, supongamos que se desea estudiar la productividad de las pequeñas y medianas empresas (PyMEs) de la Provincia de Buenos Aires. Los individuos serán cada una de las empresas bonaerenses consideradas como pequeña o mediana. Una muestra será cualquier subconjunto de dichas empresas. Algunas variables a considerar podrían ser: facturación anual, tipo de producción, partido de radicación, número de empleados, etc.



En un estudio de mercado previo al lanzamiento de un producto, ¿cuál es la población? ¿Trabajaría con una muestra? ¿Por qué? ¿Cuáles serían las variables que se deberían estudiar?

Una medida de resumen que se calcula para describir una característica de la totalidad de una población se llama **parámetro**, y aquella que se calcula para describir una característica de una muestra de la población, se llama **estadístico**.

POBLACIÓN



parámetro

MUESTRA



estadístico



Se dijo anteriormente que es habitual trabajar con muestras porque las poblaciones son muy grandes. ¿Es la única razón? ¿Qué considera más conveniente: trabajar con la población o

En el resto de este cuadernillo consideraremos que en todos los casos se está trabajando con toda la población. Los métodos de muestreo exceden los temas que se cubren. Sin embargo, es necesario estar muy atento a las generalizaciones incorrectas, por cierto, que suelen realizarse a partir de muestras que no fueron seleccionadas de manera probabilística.

3 Tipos de variables. Escalas de medición

Dependiendo de los valores que pueden tomar las variables, pueden ser:

Cualitativas: aquéllas cuyos posibles valores son cualidades.

Cuantitativas: aquéllas cuyos posibles valores son numéricos y provienen de un proceso de conteo o de medición.

Por ejemplo, si se plantea la variable “Facultad en la que estudia”, sus posibles valores (o respuestas) podrían ser: Ciencias Económicas, Ciencias Exactas, Ciencias Veterinarias, Arte, Ciencias Humanas, Otra o ninguna. Mientras que si la variable fuera “Distancia a la que vive desde el campus (en km.)”, esta variable sería cuantitativa ya que las posibles respuestas son cantidades, por ejemplo, a 5,6 km.

Al plantear una variable determinada, es necesario definir si será cuantitativa o cualitativa y dejar claramente especificados los posibles valores que puede tomar. A este conjunto de posibles valores se lo denomina **categorización** de una variable. Y para que dicha categorización sea estadísticamente correcta las categorías tienen que ser *exhaustivas* (todos los individuos deben poder incluirse en alguna de las categorías), y *excluyentes* (cada individuo debe pertenecer a una sola categoría).

Las condiciones de exhaustividad y exclusión deben cumplirse para la categorización de cualquier tipo de variable (para que sea estadísticamente correcta).



La variable “Distancia a la que vive desde el campus (en km.)” también podría haberse pensado de manera cualitativa, ¿cómo la replantearía para que sea cualitativa? ¿Las variables cuantitativas pueden ser transformadas en variables cualitativas? ¿Y las cualitativas en cuantitativas?

Comentario: En algunos contextos, se llaman “variables” a aquéllas que son cuantitativas y “atributos” a las cualitativas, y se suele denominar categorías a los valores posibles de las variables cualitativas y valores a los valores posibles (valga la redundancia) de variables cuantitativas.

Existen diferencias sustanciales aún entre algunas variables cualitativas, como entre cuantitativas. Si por ejemplo se estudia la variable sexo, la única relación que se puede establecer entre dos individuos en particular es la de igualdad o desigualdad, pero no se podrá establecer una relación de orden (es decir de mayor o menor). Si en cambio la variable estudiada fuese el máximo nivel de estudios alcanzado las observaciones podrían ordenarse. Por otro lado, si la variable relevada fuese la edad se podrían ordenar las observaciones y, además, cuantificar las distancias entre ellas. Dependiendo de la riqueza de las relaciones que se puedan establecer entre los diferentes valores de una variable, existen diferentes **niveles o escalas de medición**.

Tradicionalmente se han distinguido cuatro escalas de medida: nominal, ordinal, de intervalo y de razón. La escala **nominal** permite **clasificar** a los individuos de la población en estudio de modo que todos los que pertenezcan a una misma categoría sean equivalentes respecto de la variable que se está midiendo. Esta escala de medida es la más débil de todas; la única relación que es posible establecer entre los objetos o sujetos es la de *igualdad – desigualdad*. Un ejemplo es la variable sexo.

La escala **ordinal** consiste en asignar a los individuos una identificación que permita ordenarlos según el nivel de variable que poseen. En la escala ordinal, además de estar presente la relación de igualdad-desigualdad propia de la escala nominal, puede establecerse una relación de **orden** (mayor, igual o menor) entre las categorías. Por ejemplo, es posible ordenar a un conjunto de individuos según el nivel de satisfacción con un determinado servicio dividiéndolos en 5 categorías:

- A: Totalmente satisfecho
- B: Satisfecho
- C: Medianamente satisfecho
- D: Poco satisfecho
- E: Nada satisfecho


Sin embargo, no es posible afirmar nada acerca de la magnitud de la diferencia existente entre dos individuos, esto es, puede decirse que el individuo A tiene un nivel de satisfacción mayor que un individuo B, pero no puede decirse cuánto más satisfecho está. Específicamente se desconoce si la diferencia entre la satisfacción de un sujeto de la categoría A y otro de la categoría B es igual (o distinta) que la diferencia entre la satisfacción de dos sujetos incluidos en las categorías C y D.

En la escala de **intervalos**, además de poder clasificar y ordenar a los individuos según la variable considerada, puede **cuantificarse la distancia** entre dos individuos. En este tipo de escala no existe el cero absoluto, es decir no existe un valor numérico que indique ausencia absoluta de cantidad de variable. El valor 0 es un punto arbitrario en esta escala. Además, la diferencia que existe entre dos valores consecutivos es siempre la misma (por ejemplo, la diferencia entre 10 y 11 es la misma que la que existe entre 3 y 4) y no es posible establecer relaciones proporcionales del estilo “12 es el doble que 6” (dado que no existe un cero absoluto). La temperatura resulta un ejemplo claro de una variable que se mide utilizando este tipo de escala. Cuando se dice, en la escala Celsius, que ayer hubo 20 grados de temperatura máxima y hoy 25, se está diciendo no sólo que hoy hubo más temperatura que ayer (afirmación propia de la escala ordinal) sino que hubo 5 grados más. Del mismo modo 20 grados son 5 más que 15. La diferencia entre 25 y 20 es la misma que entre 20 y 15. Sin embargo, no es posible afirmar que 20 grados representen el doble que 10. En la escala Celsius el cero es un punto arbitrario de la escala y, por tanto, no indica ausencia de cantidad de variable.

La escala de **razones** añade a la de intervalos la presencia del cero absoluto, el cual indica ausencia absoluta de la cantidad de variable. Esto permite observar la relación



Si las categorías de la variable “Nivel de satisfacción” se definen como
1: Totalmente satisfecho, 2: Satisfecho, 3: Medianamente satisfecho,
4: Poco satisfecho y 5: Nada satisfecho,
¿Esto la convierte en una variable cuantitativa?



Si se desea estudiar el gasto mensual en transporte de los estudiantes de la UNCPBA que cursan en el campus ¿cuál es la población?, ¿cuáles son los individuos? ¿qué variables será conveniente relevar? ¿cómo sería una categorización correcta para cada una de ellas?
¿a qué tipo de escala corresponden?

proporcional entre dos valores de la variable. La edad de las personas, la extensión de las jornadas laborales, el tamaño de los locales comerciales, son ejemplos de variables medidas en escala de razón.

4 Organización de los datos

Los datos pueden ser obtenidos de diferentes maneras, mediante publicación de fuentes gubernamentales o privadas, industriales o individuales, mediante el diseño de un experimento, efectuando una encuesta, etc. Una vez realizado el relevamiento, las observaciones obtenidas suelen ser registradas en el orden en que se recolectan. Se dice que los datos están en forma bruta. Pero dichos datos fueron tomados con algún objetivo, y es necesario organizarlos y presentarlos en cuadros y/o gráficos para facilitar su visualización, interpretación y realizar un posterior análisis.

La presentación en tablas y gráficos, requiere la especificación de un título y de la fuente (por ejemplo, elaboración propia).

4.1 Tablas de distribución de frecuencias

Los datos brutos, sin organizar, son prácticamente imposibles de interpretar. Por ejemplo:

- un analista de empresas que trate de reconocer la configuración que tienen las ventas de una compañía, poco podría averiguar mirando simplemente las facturas producidas en un período determinado;
- la lista de productos fabricados por los trabajadores de una planta y expresados en unidades de producción, apenas si darían una vaga idea de la productividad del grupo.

Para utilizarlos mejor, es necesario organizarlos en alguna forma sistemática. Esto se efectiviza en primer lugar confeccionando una tabla llamada **tabla de distribución de frecuencias**.


Claramente, en situaciones con una baja cantidad de datos, los datos brutos pueden ser interpretados sin necesidad de organizarlos. Sin embargo, en los tiempos actuales son excepcionales las situaciones en las cuales se cuenta con pocos datos para tomar decisiones. El desafío de estos tiempos consiste en poder obtener información útil a partir de los grandes volúmenes de datos.

Consideremos que una empresa desea analizar el nivel de estudios de sus empleados. Definamos la variable:

X: "Máximo nivel de estudios completado"

Las categorías a considerar son: Ninguno, Primario, Secundario, De grado, Post-grado. Se confecciona, entonces, una tabla tal que en la primera columna conste la variable con sus posibles categorías, y en la segunda columna el número de individuos correspondientes a cada una de ellas.

Máximo nivel de estudios (X)	Cantidad de personas (f_i)
Ninguno	0
Primario	150
Secundario	200
De grado	50
Post-grado	100
Total	N = 500



¿Se podría haber definido la variable como "estudios cursados"?
 ¿Es necesario considerar la categoría "ninguno"?
 ¿La variable se podría haber categorizado de alguna otra manera?

A la cantidad de observaciones correspondientes a cada categoría se la llama **frecuencia absoluta** y suele designársela como f_i (frecuencia correspondiente a la categoría i-ésima).

Muchas veces, interesa conocer la proporción de observaciones correspondientes a cada categoría, con respecto al total de la población. Es necesario hablar en ese caso de **frecuencias relativas** (f_{ri}). Para cada categoría la frecuencia relativa se obtiene haciendo:

$$f_{ri} = \frac{f_i}{N}$$

Siendo: N = total de individuos de la población.

También puede expresársela en forma porcentual, dando lugar entonces a las **frecuencias relativas porcentuales** (también llamadas **frecuencias porcentuales** o **porcentajes**).


$$f_{ri} \% = f_{ri} \cdot 100\%$$

Para el Ejemplo 1, puede obtenerse una distribución categórica con **frecuencias relativas** y **frecuencias relativas porcentuales**, como sigue:

Máximo nivel de estudios (X)	Cant. de personas (f_i)	f_{ri}	$f_{ri} \%$
Primario	150	0,30	30
Secundario	200	0,40	40
De grado	50	0,10	10
Post-grado	100	0,20	20
Total	500	1	100

Donde, por ejemplo: $f_{r1} = \frac{150}{500} = 0,3$ $f_{r1} \% = \frac{150}{500} \cdot 100\% = 30\%$

Las frecuencias relativas son de suma importancia cuando se quieren comparar dos distribuciones categóricas con distintos totales. En ese caso las cifras absolutas carecen de sentido; por lo tanto, se debe acudir a valores relativos.



Si se quieren comparar dos poblaciones diferentes, ¿es más conveniente hacerlo mediante frecuencias absolutas, relativas o relativas porcentuales? ¿Podrías dar algún ejemplo en el cual brindar las conclusiones sólo con porcentajes pueda conducir a conclusiones confusas?

4.1.2 Tabla de distribución de frecuencias para variables cuantitativas

Cuando se trabaja con variables cuantitativas, los datos pueden organizarse de dos maneras diferentes.

4.1.2.1 Caso A: datos agrupados en forma simple

Es adecuado utilizar esta disposición de los datos cuando la variable a estudiar adopta una cantidad no muy grande de valores distintos.

Ejemplo 2

Supongamos que el fenómeno a estudiar es el número de piezas que no responden a las normas de calidad ISO 9000, producidas en cada jornada de trabajo en una fábrica de

amortiguadores. Se relevó la información durante 120 días obteniéndose los siguientes datos:

3 2 4 5 6 4 3 4 5 6 3 6 7 4 5 6 2 6 5 3
 3 3 3 4 5 4 3 6 3 3 5 4 6 4 4 7 2 4 3 2
 2 4 2 7 3 5 4 5 5 4 5 6 7 4 4 6 5 4 2 4
 4 2 2 2 3 6 2 4 5 4 2 8 5 3 3 3 5 2 4 4
 7 5 6 4 2 6 3 8 4 4 5 7 5 2 2 3 4 2 4 5
 2 5 5 5 2 6 7 6 2 3 3 6 7 3 7 4 4 4 8 8

La variable (X) es: “Cantidad de piezas defectuosas producidas”. Como solamente toma 7 valores de variable distintos, pueden ordenarse según su magnitud (creciente o decreciente) y contabilizarse la cantidad de observaciones (cantidad de días) que corresponde a cada valor de la variable. De esta manera, pueden organizarse los datos en una tabla de distribución de frecuencias tal como fue explicado para variables cualitativas:

X	f_i
2	20
3	21
4	30
5	21
6	15
7	9
8	4
Total	N = 120



Respecto a la última fila de la tabla de distribución de frecuencias, ¿cuál de las siguientes afirmaciones es correcta?

- 1· En 4 días se realizaron 8 piezas defectuosas
- 2· En 8 días se realizaron 4 piezas defectuosas

En forma análoga a lo definido para tablas de frecuencias de datos cualitativos, a f_i la llamamos frecuencia absoluta correspondiente al i -ésimo valor de variable.



Si el gerente de producción quiere comparar el nivel de eficiencia en dos períodos de tiempo diferentes, ¿será suficiente realizar la tabla de distribución de frecuencias absolutas de cada una de las plantas?

Análogamente a lo realizado para datos cualitativos, es posible calcular las frecuencias relativas y porcentuales:

X	f_{ri}	$f_{ri}\%$
2	0,17	17
3	0,18	18
4	0,25	25
5	0,18	18
6	0,13	13
7	0,08	8
8	0,03	3
Total	1,02	102



La tabla anterior se confeccionó redondeando a los centésimos (con reglas matemáticas tradicionales). Esto provocó que el total de las frecuencias relativas sumen más que 1 y el de las porcentuales más que 100%. Esto se corrige modificando la mayor frecuencia relativa. ¿Por qué cree que es ésta la frecuencia que se modifica?

Con la modificación correspondiente la tabla de distribución de frecuencias relativas y porcentuales sería:

X	f_{ri}	$f_{ri}\%$
2	0,17	17
3	0,18	18
4	0,23	23
5	0,18	18
6	0,13	13
7	0,08	8
8	0,03	3
Total	1	100

En ocasiones, además de interesarnos la cantidad de observaciones correspondientes a cada valor (frecuencia absoluta), o la proporción que representa un valor con respecto al total (frecuencia relativa), también puede interesarnos saber cuántas observaciones tienen

un valor menor o igual (o menor, o mayor, ...) a un determinado valor de variable. Debemos hablar en estos casos de **frecuencia acumulada creciente** o **decreciente**.

Si, por ejemplo, nos preguntamos ¿en cuántos días se produjeron hasta 3 piezas defectuosas? O ¿en cuántos días se detectaron a lo sumo 8 piezas defectuosas?; las respuestas pueden encontrarse en la siguiente tabla:

X	Fa↑ (frecuencias acumuladas crecientes)
2 o menos ($X \leq 2$)	20
3 o menos ($X \leq 3$)	41
4 o menos ($X \leq 4$)	71
5 o menos ($X \leq 5$)	92
6 o menos ($X \leq 6$)	107
7 o menos ($X \leq 7$)	116
8 o menos ($X \leq 8$)	120

La tabla anterior muestra la **distribución de frecuencias acumuladas crecientes absolutas** porque resulta de sumar (acumular) frecuencias absolutas. Esto es, contabiliza la cantidad de observaciones con un valor menor o igual a un determinado valor de variable. En efecto, la primera frecuencia acumulada (F_1) resulta igual a la primera frecuencia absoluta (f_1), es decir:

$$F_1 = f_1$$

$$\text{Para la segunda hacemos: } F_2 = f_1 + f_2 \text{ o } F_2 = F_1 + f_2$$

$$\text{Para la tercera: } F_3 = f_1 + f_2 + f_3 \text{ o } F_3 = F_2 + f_3$$


...

$$\text{Para la n-1: } F_{n-1} = f_1 + f_2 + \dots + f_{n-1} \text{ o } F_{n-1} = F_{n-2} + f_{n-1}$$

$$\text{Y, para la enésima: } F_n = f_1 + f_2 + \dots + f_n \text{ o } F_n = F_{n-1} + f_n$$

$$\text{Es decir } F_n = \sum_{i=1}^n f_i = N$$

Así la $F_3 = 71$ para nuestro ejemplo, indica que en 71 días se produjeron 4 piezas defectuosas o menos.



¿Podrían calcularse las frecuencias acumuladas en el caso de variables cualitativas nominales?

También pueden acumularse en forma creciente las frecuencias relativas (y las frecuencias acumuladas crecientes porcentuales), del siguiente modo:

X	$F_{ar}\uparrow$ (frecuencias acumuladas crecientes relativas)	$F_{a\%}\uparrow$ (frecuencias acumuladas crecientes porcentual)
$X \leq 2$	0,17	17
$X \leq 3$	0,35	35
$X \leq 4$	0,58	58
$X \leq 5$	0,76	76
$X \leq 6$	0,89	89
$X \leq 7$	0,97	97
$X \leq 8$	1	100

Se construye así la distribución de frecuencias acumuladas relativas crecientes. Donde, por ejemplo, $F_3 = 0,58$ indica que el 58% de los días se produjeron a lo sumo 4 piezas defectuosas.

Si se quisiera conocer ¿en cuántos días se produjeron 2 o más piezas defectuosas?, la respuesta se encuentra en la siguiente tabla:

X	$F_{a\downarrow}$ (frecuencias acumuladas decrecientes absolutas)
2 o más ($X \geq 2$)	120
3 o más ($X \geq 3$)	100
4 o más ($X \geq 4$)	79
5 o más ($X \geq 5$)	49
6 o más ($X \geq 6$)	28
7 o más ($X \geq 7$)	13
8 o más ($X \geq 8$)	4

Resultado que llamamos **distribución de frecuencias acumuladas decrecientes**, porque resulta de restar (acumular en forma decreciente) al total las frecuencias absolutas. También pueden calcularse las frecuencias acumuladas decrecientes relativas y porcentuales.



Interprete la quinta frecuencia de cada una de las tablas del punto 4.1.2.1

4.1.2.2 Caso B: datos agrupados en intervalos de clase

En el Caso A se vio el modo de resumir un conjunto de datos cuantitativos cuando los diferentes valores de variable no son muchos, por tanto, la distribución en forma simple de los mismos, proporciona una organización adecuada (en el sentido de que leyendo el cuadro se pueden obtener conclusiones).

Si la variable a analizar adopta una gran cantidad de valores el resumen citado anteriormente no brinda información clara, esto es, se tendrían tantos “renglones” en la tabla de distribución de frecuencias como valores de variable. Por otro lado, en ocasiones, al relevar los datos, se formulan preguntas con opciones de respuestas que no permiten conocer el valor exacto del dato sino un rango de valores entre los que se encuentra. Un ejemplo de esto se puede encontrar en las preguntas acerca de los ingresos mensuales de un individuo. Difícilmente un encuestador conseguirá una respuesta exacta. En cambio, es factible que el encuestado pueda señalar “entre qué valores” se encuentra dicho monto.

En estos casos se utiliza el agrupamiento en intervalos.

Es necesario distinguir dos situaciones:

- 1) *Aquellas en las cuales se tienen los valores exactos de la variable y que, sólo con fines de organización se agrupan en intervalos*
- 2) *Aquellas en las cuales los datos son relevados mediante intervalos (no conociendo de esta manera los valores exactos)*



¿Qué característica tendría la tabla de distribución de frecuencias en este ejemplo si se lo agrupara siguiendo los lineamientos del punto 4.1.2.1?

Ejemplo 3

Supongamos que se desea analizar los años de antigüedad de los 2000 empleados de una cadena de supermercados.

Cuando la variable adopta muchos valores distintos se hace necesario agrupar los datos en categorías que se denominan intervalos de clase.

Cuando los datos se agrupan en tablas de distribución por intervalos, el proceso de análisis e interpretación de datos se vuelve mucho más manejable y significativo. Pero no debemos desconocer que se pierde cierta precisión debido a que no se trabajará con los verdaderos valores de la variable.

Al construir la distribución por intervalos se debe prestar atención a:

- Seleccionar el número apropiado de intervalos.
- Establecer los límites de los intervalos para que los mismos resulten exhaustivos y excluyentes.

La cantidad de intervalos no debe ser muy grande ni muy pequeño. Un gran número de clases puede que no condense los datos suficientemente para ser de valor práctico; un número pequeño de intervalos tiende a resumir en exceso los datos, por lo que se pierde mucha información. Algunos autores sostienen que el número de intervalos debe variar entre 5 y 20.

En el ejemplo de la antigüedad de los 2000 empleados de la cadena de supermercados se puede suponer la siguiente distribución:

X (años de antigüedad)	f _i (cantidad de empleados)
$0 \leq x < 5$	300
$5 \leq x < 10$	200
$10 \leq x < 15$	300
$15 \leq x < 20$	500
$20 \leq x < 25$	200
$25 \leq x < 30$	250
$30 \leq x < 35$	250
	N = 2000

Antes de continuar es necesario hacer algunas aclaraciones respecto de la notación. El primer intervalo: $0 \leq x < 5$ indica que se consideran todos los años de antigüedad mayores o iguales a 0 y menores a 5 (sin incluir el 5). Esta notación resulta clara para los que estamos familiarizados con estos símbolos, pero no para alguien que no los usa cotidianamente. En caso de tener que presentar un informe, se recomienda no utilizar símbolos matemáticos pero tener especial cuidado en que los intervalos resulten excluyentes y exhaustivos.

Obtenida la distribución de frecuencias, es necesario conocer algunas definiciones técnicas.

A las agrupaciones $5 \leq x < 10$;... etc., se las llama clases o intervalos de clases.

Los números situados a la izquierda de cada intervalo se llaman **límites inferiores** de clases y los números situados a la derecha, **límites superiores** de clases.

El punto medio de la clase se llama **marca de clase** y la representaremos por x_{ic} . El punto medio de la i -ésima clase se obtiene, entonces, haciendo:

$$x_{ic} = \frac{\text{límite inferior}_i + \text{límite superior}_i}{2}$$

Por ejemplo para la tercera clase:

$$x_{ic} = \frac{10 + 15}{2} = 12,5$$

El número de unidades entre los límites de un intervalo se llama amplitud del intervalo y se lo designa con una c . Cuando la misma amplitud es usada para todos intervalos, se tiene una distribución con intervalos uniformes.

En el ejemplo de la tabla anterior, se tiene una distribución con intervalos uniformes cuya amplitud $c = 5$.

De esta manera, cada intervalo tiene su límite inferior, límite superior, amplitud y marca de clase.



¿Los intervalos de clase de una distribución, deben tener todos las mismas amplitudes? ¿Por qué?


Habiendo consensuado cuáles son los intervalos adecuados para organizar los datos, puede presentarse una tabla de distribución de frecuencias con las frecuencias absolutas, relativas y porcentuales. Al igual que en la organización de datos simples, pueden calcularse las frecuencias acumuladas crecientes y decrecientes para responder preguntas del estilo ¿cuántos empleados tienen una determinada antigüedad o menos?; o ¿cuántos empleados tienen una determinada antigüedad o más?

X (años de antigüedad)	$F_a \uparrow$	$F_{a\%} \uparrow$
Menos de 0 años de antigüedad (< 0)	0	0
Menos de 5 años de antigüedad (< 5)	300	15
Menos de 10 años de antigüedad (< 10)	500	25
Menos de 15 años de antigüedad (< 15)	800	40
Menos de 20 años de antigüedad (< 20)	1300	65
Menos de 25 años de antigüedad (< 25)	1500	75
Menos de 30 años de antigüedad (< 30)	1750	85,5
Menos de 35 años de antigüedad (< 35)	2000	100

Así $F_a \uparrow = 500$ indica que hay 500 empleados con menos de 10 años de antigüedad. Del mismo modo $F_{a\%} \uparrow = 65$, indica que el 65% del total de los empleados tienen menos de 20 años de antigüedad.

Análogamente, para las frecuencias acumuladas decrecientes (absolutas y relativas), la tabla es:

X (años de antigüedad)	$F_a \downarrow$	$F_{a\%} \downarrow$
0 o más años de antigüedad (≥ 0)	2000	100
5 o más años de antigüedad (≥ 5)	1700	85
10 o más años de antigüedad (≥ 10)	1500	75
15 o más años de antigüedad (≥ 15)	1200	60
20 o más años de antigüedad (≥ 20)	700	35
25 o más años de antigüedad (≥ 25)	500	25
30 o más años de antigüedad (≥ 30)	250	12,5
35 o más años de antigüedad (≥ 35)	0	0



Analizar cuáles de las siguientes preguntas pueden contestarse con la información de las tablas anteriores y cuáles no:

1. Si los empleados se jubilan con una antigüedad de al menos 25 años, ¿cuántos están en condiciones de jubilarse?
2. ¿Cuántos empleados tienen más de 10 años de antigüedad?
3. ¿Cuántos empleados tienen al menos 10 años de antigüedad?

A tener en cuenta:

- Los datos pueden ser relevados de forma simple o en intervalos. En el caso en el cual se releven en forma simple, puede decidirse (dependiendo de la cantidad de valores diferentes que puede tomar la variable) organizarlos de forma simple o en intervalos. Pueden surgir algunas cuestiones que puedan ser respondidas a partir de la organización en intervalos y otras en las cuales se necesiten los datos simples. En este último caso, más allá de la organización elegida para presentar los datos, tienen que usarse los datos en forma simple para responderlas.
 - No confundir la escala medición “de intervalos” con el agrupamiento en intervalos.

4.1.3 Organización de datos para análisis bivariado

En muchas ocasiones resulta relevante estudiar el comportamiento conjunto de dos (o más) variables. Es decir que de cada individuo de la población o de la muestra se observan dos (o más) características. Si se analizan dos variables se dice que se está efectuando un **análisis bivariado**. Si el estudio comprende más de dos variables se lo llama **análisis multivariado**. Por ejemplo, puede ser interesante estudiar la asociación entre el sueldo y el sexo de un grupo de empleados, o la asociación entre la inversión en publicidad y las ventas de un grupo de empresas.

Para organizar los datos en este tipo de análisis se utilizan las **tablas de contingencia**, las cuales son muy útiles para obtener conclusiones sobre el comportamiento combinado (conjunto) de las variables.

Ejemplo 4

Se releva información acerca de la edad y el cargo que desempeñan los empleados de una empresa. La información que se obtiene es la siguiente:

Empleado	Edad	Cargo
ÁLVAREZ	43	operario
AMUCHASTEGUI	28	administrativo
ARIAS	31	administrativo
PEREZ, J.	34	operario
BARBOSA	27	operario
RODRÍGUEZ, M.	29	operario
BECERRA	51	jefe de sección
BELUCCI	54	administrativo
BENITEZ	47	administrativo
SUÁREZ, G.	42	operario
DÍAZ, F.	48	administrativo
CARABETTA	54	operario
CEJAS	33	operario
DOMÍNGUEZ, N.	30	operario
DIAZ, M de los A.	26	operario
DIAZ, N.G.	44	administrativo
DOS SANTOS	41	administrativo
DUCA	39	jefe de sección
ELIZARI	51	administrativo
ESPEJO	53	operario
SABINO	50	operario

Empleado	Edad	Cargo
FERNANDEZ, A. E.	50	administrativo
FERNANDEZ, L. D.	44	administrativo
FERREIRA	52	jefe de sección
NIELSEN	48	operario
FORESTI	36	operario
MOLINA	28	operario
FUEYO	34	operario
FURCI	36	administrativo
GALLI	25	administrativo
GARAY	40	operario
GARCIA, J.	38	operario
RODRÍGUEZ, S.	32	administrativo
GIRBALDI	39	operario
GOÑI	48	jefe de sección
GRAMUGLIA	49	operario
RAMIREZ	53	administrativo
IGLESIAS	54	administrativo
IRIGOIN	29	operario
SERRANO	39	administrativo
ALVAREZ, J.	33	administrativo
LOPEZ, P.	26	operario

En la tabla anterior se tienen 42 observaciones bivariadas (42 empleados y 2 variables: edad y cargo). Esta información también podría organizarse en un cuadro de doble entrada (o tabla de contingencia) tal como se muestra a continuación:

		Edad		Total
		entre 25 y 39	entre 40 y 54	
Cargo	Administrativo	7 (f_{11})	10 (f_{12})	17 (f_{1+})
	Operario	14 (f_{21})	7 (f_{22})	21 (f_{2+})
	Jefe de sección	1 (f_{31})	3 (f_{32})	4 (f_{3+})
Total		22 (f_{+1})	20 (f_{+2})	42 ($N = f_{++}$)

En esta tabla se observan dos tipos de frecuencias (cantidades): las **frecuencias marginales** y las **frecuencias conjuntas**.

Las primeras contabilizan la cantidad de datos que se tienen considerando sólo una variable. De esta manera f_{i+} se corresponde con la cantidad total de observaciones de la i -

ésima fila (f_{1+} indica que 17 empleados son Administrativos). Y f_{+j} se corresponde con la cantidad total de observaciones de la j -ésima columna (f_{+1} indica que 21 empleados tienen entre 25 y 39 años).

Las frecuencias conjuntas (f_{ij}) denotan la cantidad de datos que pertenecen a la categoría de la i -ésima fila y de la j -ésima columna a la que hacen referencia. Por ejemplo, el valor 13 (f_{21}) indica que hay 14 empleados que son operarios (fila 2) y que tienen edades comprendidas entre 25 y 39 años (columna 1).

Por último f_{++} referencia la cantidad total de datos.

Además de las frecuencias absolutas, también pueden calcularse frecuencias porcentuales, ya sea respecto del total de casos o tomando a alguna variable como base (dependiendo del interés).

Veámoslo en el ejemplo. Si se toma como base la totalidad de los individuos la tabla de contingencia de valores porcentuales será:

		Edad		Total
		entre 25 y 39	entre 40 y 54	
Cargo	Administrativo	16,67%	23,81%	40,47%
	Operario	33,33%	16,67%	50,00%
	Jefe de sección	2,38%	7,14%	9,52%
Total		52,38%	47,62%	100% (42)

Algunas conclusiones que se pueden extraer de esta tabla:

- Del total de los *empleados*, el 33,33% son operarios y tienen entre 25 y 39 años de edad.
- Del total de los *empleados*, el 40,47% son administrativos.

Si se toma como base la variable Cargo los porcentajes se calculan tomando cada categoría de dicha variable como el total:

		Edad		Total
		entre 25 y 39	entre 40 y 54	
Cargo	Administrativo	41,18%	58,82%	100% (17)
	Operario	66,67%	33,33%	100% (21)
	Jefe de sección	25,00%	75,00%	100% (4)
Total		52,38%	47,62%	100% (42)

Algunas conclusiones que se pueden extraer de esta tabla:

- Del total de los *empleados administrativos*, el 41,18% tienen entre 25 y 39 años de edad.
- Del total de los *jefes de sección*, el 75% tienen entre 40 y 54 años.

Si se toma como base la variable Edad la tabla de contingencia correspondiente será:

		Edad		Total
		entre 25 y 39	entre 40 y 54	
Cargo	Administrativo	31,82	50	40,48
	Operario	63,64	35	50,00
	Jefe de sección	4,54	15	9,52
Total		100% (22)	100% (20)	100% (42)



Enuncie algunas conclusiones que se desprendan de la tabla precedente

Al realizar tablas de contingencia con las frecuencias porcentuales, es una buena práctica indicar entre paréntesis las frecuencias absolutas.

4.2 Gráficos

Sabemos que un gráfico es capaz de brindar información mucho más rápidamente que un texto o un conjunto de datos, aun cuando se hayan ordenado en tablas o cuadros. Dicen que una imagen vale más que mil palabras...

Al observar el gráfico correspondiente a una distribución de frecuencias, a menudo resaltan características que no eran evidentes en los datos mismos. Además de que la gráfica ofrece una excelente imagen de los datos en conjunto, puede subrayar también irregularidades y rasgos poco comunes. Por ejemplo, las observaciones muy alejadas que de alguna manera no coinciden con la imagen en conjunto, es decir, con el patrón global de los datos, pueden tener su origen en errores de medición, fallas en el equipo o causas similares.

Existen diferentes tipos de gráficos que se corresponden con las diferentes características de los datos que representan.

4.2.1 Gráficos para datos cualitativos

Las frecuencias absolutas, relativas y relativas porcentuales de variables cualitativas pueden representarse con los gráficos que se detallan a continuación. En todos los casos, consideraremos el Ejemplo 1.

Diagrama circular


Este diagrama, también llamado diagrama de torta se utiliza generalmente para graficar frecuencias absolutas, relativas y relativas porcentuales (porcentajes) para variables cualitativas (también puede utilizarse para variables cuantitativas).

Consiste en un círculo cuyas áreas son divididas proporcionalmente teniendo en cuenta las frecuencias: el total del círculo (360°) se corresponde con el total de las frecuencias, por lo tanto, la frecuencia que quiere representarse será obtenida por una regla de tres simple.

Volviendo al ejemplo presentado (“máximo nivel de estudios completado”), para hallar el área correspondiente a la categoría primaria se procede de la siguiente manera:

Si al 100% de los datos, les corresponden 360°, al 30% le corresponden $\frac{30 \cdot 360}{100} = 108^\circ$. Si trabajáramos con las frecuencias absolutas el razonamiento equivalente es: Si los 500 datos se corresponden con 360°, las 150 observaciones de la categoría primaria se representan por $\frac{150 \times 360}{500} = 108^\circ$. Análogamente se calcula el ángulo central para cada categoría.

El gráfico correspondiente a las frecuencias absolutas y porcentuales es:



En general es más usual encontrar los gráficos circulares representando la frecuencia porcentual. ¿Qué diferencia habría con el gráfico precedente?

Gráfico de barras

Este diagrama consiste en un conjunto de barras, una por cada categoría de variable. La altura de cada una de ellas es proporcional a la frecuencia (absoluta, relativa, relativa porcentual).

Estas barras pueden ser horizontales o verticales, y dependiendo de esto, se denomina diagrama de barras horizontales o diagrama de barras verticales. En el primer caso la variable y sus categorías se ubican en el eje de ordenadas (que llamaremos eje Y) y las frecuencias en el eje de abscisas (eje X). En el caso del diagrama vertical se trabaja al revés (la variable en el eje X y las frecuencias en el eje Y).

No hay un “ancho” predeterminado que tienen que tener las barras, pero es importante tener en cuenta que nunca se deben dibujar “pegadas” o contiguas.

Para el ejemplo propuesto, se muestran los diagramas de barras para las frecuencias relativas porcentuales.




Diagrama de barras verticales

Diagrama de barras horizontales**Pictograma**

Existen variantes “estéticas” de estos gráficos. Son los llamados pictogramas en los cuales, en lugar de tener barras para cada una de las categorías, se muestra un dibujo de las unidades elementales. En el ejemplo visto, cada grupo de 50 personas será representado por el dibujo de una persona y el pictograma resultante será:



4.2.2 Gráficos para variables cuantitativas

Si bien la mayoría de los gráficos presentados para variables cualitativas pueden utilizarse en el caso de cuantitativas, pueden no resultar suficientes para mostrar el comportamiento de los datos (ya que estos gráficos no toman en cuenta la característica de la cuantificación de las distancias que tienen las variables cuantitativas).

4.2.2.1 Datos agrupados en forma simple

Gráfico de líneas (frecuencias absolutas, relativas y porcentuales)

Es la representación gráfica de una distribución de frecuencias de datos organizados de forma simple (sin agrupar). Presenta los valores posibles y sus frecuencias absolutas, relativas o relativas porcentuales.

Este diagrama es similar al diagrama de barras de los datos cualitativos, pero en lugar de hacer una barra por cada categoría o valor de variable, se realiza una línea. Sin embargo, se pueden señalar dos diferencias importantes. En primer lugar, en este gráfico se representan siempre los valores de variable en el eje de abscisas y de las frecuencias en el eje de ordenadas, con lo cual las líneas son siempre verticales. En segundo lugar, y por tratarse de una variable cuantitativa, en el eje de abscisas se debe respetar la escala elegida aun cuando haya valores de la variable con frecuencia cero. Es decir, no se pueden “saltar” valores de variable por el sólo hecho de no aparecer en la distribución. Deberán ser representados con una “línea de altura cero”.

El siguiente gráfico corresponde a las frecuencias relativas de la variable planteada en el Ejemplo 2.





Gráfico escalonado (frecuencias acumuladas)

Para representar las frecuencias acumuladas tanto crecientes como decrecientes se utiliza un gráfico escalonado.


**4.2.2.2 Datos agrupados en intervalos****Histograma y polígono de frecuencias (frecuencias absolutas, relativas y porcentuales)**

El **histograma** consiste en una serie de rectángulos que se construyen dibujando para cada intervalo un rectángulo cuya área sea proporcional a la frecuencia absoluta de dicho intervalo. Si los intervalos son de amplitud constante, las alturas de los rectángulos serán iguales a las frecuencias de cada uno. Pero si las amplitudes de los intervalos son diferentes, las alturas de los rectángulos deben “corregirse” de modo que visualmente no se distorsione la información que brinda el histograma. Así, por ejemplo, si un intervalo tiene una amplitud que es el triple de la de los demás, la altura del correspondiente rectángulo en el histograma deberá ser la tercera parte de la frecuencia de dicho intervalo.

La construcción e interpretación de histogramas que tienen intervalos de diferente amplitud debe realizarse de manera cuidadosa ya que puede conducir a conclusiones inválidas.

El **polígono de frecuencias** es una sucesión de segmentos que unen puntos cuyas coordenadas son la marca de clase de cada intervalo y su correspondiente frecuencia absoluta, relativa o porcentual. El polígono de frecuencias comienza y finaliza en la marca de clase anterior y posterior al primero y último intervalo, respectivamente, con frecuencia cero.


Para los datos del Ejemplo 3 (antigüedad de los 2000 empleados) el histograma y polígono de frecuencias resultan:



Ojiva (frecuencias acumuladas)

Las ojivas se utilizan para representar las frecuencias acumuladas. En el de las abscisas (eje X) se señalan los límites de los intervalos y en el eje de las ordenadas (eje Y) las frecuencias acumuladas que les corresponden.

Para el ejemplo anterior las ojivas correspondientes a las frecuencias absolutas (creciente y decreciente) se muestran a continuación:



Hemos efectuado una descripción de los gráficos más tradicionales utilizados en estadística descriptiva. Es necesario aclarar que existen variaciones de los mismos, aunque conceptualmente se basan en los aquí explicados.

Con posterioridad al estudio de los indicadores de posición se presentará una opción más de presentación gráfica de los datos: el box-plot o diagrama de caja.

Tener especial cuidado con aquellos gráficos en los cuales algunos de los ejes no comienzan en 0, ya que pueden hacerse interpretaciones erróneas. Pueden encontrarse varios ejemplos de esta situación en el libro "¿Cómo mentir con estadísticas?" (Huff, 1965).

4.2.3 Gráficos para datos bivariados

Para representar datos cualitativos bivariados (o cuantitativos con pocos valores de variable) se pueden utilizar **gráficos de barras agrupadas** o **barras apiladas**. Se ejemplifican dichos gráficos para las variables Cargo y Edad del Ejemplo 4.

Gráfico de barras agrupadas para la variable edad según el cargo







Gráfico de barras agrupadas para la variable cargo según la edad**Gráfico de barras apiladas para la variable edad según el cargo**

Gráfico de barras apiladas para la variable cargo según la edad

Si las dos variables que se consideran en un estudio bivariado son cuantitativas pueden graficarse mediante un **diagrama de dispersión**. Las dos variables cuantitativas se representan en un sistema de ejes cartesianos. El diagrama consiste en una nube de puntos donde cada uno de ellos representa a un dato y tiene por coordenadas los valores que toman ambas variables para cada observación.


Ejemplo 5

Supongamos que se desea estudiar conjuntamente la relación entre la antigüedad en el cargo y la cantidad de ventas diarias que concreta cada uno de los 20 empleados de un comercio. Los datos en bruto son los siguientes:

Nº Empleado	Antigüedad	Número de ventas diarias
1	10	30
2	9	34
3	11	33
4	20	55
5	19	50
6	15	44
7	9	35
8	6	28
9	2	20
10	9	30

Nº Empleado	Antigüedad	Número de ventas diarias
11	12	40
12	15	47
13	15	42
14	7	29
15	10	32
16	18	51
17	16	45
18	11	37
19	8	30
20	6	25

El diagrama de dispersión correspondiente a este conjunto de datos se presenta a continuación.



De la observación de esta representación gráfica es posible hacerse una idea del tipo de relación existente entre las variables. Aparentemente los empleados de mayor antigüedad realizan mayor número de ventas diarias. Pero para reforzar estas ideas preliminares es necesario acompañar los gráficos con otro tipo de herramienta estadística que se estudiarán en los próximos apartados.



¿Qué aspecto tendría el diagrama de dispersión correspondiente a los siguientes pares de variables?

- 1- el ingreso per cápita y la tasa de mortalidad al año de vida en distintos países de América.
- 2- Inversión en publicidad y ventas en distintas empresas.

Todos los gráficos deben ser autocontenidos, esto es, deben tener toda la información que se necesita para entenderlos: título, referencias, fuente...

5 Indicadores

Los datos están ahí, seguramente conteniendo mucha de la información que nos es de interés. Sin embargo, la mayoría de las veces esta información no está tan visible y accesible y es por eso que se requieren de diferentes técnicas estadísticas para descubrirla.

Las tablas de frecuencia nos ayudan a organizar la información, los gráficos a “mirarle la cara” a los datos, y también existen indicadores que permiten, por un lado, resumir el conjunto de datos en un único valor de variable y, por otro, dar cuenta de la variabilidad del conjunto de datos. Los primeros se denominan indicadores de tendencia central (y de posición) y los segundos indicadores de dispersión.

5.1 Indicadores de tendencia central y posición

Dada cualquier serie de datos particular, por lo general es posible seleccionar algún valor o promedio típico para describir toda la serie de datos. Este valor descriptivo típico es una medición de tendencia central o de ubicación.

Los indicadores de tendencia central sintetizan en un único valor de variable el comportamiento global del fenómeno estudiado.

Entre los más importantes se encuentran la media, la mediana y la moda. Los indicadores de posición localizan la posición de algún caso típico (o atípico) en relación con otros casos. Se incluyen: mediana, cuartiles, deciles, percentiles, etc.

Si bien en la mayoría de los textos se nombran indistintamente, o bajo el nombre de “indicadores de posición” se incluyen a los de “tendencia central”, es importante conocer la sutil diferencia que existe entre ellos.

5.1.1 Media aritmética

La **media aritmética** (también conocido como **promedio**) se simboliza con la letra griega μ (mu). Es el indicador de tendencia central más conocido.

Se lo calcula como la suma de los valores de todas las observaciones dividida por la cantidad total de observaciones. Simbólicamente

$$\mu = \frac{\sum_{i=1}^N x_i}{N}$$

donde

x_i representa el i-ésimo valor de la variable X

N representa el total de datos

Ejemplo 6

Supongamos que los siguientes datos corresponden a los sueldos diarios de seis gerentes de una empresa:


\$850 \$600 \$940 \$880 \$740 \$920

La media aritmética de estos valores se calcula como sigue:

$$\mu = \frac{850+600+940+880+740+920}{6} = \frac{4660}{6} = \$821,66$$

La interpretación de este valor es que en promedio cada gerente gana \$821,66 diarios. Cabe señalar que ninguno tiene exactamente este valor de sueldo.

Si representamos los datos:



Se puede observar que hay 4 observaciones mayores y dos menores que la media aritmética. La misma actúa como centro de gravedad o punto de equilibrio de la distribución de los datos, las observaciones mayores equilibran a las menores.

Para la distribución del Ejemplo 2 el cálculo de la media aritmética es:

$$\mu = \frac{\begin{array}{ccccccc} 20 & 21 & 30 & 21 & 15 & 9 & 4 \\ \hline 2+2+\dots+2 & 3+3+\dots+3 & 4+4+\dots+4 & 5+5+\dots+5 & 6+6+\dots+6 & 7+7+\dots+7 & 8+8+\dots+8 \end{array}}{120} = 4,275$$

O, lo que es lo mismo:

$$\mu = \frac{2 \cdot 20 + 3 \cdot 21 + 4 \cdot 30 + 5 \cdot 21 + 6 \cdot 15 + 7 \cdot 9 + 8 \cdot 4}{120} = 4,275 \text{ piezas defectuosas}$$

Entonces si tenemos los datos agrupados en forma simple podemos expresar simbólicamente:

$$\mu = \frac{\sum x_i \cdot f_i}{\sum f_i}$$

Si se desea calcular la media aritmética para datos agrupados en intervalos de clase, las observaciones correspondientes a cada intervalo se hacen coincidir con la marca de clase del mismo. Así, al calcular la media aritmética para el Ejemplo 3 tendremos:

$$\mu = \frac{\sum x_{ic} \cdot f_i}{\sum f_i} = \frac{2,5 \cdot 300 + 7,5 \cdot 200 + 12,5 \cdot 300 + 17,5 \cdot 500 + 22,5 \cdot 200 + 27,5 \cdot 250 + 32,5 \cdot 250}{2000} = 17,125 \text{ años de antig.}$$



Si se cuenta con los datos agrupados en forma simple y con los datos agrupados en intervalos de clase, ¿cuál de los posibles cálculos para la media aritmética resultaría más exacto?

Puntualicemos algunas características de la media aritmética:

- Como consecuencia de su definición es claro que la media aritmética sólo puede ser calculada para variables cuantitativas.
- Debe notarse que el valor de la media aritmética de una distribución debe estar comprendido entre el mínimo y el máximo valor que toma la variable, aunque no necesariamente es un valor que asume la misma.
- Para su cálculo se utilizan todos los valores que toma la variable. Esto trae dos consecuencias. Por un lado, el valor de la media aritmética refleja el comportamiento de toda la distribución, pero por otro, se ve afectada por valores extremos. Esto último puede llevar a decisiones inconvenientes. Supongamos que se está estudiando el nivel de ingresos de las familias de un cierto vecindario a fin de definir el mercado objetivo de un comercio que se instalará. Luego de relevar los datos se encuentra que el ingreso promedio por familia es de \$10654,86 y se toman decisiones empresariales considerando los objetos que consumen familias cuyos ingresos están “cercaños” a los \$10000. Si entre los datos relevados había algún valor extremadamente grande, es posible que en realidad ninguna de las familias tenga ingresos cercanos a ese valor y, por lo tanto, los objetos puestos a la venta finalmente no sean consumidos por la población.

5.1.2 Moda o modo

La **moda** o **modo** (m_o) es el valor de variable que más se repite. Si los datos están organizados en una tabla de distribución de frecuencias, la moda es el valor de variable que presenta la mayor frecuencia absoluta. Este indicador de posición puede calcularse tanto para variables cualitativas como cuantitativas.

La moda del Ejemplo 1 es $m_o = \text{secundario}$

La moda del Ejemplo 2 es $m_o = 4$ piezas defectuosas

En el Ejemplo 3 hay un **intervalo modal** que es $[15;20)$

Si en una distribución hay dos valores de variable que presentan la misma y máxima frecuencia absoluta se dice que la distribución tiene dos modas o que es **bimodal**. Si hubiera tres o más valores de variable con igual y máxima frecuencia se dice que no hay moda en el conjunto de datos.



¿Es correcto decir que el nivel de estudios alcanzado por la mayoría de los empleados es secundario?
¿o que la mayoría de los días se produjeron 4 piezas defectuosas?

5.1.3 Mediana, Cuartiles, Deciles y Percentiles

En circunstancias como la planteada anteriormente es más apropiado utilizar la **mediana** (m_e). Ésta es el valor de variable menor o igual que el 50% de los datos y mayor o igual que el otro 50%. También puede definirse como el valor de variable que divide al conjunto de datos en dos partes iguales, de tal manera que el 50% de los datos tienen un

valor menor o menor o igual que la mediana y el otro 50% tienen un valor mayor o igual o mayor que la mediana.

Un ejemplo simple surge de considerar las alturas en un grupo de alumnos. Si se les pide que se ordenen de forma ascendente según la altura y se le pregunta al alumno que está en el medio cuanto mide, ése será el valor de la mediana. Si el alumno del medio mide 1,68 mts. entonces la mitad de los alumnos mide 1,68 mts. o menos y la otra mitad de los alumnos mide 1,68 mts. o más.

El cálculo de la mediana implica entonces: ordenar los datos, identificar la posición del “medio” y obtener el valor de dicha observación. Resulta entonces fundamental distinguir entre **posición** de la mediana y **valor** de la mediana.

Dado un conjunto de datos recopilados en forma bruta, primero hay que disponerlos en un arreglo ordenado en forma ascendente o descendente. Si el número de observaciones es impar la mediana será el valor de variable que quede en el centro de dicho arreglo. Es decir que si se cuenta con N datos la mediana se ubica en la posición $(N+1)/2$. En caso de tener un número par de observaciones la mediana es el promedio entre los dos valores centrales de la distribución ordenada.

En algunos textos, puede encontrarse que la mediana se ubica en la posición $N/2$. Puede usarse cualquiera de estas definiciones. En general, el cálculo y la interpretación de la mediana son aproximadas. En algunos casos significará que el 50% de los datos tienen un valor menor que la mediana, y en otros que el 50% de los datos tienen un valor menor o igual que la mediana... y la interpretación a realizar dependerá del conjunto de datos en particular.

Consideremos nuevamente los datos del Ejemplo 6:

\$850 \$600 \$940 \$880 \$740 \$920

Como primer paso se deben ordenar:

\$600 \$740 **\$850** **\$880** \$920 \$940

Al ser $N = 6$, se tiene que la posición de la mediana será $(6+1)/2 = 3,5$. Es decir la mediana se encuentra entre la tercera y la cuarta observación. Por lo tanto:

$$m_e = (\$850 + \$880) / 2 = \$865$$

Este valor se interpreta diciendo que la mitad de los gerentes gana \$865 diarios o menos y la otra mitad gana \$865 diarios o más.

Si a la distribución se le agregara un valor más, por ejemplo \$950, los datos ordenados serían:

\$600 \$740 \$850 **\$880** \$920 \$940 \$950

y la mediana será el valor que ocupe la posición $(7+1)/2 = 4$, es decir la $m_e = \$880$.

Consideremos ahora el Ejemplo 2. Como los datos son 120 sería claramente engorroso disponerlos como lo hicimos precedentemente. Sin embargo, la disposición de la tabla de distribución de frecuencias acumulada será de gran ayuda.

X: "Cantidad de piezas defectuosas producidas"	$f_a \uparrow$
2 o menos (≤ 2)	20
3 o menos (≤ 3)	41
4 o menos (≤ 4)	71
5 o menos (≤ 5)	92
6 o menos (≤ 6)	107
7 o menos (≤ 7)	116
8 o menos (≤ 8)	120

Al ser 120 observaciones la posición de la mediana será $(120 + 1) / 2 = 60,50$. Lo cual indica que la mediana debe ser el promedio entre las observaciones ubicadas en los lugares 60 y 61 de la distribución. De la observación de la tabla anterior se ve que ambos valores son 4. Por lo tanto:

$$m_e = 4 \text{ piezas defectuosas}$$

Como se puede observar, para calcular la mediana de una distribución sólo es necesario ordenar las observaciones y luego identificar el valor central. Por esta razón es que este indicador de posición puede hallarse también para variables cualitativas ordinales. Por ejemplo, para la variable "Máximo nivel de estudios completado" del Ejemplo 1 la mediana es:

$$m_e = \text{secundario}$$



¿Cómo se interpretan los valores de las medianas calculadas anteriormente? (realizar dichas interpretaciones en términos de los problemas)


Si los datos están agrupados en intervalos de clase y se utiliza la distribución de frecuencias acumuladas, se puede identificar sin dificultad el intervalo al que pertenece la mediana de la distribución. Pero para hallar el valor exacto de la misma es necesario utilizar un proceso de interpolación que no es parte del presente curso. Sin embargo, vamos a precisar un método gráfico que permite aproximar el valor de la mediana cuando se cuenta con datos en intervalos de clase.

Consideremos la ojiva del Ejemplo 3

Identifiquemos el punto cuya ordenada coincide con el 50% de las observaciones. En este caso dicho valor es 1000. La abscisa de dicho punto es aproximadamente 16,5. Por la propia construcción de este gráfico dicho valor significa que hay 1000 empleados que tienen una antigüedad de 16,5 años o menos, los cuales representan el 50% de la población. Quiere decir que la mediana de esta distribución es $m_e = 16,50$ años. Se puede apreciar que el punto considerado es la intersección de ambas ojivas.

A partir de la misma definición de mediana surgen otros indicadores de posición que se basan en la misma forma de cálculo, pero dividen a la distribución de datos en distintas fracciones. Los **cuartiles**, por ejemplo, dividen a la distribución en cuartos. El primer cuartil (Q1) es un valor de variable mayor o igual que el 25% de los datos y menor o igual que el 75%, el segundo cuartil coincide con la mediana y el tercer cuartil (Q3) es mayor o igual que el 75% y menor o igual que el 25% de los datos.

Análogamente, los **deciles** dividen la distribución en décimos y los **percentiles** en centésimos.



Encontrar gráficamente e interpretar el 4º decil del
Ejemplo 4. ¿Con quién coincide el percentil 75?



Determinar las posiciones de los cuartiles,
deciles, percentiles...
¿Puede generalizar el modo de calcular dichas posiciones?

5.1.4 Selección del indicador de posición adecuado


La selección de la media, la mediana o la moda depende del contexto en el que se está aplicando. Con frecuencia se habla del salario promedio (media aritmética) del conjunto de trabajadores de una empresa y éste puede ser de utilidad para tomar decisiones de planificación presupuestaria. Pero si la división de control de calidad de una fábrica de tornillos está analizando la longitud de los mismos, puede ser de mayor utilidad la mediana ya que indica el problema causado por la presencia de alguna observación extrema. Por último, para los diseñadores de autos es más útil saber que la familia modal tiene dos hijos que contar con la información que afirma que el número promedio de hijos por familia es 1,7.

5.1.5 Box-plot o diagrama de caja

Se presenta a continuación otro tipo de gráfico utilizado para realizar análisis exploratorio de variables cualitativas. Se incluye en esta sección debido a que para su confección son necesarios los cuartiles y la mediana.



El **box-plot** o diagrama de caja está compuesto por un rectángulo, la "caja", y dos brazos, los "bigotes". Sobre un segmento que comienza en el valor mínimo de la variable y termina en el valor máximo, se dibuja un rectángulo cuyos lados perpendiculares al segmento se ubican a la altura del primer y tercer cuartil. Finalmente se traza una tercera línea, también perpendicular al segmento, que coincide con el valor de la mediana.

Para el Ejemplo 2 el gráfico es:



Este gráfico permite analizar la simetría o asimetría de los datos, reconocer sectores de menor o mayor concentración de datos, así como contrastar el comportamiento de una misma variable en dos escenarios.

Supongamos, por ejemplo, que se desea comparar la variable Cantidad de piezas defectuosas producidas en dos turnos distintos de la fábrica. Los diagramas que se obtienen son los siguientes:



¿Qué conclusiones se pueden sacar respecto de la cantidad de piezas defectuosas producidas en un turno o en el otro?

5.2 Indicadores de dispersión

Como se dijo anteriormente las medidas de tendencia central tienen como objetivo sintetizar los datos de una distribución en un valor de variable. Pero un análisis en el cual sólo se calculan estos indicadores resulta incompleto. Debe ser acompañado por la descripción del grado de dispersión o variabilidad existente que presenta el grupo de datos. Los indicadores encargados de dar cuenta sobre dicha variabilidad que exhiben los valores de las observaciones se denominan **medidas (indicadores) de dispersión**.

Cabe destacar que si los datos no presentaran variabilidad, no habría necesidad de la gran mayoría de los análisis de la estadística descriptiva... incluso ya no tendría sentido el concepto de "variable"...

5.2.1 Recorrido o rango

El **recorrido** o **rango** indica la amplitud del intervalo al que pertenecen la totalidad de las observaciones. Se calcula entonces como la diferencia entre la observación mayor y la menor. Para el Ejemplo 2:

$$\text{Recorrido} = x_{\max} - x_{\min} = 8 - 2 = 6 \text{ piezas}$$

La utilidad de esta medida de dispersión es limitada ya que sólo toma en cuenta los valores más alto y más bajo de una distribución y no considera ninguna otra observación del conjunto de datos. Como consecuencia de esto, ignora la naturaleza de la variación entre todas las demás observaciones y se ve muy influido por valores extremos.

5.2.2 Recorrido intercuartílico

El **recorrido intercuartílico (RI)** se calcula como la diferencia entre el Cuartil 3 y el Cuartil 1. Indica la longitud del intervalo al que pertenecen el 50% central de las observaciones. En el Ejemplo 2:

$$\text{RI} = Q_3 - Q_1 = 5 - 3 = 2 \text{ piezas}$$

Si bien este indicador elimina el problema de verse influido por valores extremos, no refleja el comportamiento de la totalidad de los valores observados.

5.2.3 Varianza

Los indicadores más utilizados de la dispersión son aquéllos que tratan con la desviación promedio con respecto a la media aritmética.

Siguiendo esta lógica un procedimiento adecuado sería calcular las distancias entre cada valor de variable y la correspondiente media aritmética para luego promediar dichas distancias. El inconveniente que se presenta es que, debido a la propia definición de la media aritmética, la suma de todas esas distancias es nula. Con lo cual el promedio daría siempre cero y no revelaría información alguna. Para resolver este problema se elevan al

cuadrado dichas distancias antes de promediarlas. Así la fórmula para el cálculo de la varianza será:

$$\sigma^2 = \frac{\sum (x_i - \mu)^2}{N} \quad \text{o también} \quad \sigma^2 = \frac{\sum (x_i - \mu)^2 \cdot f_i}{\sum f_i}$$

Para el Ejemplo 2 la varianza será:

$$\sigma^2 = \frac{(2-4,275)^2 \cdot 20 + (3-4,275)^2 \cdot 21 + \dots + (8-4,275)^2 \cdot 4}{120} = 2,649 \text{ unidades?}$$



¿Por qué la suma de las distancias de cada dato a la media es igual a 0? ¿En qué unidades queda expresada la varianza?

5.2.4 Desviación estándar

La **desviación estándar** (σ) es simplemente la raíz cuadrada de la varianza. Esto resuelve el problema de las unidades que se observó anteriormente.

$$\sigma = \sqrt{\frac{\sum (x_i - \mu)^2}{N}} \quad \text{o también} \quad \sigma = \sqrt{\frac{\sum (x_i - \mu)^2 \cdot f_i}{\sum f_i}}$$

El desvío estándar para la variable definida en el Ejemplo 2 es $\sigma = \sqrt{2,649} = 1,6276$ piezas. Lo cual significa que, en promedio, las observaciones se alejan de la media aritmética aproximadamente 1,63 piezas.

5.2.5 Coeficiente de variación

Al contrario de las cuatro medidas previas, el **coeficiente de variación (CV)** es una medida relativa ya que se expresa como porcentaje en lugar de hacerlo en las unidades de los datos. Esta característica resulta de particular utilidad. En primer lugar, es indispensable si se desea comparar la variabilidad de dos o más conjuntos de datos que puedan estar expresados en distintas unidades de medida. Por ejemplo, si se desea comparar la variabilidad de los pesos y las alturas de un conjunto de animales se contaría con un desvío estándar expresado en kg. y otro en metros. En segundo lugar, el valor del CV de una distribución es un indicador que puede utilizarse para establecer si la media aritmética es representativa del conjunto de datos.

La fórmula para su cálculo es:

$$CV = \left| \frac{\sigma}{\mu} \right| \cdot 100\%$$

Para el Ejemplo 2 se tiene:

$$CV = \frac{1,63}{4,275} \cdot 100\% = 34,31\%$$

Cabe señalar que un valor “chico” de CV indica que el desvío es pequeño en comparación con la media y, por lo tanto, la media aritmética es representativa del conjunto

de datos. En caso contrario, si el CV es “grande” indica mucha dispersión de los datos y la media aritmética no resulta un buen indicador para representarlos.



¿Cuáles son los posibles valores que pueden tomar los indicadores de dispersión? ¿Y los de tendencia central? ¿Cómo se interpreta un indicador de dispersión igual a 0? ¿Y uno de tendencia central igual a 0? ¿Cómo se interpreta el valor obtenido?

Un análisis de datos que sólo presenta indicadores de tendencia central y que no hace ninguna referencia a la variabilidad del conjunto de datos es un análisis incompleto y deficiente.

6 Medidas de asociación

Ante la necesidad de analizar la asociación entre dos variables (particularmente cuantitativas) los gráficos (por ejemplo, el diagrama de dispersión) suelen dar una idea aproximada de la misma. Resulta imprescindible calcular alguna medida estadística que brinde precisión sobre dicha asociación.

6.1 Covarianza

Consideremos nuevamente el Ejemplo 5. En él se presentaban dos variables cuantitativas:

X: “Antigüedad en la empresa de cada empleado”

Y: “Número de ventas diarias que realiza el empleado”

A cada una de estas variables, en su carácter de cuantitativa se le puede calcular la media aritmética y el desvío estándar. Se obtiene:


$$\mu_x = 11,40 \text{ años}$$

$$\sigma_x = 4,66 \text{ años}$$

$$\mu_y = 36,85 \text{ ventas diarias}$$

$$\sigma_y = 9,26 \text{ ventas diarias}$$

Si ahora sobre el diagrama de dispersión trazamos las rectas de las ecuaciones $x = \mu_x$ e $y = \mu_y$, tendremos que cada punto se ubica a una determinada distancia de cada una de dichas rectas que se pueden calcular como indica la figura:



Al restar a cada valor de variable su media aritmética se tendrán algunos valores positivos y otros negativos.



¿En qué sector del gráfico se ubican los puntos

1. en los que las distancias verticales son positivas?

2. en los que las distancias verticales son negativas?

3. en los que las distancias horizontales son positivas?

4. en los que las distancias horizontales son negativas?

Se define la covarianza entre dos variables X e Y de la siguiente forma:

$$\text{cov}(x, y) = \frac{\sum (x_i - \mu_x) \cdot (y_i - \mu_y)}{N}$$

El signo de cada término del numerador será positivo si ambos factores tienen igual signo y será negativo si ambos factores tienen distintos signos. Como consecuencia de esto un valor positivo de la covarianza indica mayoría de puntos ubicados en los cuadrantes I y III, indicando esto una configuración ascendente de la nube y, por lo tanto, una relación lineal directa entre las variables. Análogamente, un valor negativo de la covarianza indica mayoría de puntos ubicados en los cuadrantes II y IV, indicando esto una configuración descendente de la nube y, por lo tanto, una relación lineal inversa entre las variables.

La covarianza toma valores comprendidos entre $-\infty$ y $+\infty$. Por otra parte, queda expresado en el producto de las unidades de las variables consideradas para su cálculo. Estas dos características limitan la interpretación de la covarianza ya que, si bien su signo nos da información acerca del tipo de asociación entre las variables (directa o inversa) no es posible determinar la fortaleza relativa de dicha relación.

En el Ejemplo 5 el cálculo de la covarianza está dado por:

$$cov(x, y) = \frac{(10-11,4).(30-36,85)+(9-11,4).(34-36,85)+\dots+(6-11,4).(25-36,85)}{20} = 42,16 \text{ años x ventas diarias}$$



¿44,38 años x ventas diarias es mucho o poco?

6.2 Correlación

Para solucionar las limitaciones mencionadas anteriormente se define el coeficiente de correlación de la siguiente manera:

$$\rho = \frac{cov(x, y)}{\sigma_x \cdot \sigma_y}$$

De esta definición se puede observar que este coeficiente no tiene unidades. Además, puede demostrarse que toma valores comprendidos entre -1 y 1.

Si las variables tienen una asociación lineal directa, $\rho > 0$. Si tienen una asociación lineal directa perfecta, ρ será igual a 1.

Si las variables tienen una asociación lineal inversa, $\rho < 0$. Si tienen una asociación lineal inversa perfecta, ρ será igual a -1.

Si las variables no tienen asociación lineal, $\rho = 0$.

Para el Ejemplo 5 el cálculo correspondiente es:

$$\rho = \frac{cov(x, y)}{\sigma_x \cdot \sigma_y} = \frac{42,16}{4,66 \cdot 9,26} = 0,9770$$


El cual indica una relación lineal directa y fuerte entre las variables.

La fuerza de la relación entre dos variables cuantitativas viene dada por cuán lejos se encuentre el coeficiente de correlación respecto de cero tanto en sentido positivo como negativo: a mayor lejanía de 0 (o mayor cercanía a 1 o -1) mayor fuerza de la relación.

Entonces a la hora de evaluar la fuerza de la correlación en términos relativos (es decir, respecto al ρ de otro par de variables) simplemente tenemos que comparar el valor absoluto de sus ρ , y el que resulte mayor será el de mayor fuerza. En cambio, a la hora de evaluar la fuerza de una relación lineal en términos absolutos se genera el problema de delimitar cuándo una relación es fuerte y cuándo es débil. Por ejemplo, si ρ es de 0,01 seguramente nos inclinaríamos a decir que las variables tienen una relación muy débil o que directamente no tienen asociación lineal, mientras que si es de 0,99 podríamos decir con seguridad que la relación es muy fuerte. El problema se genera en situaciones intermedias, por ejemplo, cuando ρ nos da -0,27, 0,74 o -0,58. Allí la interpretación depende de los valores usuales o esperados para esas correlaciones en el campo de conocimiento y en el tema en el que estemos trabajando. En esta asignatura puntual y para poder resolver los

ejercicios usando las mismas pautas, se muestra a continuación una serie de umbrales de referencia arbitrarios que definen la fuerza de la relación, pero que de ninguna manera constituyen una escala fija y estable que puede ser aplicada a cualquier análisis de correlación:

$$\begin{aligned} 0 < |\rho| < 0,6 & \Rightarrow \text{Correlación lineal débil} \\ 0,6 \leq |\rho| < 0,8 & \Rightarrow \text{Correlación lineal moderada} \\ 0,8 \leq |\rho| < 1 & \Rightarrow \text{Correlación lineal fuerte} \end{aligned}$$



¿Podría indicar valores razonables del coeficiente de correlación para cada par de variables indicadas?

1. Ingreso per cápita y Tasa de mortalidad al año de vida en distintos países de América
2. Inversión en publicidad y Ventas en distintas empresas
3. Eficiencia laboral y Tiempo transcurrido desde el inicio de la jornada

En esta sección sólo se presentan las técnicas estadísticas para “medir” asociación lineal entre variables cuantitativas. Existen técnicas para dar cuenta de la asociación entre variables cualitativas y entre una variable cualitativa y una cuantitativa...

7 Conclusiones

Cuando se deciden relevar datos, es porque seguramente se tiene un “problema concreto” que se quiere resolver. Ante esta necesidad, pueden establecerse las siguientes etapas:

- 1) Formulación o definición del problema (con objetivos claros y concretos)
- 2) Diseño de la investigación (población, muestra, individuos, variables)
- 3) Recolección de datos
- 4) Organización y descripción de los datos (análisis univariado, bivariado, multivariado, ...)
- 5) Decisión o inferencia final

Se necesita entonces tener conocimiento del problema en sí mismo, y de algunas cuestiones estadísticas que aseguren que las herramientas utilizadas para la obtención de información son las adecuadas (el uso de herramientas inadecuadas, seguramente conducirá a conclusiones que no son pertinentes).

En este primer cuadernillo, se brindan las herramientas básicas para poder realizar un análisis descriptivo de los datos. Es importante tener claro que el análisis de datos más sofisticado no puede sustituir una pobre definición del problema, un mal diseño del estudio, un muestreo inadecuado, una deficiente medición, un mal trabajo de campo o un procesamiento de datos mal elaborado.

8 Bibliografía

Anderson, David R. y Sweeney, Dennis J. (2008). *“Estadística para administración y economía”*. Cengage Learning Editores. 1056 páginas.

Berenson, M. L.; Levine, D. M. (1998). *“Estadística para administración y economía”*. Ed. Interamericana, 6ª Edición.

Levin, Richard T. y Rubin, David S. (2004). *“Estadística para administración y economía”*. Pearson Educación, México. Séptima edición. 952 páginas.

Levine, David. M.; Krehbiel, Timothy. C.; Berenson, Mark. L. (2006). *“Estadística para administración”*. México: Pearson Educación, 4ª Edición. 619 páginas.

Bibliografía Adicional

Baranger, Denis. *“Construcción y análisis de datos: Introducción al uso de técnicas cuantitativas en la investigación social”*. Editorial Universitaria. Universidad Nacional de Misiones. 1992.

Blalock, Hubert. (1986). *“Estadística Social”*. Fondo de Cultura Económica. México.

Chou, Ya Lun. (1977). *“Análisis Estadístico”* - Ed. Interamericana.

Huff, Darrell. (1965). *“¿Cómo mentir con Estadísticas?”*. Gráficas Sagitario. Barcelona. 158 páginas.

Mendenhall, William; Beaver, Robert J. y Beaver, Barbara M. (2009). *“Introduction to probability and statistics”*. Cengage Learning, 13 edición. 746 páginas.

Material de cátedra

Estadística (Carreras: Contador Público Nacional, Licenciado en Administración y Licenciado en Economía Empresarial)

Técnicas cuantitativas para el Management y los Negocios (Carrera Contador Público Nacional)

Técnicas cuantitativas para el Management y los Negocios I (Carrera Licenciado en Administración)

Módulo II: Estadística Inferencial (parte 1)

Autores

María del Carmen Romero

Silvina Etcheverría

**Facultad de Ciencias Económicas
Universidad Nacional del Centro de la Provincia de
Buenos Aires**



Tabla de contenido

1	Estadística Inferencial: Introducción.....	3
2	Estadística Inferencial: Conceptos básicos	3
2.1	Espacio muestral y eventos	3
2.2	Operaciones entre eventos	5
2.3	Asignación de probabilidades.....	6
2.3.1	Probabilidad clásica.....	6
2.3.2	Probabilidad empírica	7
2.3.3	Probabilidad subjetiva	7
2.4	Reglas para el cálculo de probabilidades	8
2.4.1	Probabilidad simple.....	8
2.4.2	Probabilidad de la intersección de eventos	9
2.4.3	Probabilidad condicional.....	9
2.4.4	Regla de la multiplicación.....	10
2.4.5	Eventos independientes	11
2.4.6	Probabilidad de la unión de eventos.....	11
2.5	Teorema de la probabilidad total y teorema de Bayes	12
2.5.1	Teorema de la probabilidad total.....	12
2.5.2	Teorema de Bayes	13
3	Variable aleatoria	15
3.1	Definición.....	15
3.2	Variable aleatoria discreta.....	16
3.2.1	Función masa de probabilidad.....	16
3.2.2	Función de distribución	17
3.2.3	Esperanza matemática y varianza	18
3.2.4	Propiedades de la esperanza matemática y varianza	19
3.3	Variable aleatoria continua	19
3.3.1	Función densidad de probabilidad.....	19
3.3.2	Función de distribución acumulada.....	21
3.3.3	Esperanza y varianza	21
3.4	Distribuciones conjuntas de probabilidades	22
3.4.1	Distribuciones marginales y condicionales	23
3.4.2	Variables aleatorias independientes	24
3.4.3	Covarianza.....	24
4	Distribuciones de probabilidad.....	25
4.1	Distribuciones discretas.....	25

4.1.1	Binomial	25
4.1.2	Hipergeométrica	27
4.1.3	Poisson	28
4.2	Distribuciones continuas	29
4.2.1	Distribución Uniforme	29
4.2.2	Distribución Normal.....	30
4.2.3	Aproximación normal de la distribución binomial de probabilidades	36

1 Estadística Inferencial: Introducción

Ya se ha señalado en el módulo anterior que el objetivo final del análisis de datos es el de extraer conclusiones de tipo general (parámetros de una población) a partir de cálculos efectuados sobre un conjunto particular de datos (estadísticos de una muestra). Para que este proceso de generalización sea válido la muestra obtenida debe ser representativa de la población, para lo cual existen distintos métodos de llevar a cabo el muestreo.

El término **muestreo** se refiere al proceso seguido para extraer una muestra de una población. El muestreo puede ser de dos tipos: **probabilístico** y **no probabilístico**. En el muestreo probabilístico se conoce (o puede calcularse) la probabilidad asociada a cada una de las muestras que es posible extraer, cada elemento poblacional posee una probabilidad conocida (o calculable) de pertenecer a la muestra. En el muestreo no probabilístico se desconoce o no se tiene en cuenta la probabilidad asociada a cada muestra. Sólo el muestreo probabilístico permite obtener una idea sobre el grado de representatividad de la muestra seleccionada.

Se hace necesario entonces estudiar el concepto de **probabilidad** como así también las propiedades y reglas que rigen su cálculo.

2 Estadística Inferencial: Conceptos básicos

2.1 Espacio muestral y eventos

La Teoría de Probabilidades estudia los llamados **experimentos aleatorios**. Ejemplos clásicos de estos experimentos son los juegos de azar.

Un experimento aleatorio tiene las siguientes características:

- 1- Se lo puede repetir bajo las mismas condiciones tantas veces como se desee.
- 2- No se puede predecir con exactitud el resultado de dicho experimento, pero se puede decir cuáles son los posibles resultados del mismo.

Ejemplo 1:

- a) tirar un dado (y registrar el número en la cara de arriba)
- b) tirar una moneda (y registrar la “cara” que se ve)
- c) lanzar una moneda tres veces (y registrar la sucesión de caras y cecas obtenidas)

Observación: en los experimentos no aleatorios o deterministas se puede predecir con exactitud el resultado del experimento, es decir, las condiciones en las que se verifica un experimento determinan el resultado del mismo. Por ejemplo, si se arroja hacia arriba un objeto con cierta velocidad inicial, es posible calcular la altura máxima que alcanzará así como el tiempo que tardará en volver a caer.

El conjunto de todos los resultados posibles de un experimento aleatorio es el **espacio muestral** y lo denominaremos con la letra S.

Ejemplo 2:

- a) Si el experimento aleatorio es tirar un dado y registrar el número en la cara de arriba, entonces el espacio muestral $S = \{1, 2, 3, 4, 5, 6\}$
- b) Si el experimento aleatorio es tirar una moneda, entonces $S = \{\text{cara, ceca}\}$
- c) Si el experimento aleatorio es lanzar una moneda tres veces y registrar la sucesión de caras y cecas obtenidas, entonces $S = \{\text{CCC, CCX, CXC, CXX, XCC, XCX, XXC, XXX}\}$, (donde C representa cara y X ceca).
- d) Si el experimento aleatorio es tirar un dado las veces necesarias hasta que sale un 6 por primera vez, y contar el número de tiros realizados, entonces $S = \{1, 2, 3, 4, \dots\} = \mathbb{N}$, donde $\mathbb{N}$ es el conjunto de los números naturales.
- e) Si el experimento aleatorio es medir el tiempo de vida de una lamparita eléctrica, entonces $S = \{t \in \mathbb{R}, t \geq 0\}$ donde $\mathbb{R}$ es el conjunto de los números reales.

Aunque en un primer momento estas situaciones parezcan alejadas de la economía, la contabilidad o la administración, existen numerosas situaciones en dichas áreas altamente vinculadas a condiciones de aleatoriedad. Como ejemplo podemos pensar en el contexto en el que se gestionan las empresas aseguradoras, los mecanismos que se ponen en marcha durante una auditoría o los escenarios a los que se enfrentan los inversores que deciden comprar o vender acciones.



Piense en otros experimentos aleatorios vinculados al área de la administración, la contabilidad y la economía

Se llama **evento o suceso** a todo subconjunto del espacio muestral.


Ejemplo 3:

- a) En el experimento dado en el Ejemplo 2 a), un posible evento es A: “que salga número par”. Los elementos de S (espacio muestral) que “cumplen” con este evento son $A = \{2, 4, 6\}$ (A está incluido en S). Si se considerara el evento B: “que salga un número menor o igual que 3”, $B = \{1, 2, 3\}$.
- b) En el experimento dado en el Ejemplo 2 c), un evento de S sería C: “que salgan por lo menos dos caras”.



Enumere los elementos de este caso

c) En el experimento dado en el Ejemplo 2 e), un evento de S sería D : “tiempo de duración de la lamparita mayor a 1200 horas”.



¿Podría enumerar los elementos en este caso?

Observaciones:

1- Un caso particular de eventos, son aquellos que no tienen elementos, esto es, que ningún elemento del espacio muestral cumple con lo especificado en el evento (el resultado es el conjunto vacío $\emptyset$). Un evento cuyo resultados en el conjunto vacío cumple con la definición presentada de evento “subconjunto del espacio muestral” (pues el conjunto $\emptyset$ está incluido en todo conjunto, en particular $\emptyset$ está incluido en S). Es el evento que nunca ocurre.

Por ejemplo, el evento “que salgan 5 caras” produce un conjunto vacío (no es posible que suceda ya que en el experimento aleatorio de lanzar una moneda 4 veces no pueden obtenerse 5 caras). Sin embargo, es un evento aplicable a este experimento aleatorio.

Otro caso particular está dado por aquellos eventos cuyos elementos son todos los elementos del espacio muestral (también cumplen con la condición de ser subconjuntos del espacio muestral). Estos eventos siempre ocurren. Un ejemplo para el experimento aleatorio de lanzar 4 monedas sería “que salgan 0 o más caras”.

2- En el ejemplo 3 a) anterior, si al tirar el dado sale el número 2, entonces podemos decir que A ocurrió pues 2 es un elemento de A . Pero también B ocurrió pues 2 es un elemento de B . En cambio si al tirar el dado sale el número 4, entonces el evento A ocurrió pero B no ocurrió, pues 4 no es un elemento de B .

Es infinita la cantidad de eventos que pueden definirse para un determinado experimento aleatorio. Cada evento definido siempre debe ir acompañado por el experimento aleatorio ya que los elementos que cumplan con ese evento depende del experimento ... Los elementos del evento “que salgan 2 caras o más” no son los mismos si se tiene que el experimentos aleatorio de tirar una moneda 2 veces o de tirar una moneda 4 veces.

2.2 Operaciones entre eventos

Las operaciones habituales entre conjuntos se pueden aplicar a los eventos, dando como resultado nuevos eventos. Específicamente:

Si A y B son eventos, entonces $A \cup B$ (se lee A unión B) es otro evento, $A \cup B$ ocurre sí y solo sí ocurre A u ocurre B .

Si A y B son eventos, entonces $A \cap B$ (se lee A intersección B) es otro evento, $A \cap B$ ocurre sí y solo sí ocurre A y ocurre B .

Si A es un evento, $\bar{A}$ es el evento complementario es decir A ocurre sí y solo sí $\bar{A}$ no ocurre.

Ejemplo 4

Si se consideran los eventos A y B del ejemplo 3 a (Evento A: “número par”, Evento B: “número menor o igual que 3”), se tiene:

$$A \cup B = \{1, 2, 3, 4, 6\} \quad (\text{“número par” o “número menor o igual que 3”})$$

$$A \cap B = \{2\} \quad (\text{“número par” y “número menor o igual que 3”})$$

$$\bar{A} = \{1, 3, 5\} \quad (\text{“número no par”})$$

2.3 Asignación de probabilidades

La probabilidad es un valor que expresa la medida de la posibilidad de que ocurra un evento. Asume valores comprendidos entre 0 y 1. Un evento cuya probabilidad de ocurrencia es cero es un evento que no va a ocurrir, si la probabilidad es 1 ocurrirá con total certeza.



¿Cuál es el valor de probabilidad que describe una situación de máxima incertidumbre?

Para asignar la probabilidad a un evento existen varias escuelas de pensamiento.

2.3.1 Probabilidad clásica

La definición clásica adjudicada al matemático Pierre Simón Laplace establece que la probabilidad de un evento es la razón entre el número de casos favorables y el número total de casos posibles, siempre que los casos sean equiprobables. En símbolos:

$$p(A) = \frac{\text{número de casos favorables}}{\text{número total de casos posibles}}$$

Ejemplo 5

Supongamos que se tira un dado equilibrado, esto es que todas las caras tienen igual probabilidad de caer hacia abajo. Consideremos los eventos D: “que salga un 5”, E: “que salga un número mayor o igual a 5” y F: “que salga un número par”. Para calcular las probabilidades de cada evento se debe contar la cantidad de resultados pertenecientes a cada evento y utilizar la definición dada. Así:

$$p(D) = \frac{1}{6} \quad \begin{array}{l} \longrightarrow \\ \longrightarrow \end{array} \quad \begin{array}{l} \text{¿Por qué?} \\ \text{¿Por qué?} \end{array}$$

$$p(E) = \frac{2}{6} = 0,3$$

$$p(F) = \frac{3}{6} = 0,5$$

En cambio si el experimento aleatorio se realiza con un dado que tiene alguna deformación o su centro de gravedad está desplazado, nada garantiza que la probabilidad de obtener un 5 sea $1/6$. En ese caso es necesario recurrir a otra forma de asignación de probabilidades.

2.3.2 Probabilidad empírica

Esta teoría afirma que un procedimiento válido para calcular la probabilidad de eventos asociados a un experimento aleatorio es el de repetir el experimento un número grande de veces y registrar la frecuencia relativa con que el evento ocurre. Imaginemos una serie de N repeticiones y sea N_A el número de ellas en que el suceso A ocurrió. La fracción N_A/N es la frecuencia relativa de A en N repeticiones. Es un hecho experimentalmente observable (si la experiencia se realiza en iguales condiciones) que a medida que N crece, la frecuencia relativa de un evento A tiende a estabilizarse alrededor de un valor límite. Ese valor límite es la probabilidad de A . Simbólicamente:

$$p(A) = \lim_{N \rightarrow \infty} \frac{N_A}{N}$$

Ejemplo 6

Se tiene una moneda y no se sabe si está “equilibrada” (esto quiere decir que al arrojarla la probabilidad de obtener una cara es igual a la probabilidad de sacar ceca). Si se desea conocer la probabilidad de obtener una cara, se debe repetir el experimento aleatorio un número grande de veces, observar la cantidad de caras que se obtienen y dividirlo por el total de repeticiones que se efectuaron. Dicho valor es la probabilidad que se desea conocer.



La probabilidad de que sufra alguna rotura el transporte en el que se está trasladando es 0,50, ya que sólo se tienen dos casos posibles: se rompe o no se rompe. ¿Esto es correcto?
¿Esta probabilidad se debe calcular según la probabilidad clásica o la empírica?

2.3.3 Probabilidad subjetiva

En esta teoría la asignación de probabilidades se basa en conocimientos del contexto en que se está trabajando a partir de evidencias disponibles, en opiniones personales, o en experiencias previas. La probabilidad asignada a un evento puede ser distinta para distintas personas que la asignen. Un ejemplo es el pronóstico del tiempo. Se realizan predicciones de cómo serán las condiciones climáticas para un período de tiempo, basadas en conocimientos científicos, pero no por repetir un experimento aleatorio un número grande de veces ni por identificar la cantidad de casos favorables sobre la cantidad de casos posibles.

La asignación de probabilidad subjetiva se da generalmente cuando los eventos ocurren un número reducido de veces.

Sin embargo, en las organizaciones a pesar de que es común tomar decisiones en base a la probabilidad subjetiva la mayoría de las veces esta se respalda con datos estadísticos.



En un estudio de mercado se afirma que la probabilidad de que una persona compre un nuevo producto es 0,7, ¿cómo puede haber sido calculada?

Si en una auditoría se sabe que la probabilidad de que una carpeta sea auditada es 1/5, ¿Cómo se habrá calculado?

Es infinita la cantidad de eventos que pueden definirse para un determinado experimento aleatorio. Cada evento definido siempre debe ir acompañado por el experimento aleatorio ya que los elementos que cumplan con ese evento depende del experimento ... Los elementos del evento “que salgan 2 caras o más” no son los mismos si se tiene que el experimentos aleatorio de tirar una moneda 2 veces o de tirar una moneda 4 veces.

2.4 Reglas para el cálculo de probabilidades

2.4.1 Probabilidad simple

La probabilidad simple es la que se asigna a un evento descrito por una sola característica. Se basa en las teorías explicadas anteriormente.

Ejemplo 7

a) En el experimento aleatorio de extraer una carta al azar de un mazo de 40 cartas españolas, la probabilidad del evento A: “la carta extraída es un as”:

$$p(A) = \frac{\text{cantidad de ases}}{\text{cantidad de cartas}} = \frac{4}{40} = 0,10$$

Para el mismo experimento aleatorio, dado evento B: “la carta extraída es de espadas”


$$p(B) = \frac{\text{cantidad de espadas}}{\text{cantidad de cartas}} = \frac{10}{40} = 0,25$$

Finalmente, para el evento C: “la carta extraída es una figura (rey, caballo o sota)”

$$p(C) = \frac{\text{cantidad de figuras}}{\text{cantidad de cartas}} = \frac{12}{40} = 0,30$$

b) En el experimento aleatorio de extraer al azar una tuerca de un lote de 50 piezas que contiene 4 defectuosas, la probabilidad del evento D: “la pieza extraída no es defectuosa”:

$$p(D) = \frac{\text{cantidad de tuercas no defectuosas}}{\text{cantidad de tuercas}} = \frac{46}{50} = 0,92$$



¿Cuánto vale $p(\bar{A})$, $p(\bar{B})$, $p(\bar{C})$ y $p(\bar{D})$?

2.4.2 Probabilidad de la intersección de eventos

Si en el experimento aleatorio del ejemplo 7a) se quiere establecer la probabilidad de que la carta extraída sea un as de espadas, se está pidiendo que se cumplan simultáneamente dos eventos: el evento A y el evento B. En símbolos se quiere calcular $P(A \cap B)$. Utilizando la definición clásica se tiene:

$$p(A \cap B) = \frac{n^{\circ} \text{ casos favorables}}{n^{\circ} \text{ casos posibles}} = \frac{\text{cantidad de ases de espada}}{\text{cantidad de cartas}} = \frac{1}{40}$$

Veremos más adelante otra forma de realizar este cálculo que será de gran ayuda cuando no se cuenta con toda la información necesaria para el cálculo directo.

2.4.3 Probabilidad condicional

En ocasiones la probabilidad de ocurrencia de un evento puede estar condicionada por la ocurrencia de otro.

Ejemplo 8

Supongamos el experimento aleatorio de extraer al azar sin reemplazo dos bolillas de una urna que contiene 7 bolillas rojas y 3 blancas. Asumimos que las bolillas de un mismo color son distinguibles.

Consideramos los eventos A: “la primera bolilla extraída es blanca”, y B: “la segunda bolilla extraída es blanca”.

Es claro que $P(A) = 3/10$. Pero si queremos calcular $P(B)$ no es tan directo. Podemos calcular la probabilidad de B sabiendo que A ocurrió: es igual a $2/9$, ya que, si A ocurrió, entonces en la urna quedaron 9 bolillas de las cuales 2 son blancas. La probabilidad anterior la anotamos $P(B/A)$ y se lee: probabilidad condicional de B habiendo ocurrido A. Es decir, $P(B/A) = 2/9$.

Notar que podemos interpretar lo anterior de la siguiente forma: el espacio muestral original S se ha reducido al evento A, es decir se toma a A como nuevo espacio muestral para calcular la probabilidad de B.

También podemos interpretar que la probabilidad condicional de B dado A debería ser la proporción de veces que ocurre $A \cap B$ con respecto al número de veces que ocurre A. Esta idea motiva la siguiente definición:

Sean A y B dos eventos de un espacio muestral S. La probabilidad condicional de B dado A se define como:

$$P(B/A) = \frac{P(A \cap B)}{P(A)} \quad \text{si } P(A) \neq 0$$

Análogamente:

$$P(A/B) = \frac{P(A \cap B)}{P(B)} \quad \text{si } P(B) \neq 0$$

En algunos casos se puede calcular $P(A/B)$ directamente reduciendo el espacio muestral. En otros será necesario aplicar la definición anterior.

Ejemplo 9

a) Se tira un dado normal dos veces. Sean los eventos A: “la suma de los números obtenidos es 6” y B: “el primer número es igual a 4”. Entonces para calcular $P(A/B)$ mediante la definición de probabilidad condicional

$$P(A/B) = \frac{P(A \cap B)}{P(B)} = \frac{\frac{1}{36}}{\frac{6}{36}} = \frac{1}{6}$$

También podemos calcularlo en forma directa, reduciendo el espacio muestral, de todos los pares que forman el evento B, observamos cuáles cumplen con lo requerido por A, es decir de todos los pares de B, solo uno tiene la propiedad de que sus componentes suman 6, por lo tanto, $P(A/B) = 1/6$.

b) En cierta ciudad, 40% de la población tiene cabellos castaños, 25% tiene ojos castaños y 15% tiene cabellos y ojos castaños. Se escoge una persona al azar. Sean los eventos A: “la persona elegida al azar tiene ojos castaños”, B: “la persona elegida al azar tiene cabellos castaños”. Si se selecciona un individuo que tiene cabellos castaños, ¿cuál es la probabilidad de que también tenga ojos castaños?

$$P(A/B) = \frac{P(A \cap B)}{P(B)} = \frac{0,15}{0,40} = 0,375$$

2.4.4 Regla de la multiplicación

Como se dijo anteriormente, si A y B son dos eventos entonces $P(A/B) = \frac{P(A \cap B)}{P(B)}$ si $P(B) \neq 0$

Por lo tanto

$$P(A \cap B) = P(B) \cdot P(A/B)$$

Análogamente de $P(B/A) = \frac{P(A \cap B)}{P(A)}$ si $P(A) \neq 0$

Se deduce que

$$P(A \cap B) = P(A) \cdot P(B/A)$$

Ejemplo 10

Consideremos el experimento de extraer dos bolillas al azar sin reemplazo de una urna que contiene 3 bolillas blancas y 7 rojas. Si A: “la primera bolilla extraída es blanca”, y B: “la segunda bolilla extraída es blanca”, entonces:

$$P(A \cap B) = P(A) \cdot P(B/A) = \frac{3}{10} \cdot \frac{2}{9}$$

La regla de la multiplicación se puede ampliar para más de dos eventos. De modo que si A_1, A_2, A_3 son tres eventos entonces


$$P(A_1 \cap A_2 \cap A_3) = p(A_1) \cdot p(A_2/A_1) \cdot p(A_3/A_1 \cap A_2)$$

Ejemplo 11

Una clase tiene 12 varones y 4 mujeres. Si se eligen 3 estudiantes de la clase al azar, ¿cuál es la probabilidad de que sean todos varones?

Anotamos A_i : “el i -ésimo estudiante elegido es un varón” $i = 1, 2, 3$. Entonces la probabilidad pedida es:

$$P(A_1 \cap A_2 \cap A_3) = P(A_1) \cdot P(A_2/A_1) \cdot P(A_3/A_1 \cap A_2) = \frac{12}{16} \cdot \frac{11}{15} \cdot \frac{10}{14}$$



¿Cuál es la probabilidad de que el primero sea varón y las otras dos mujeres?

2.4.5 Eventos independientes

Dos eventos son **independientes** si la probabilidad de ocurrencia de uno no se ve modificada por la ocurrencia del otro.

Ejemplo 12

Supongamos la situación ya analizada de extraer dos bolillas al azar sin reemplazo de una urna que contiene 3 bolillas blancas y 7 rojas. Si A: “la primera bolilla extraída es blanca”, y B: “la segunda bolilla extraída es blanca” cabe preguntarse si A y B son independientes. Para ello hagamos algunos cálculos.

La probabilidad de que ocurra B habiendo ocurrido A es $P(B/A) = \frac{2}{9}$ (¿por qué?) y la probabilidad de que ocurra B no habiendo ocurrido A es $P(B/\bar{A}) = \frac{3}{9}$ (¿por qué?). Se puede ver que la probabilidad de que ocurra B **depende** de si el evento A ocurre o no. Por lo tanto, A y B no son independientes. Del análisis anterior se desprende lo siguiente.

Si A y B son eventos **independientes** se cumple que $P(B/A) = P(B/\bar{A}) = P(B)$

Notar que por la regla de la multiplicación:

Si A y B son eventos **independientes** se cumple que $P(A \cap B) = P(A) \cdot P(B)$



¿Qué modificación se debería hacer en el experimento aleatorio de extraer dos bolillas mencionado en el ejemplo para que los eventos A y B sean independientes?

2.4.6 Probabilidad de la unión de eventos

Si en el mismo experimento aleatorio del ejemplo 7a) se quiere establecer la probabilidad de que la carta extraída sea un as o una figura, simbólicamente la probabilidad buscada es $p(A \cup C)$. Para dicho cálculo podemos recurrir a la definición clásica:

$$p(A \cup C) = \frac{n^\circ \text{ casos favorables}}{n^\circ \text{ casos posibles}} = \frac{\text{cantidad de ases} + \text{cantidad de figuras}}{\text{cantidad de cartas}} = \frac{4 + 12}{40}$$

Comparando con los resultados obtenidos en el ejemplo a del apartado 2.4.1 se observa que el cálculo precedente coincide con la suma de las probabilidades individuales de los eventos simples A y C. Es decir:

$$p(A \cup C) = p(A) + p(C)$$

Esto se debe a que los eventos A y C no tienen elementos en común, su intersección es un conjunto vacío. En símbolos $A \cap C = \emptyset$. Cuando esto ocurre se dice que los eventos A y B son **mutuamente excluyentes o disjuntos**.

¿Qué ocurrirá si los eventos no son excluyentes? Es decir, si ambos sucesos tienen elementos en común, ¿cómo se calcula la probabilidad de la unión?

Se quiere calcular la probabilidad de que la carta extraída sea un as o una carta de espadas. Simbólicamente es $p(A \cup B)$.

$$p(A \cup B) = \frac{n^{\circ} \text{ casos favorables}}{n^{\circ} \text{ casos posibles}}$$

$$p(A \cup B) = \frac{\text{cantidad de ases} + \text{cantidad de espadas} - \text{cantidad de ases de espadas}}{\text{cantidad de cartas}}$$

Debemos observar que al sumar los casos favorables cada caso debe contarse una sola vez. Si sumamos la cantidad de ases más la cantidad de espadas estamos sumando dos veces al as de espadas. Es por eso que luego se lo resta.

Se deduce entonces que:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Como puede apreciarse que el caso de eventos disjuntos es un caso particular de éste último para eventos mutuamente excluyentes en los cuales $P(A \cap B) = 0$.

2.5 Teorema de la probabilidad total y teorema de Bayes


2.5.1 Teorema de la probabilidad total

Sean n eventos mutuamente excluyentes $A_1, A_2, \dots, A_n$, que constituyen una partición de un espacio muestral S, es decir que su unión es igual al espacio muestral:

$$S = A_1 \cup A_2 \cup \dots \cup A_n$$

donde $A_i \cap A_j = \emptyset$ siendo $i \neq j$

Supongamos un evento arbitrario B que puede ocurrir simultáneamente con cualquiera de los A_i . Se desea calcular la probabilidad de que ocurra el evento B. Un gráfico va a ayudar a comprender la situación.



Podemos escribir el evento B como:

$$B = S \cap B$$

Reemplazando a S por la unión de los A_i se tiene:

$$B = (A_1 \cup A_2 \cup \dots \cup A_n) \cap B$$

y distribuyendo

$$B = (A_1 \cap B) \cup (A_2 \cap B) \cup \dots \cup (A_n \cap B)$$

Por lo tanto

$$P(B) = [(A_1 \cap B) \cup (A_2 \cap B) \cup \dots \cup (A_n \cap B)]$$

Y como los A_i son mutuamente excluyentes

$$P(B) = P(A_1 \cap B) + P(A_2 \cap B) + \dots + P(A_n \cap B)$$

Utilizando la regla de la multiplicación

$$P(B) = P(A_1) \cdot P(B/A_1) + P(A_2) \cdot P(B/A_2) + \dots + P(A_n) \cdot P(B/A_n)$$

Por lo tanto

$$P(B) = P(A_1) \cdot P(B/A_1) + P(A_2) \cdot P(B/A_2) + \dots + P(A_n) \cdot P(B/A_n)$$

Esta expresión se conoce como **regla o teorema de la probabilidad total**.

2.5.2 Teorema de Bayes

En el estudio de la probabilidad condicional se vio que revisar las probabilidades cuando se obtiene más información es parte importante del análisis de probabilidades. Por lo general, se suele iniciar el análisis con una estimación de **probabilidad inicial** o **probabilidad previa** de los eventos que interesan. Después, de fuentes como una muestra, una información especial o una prueba del producto, se obtiene más información sobre estos eventos. Dada esta nueva información, se modifican o revisan los valores de probabilidad mediante el cálculo de probabilidades revisadas a las que se les conoce

como **probabilidades posteriores**. El **teorema de Bayes** es un medio para calcular estas probabilidades. Veremos a través de un ejemplo el cálculo que propone el mencionado teorema.

Ejemplo 13

Supongamos que se tienen dos clases de dados anormales. En la mitad de ellos un as se presenta 40% de las veces que se arroja el dado. En la otra mitad un as se presenta el 70% de las veces. A la primera clase de dados la llamaremos tipo 1, y a la segunda tipo 2. Se selecciona un dado al azar y se lo lanza una vez. Si el resultado es un as, ¿cuál es la probabilidad de que sea un dado del tipo 1? Sabiendo que se tiene igual cantidad de cada tipo de dado, se puede contestar erróneamente que dicha probabilidad es 0,5. Pero es posible hacer una mejor estimación incorporando toda la información de la que se dispone.

Si llamamos A_1 al evento “El dado seleccionado es de tipo 1”, A_2 “El dado seleccionado es de tipo 2” y B al evento “El número obtenido es un as”. La probabilidad que se quiere calcular es una probabilidad condicional,

$$p(A_1/B) = \frac{p(A_1 \cap B)}{p(B)} = \frac{p(A_1) \cdot p(B/A_1)}{p(B)}$$

Siendo $P(B) = P(A_1) \cdot P(B/A_1) + P(A_2) \cdot P(B/A_2)$ que es la expresión para el cálculo de la probabilidad total estudiado anteriormente.

En el ejemplo:

$$\left. \begin{array}{l} p(A_1) = 0,5 \\ p(A_2) = 0,5 \\ p(B/A_1) = 0,4 \\ p(B/A_2) = 0,6 \end{array} \right\} \text{¿Por qué?}$$

Entonces la probabilidad de que el dado seleccionado sea del tipo 1 sabiendo que al arrojarlo se obtuvo un as es:

$$P(\text{tipo 1/salió as}) = \frac{0,5 \cdot 0,4}{0,5 \cdot 0,4 + 0,5 \cdot 0,6} = 0,364$$

Notemos que antes de lanzar el dado la probabilidad de que fuera del tipo 1 era 0,5 (probabilidad a priori). Sin embargo, después de lanzar el dado se ha podido revisar la estimación anterior, siendo ahora 0,364 (probabilidad revisada o a posteriori).

3 Variable aleatoria

3.1 Definición

Formulamos la siguiente definición: sea S el espacio muestral asociado a un experimento aleatorio. Una variable aleatoria (v.a.) es una función que asigna a cada elemento de S un número real.

Es importante destacar, que para un mismo experimento aleatorio (y espacio muestral) puede definirse una gran cantidad (infinita) de variables aleatorias. Por ejemplo, para el experimento aleatorio de tirar una moneda 3 veces y registrar la secuencia de caras y cecas obtenidas, puede definirse, por ejemplo, la variable aleatoria “cantidad de caras” (que tomaría los valores 0, 1, 2 y 3), “cantidad de cecas”, “cantidad de cambios en la secuencia” (si se tiene, por ejemplo, CSCC, se registran dos cambios, uno de C a S y otro de S a CC).

Notación: se anota a una variable aleatoria con letras mayúsculas, por ejemplo: $X, Y, Z, W, \dots$

Entonces, si X es una variable aleatoria de S en R la notamos como sigue:

$$X: S \rightarrow R \text{ tal que } X(s) = x$$

donde S representa el espacio muestral, s un elemento de dicho espacio;

X una variable aleatoria y x un valor particular de esa variable.



¿Qué diferencia una variable aleatoria de una variable que no es aleatoria?

Ejemplo 14

En el experimento aleatorio de tirar una moneda tres veces podemos considerar la v.a. $X: S \rightarrow R$ definida por X : “Cantidad de caras”. Entonces:

$$X(CCC) = 3$$

$$X(CCX) = X(CXC) = X(XCC) = 2$$

$$X(CXX) = X(XCX) = X(XXC) = 1$$

$$X(XXX) = 0$$

(No confundir la X que representa a la variable aleatoria “Cantidad de caras”, con la que representa la ceca de la moneda).



¿Qué otras variables aleatorias podría definir asociadas al mismo experimento aleatorio? ¿Y asociadas al experimento de arrojar un dado dos veces?

3.2 Variable aleatoria discreta

Si una variable aleatoria puede tomar solamente un número finito de valores o un número infinito numerable de valores se la llama discreta. Así por ejemplo son variables aleatorias discretas la suma de los números obtenidos al tirar un dado dos veces, la cantidad de tornillos defectuosos fabricados por una determinada maquinaria, la cantidad de enfermos que responden satisfactoriamente a un tratamiento médico, etc.

También puede decirse que una variable discreta está asociada con un proceso de conteo, mientras que una continua con un proceso de medición.

3.2.1 Función masa de probabilidad

Cada valor que asume una variable aleatoria se corresponde con un evento asociado a un experimento aleatorio, razón por la cual es pertinente calcular la probabilidad de ocurrencia.

Ejemplo 15

Consideremos la variable aleatoria X: “número de caras que se observan al tirar una moneda tres veces” las probabilidades correspondientes a los valores de X son:

$P(X=0) = 1/8$ (se refiere a la probabilidad de obtener 0 caras al tirar una moneda 3 veces)

$P(X=1) = 3/8$

$P(X=2) = 3/8$

$P(X=3) = 1/8$


En general si X es una v.a. discreta, a cada valor x_i que asume dicha variable se le asigna un valor $p(x_i) = p(X = x_i)$. Esta asignación debe cumplir las siguientes condiciones:

a) $p(x_i) \geq 0$, para todo i

b) $\sum p(x_i) = 1$

La función $p(x)$ así definida se llama **función de probabilidad** o **función masa de probabilidad**.

Una función masa de probabilidad puede presentarse en forma de tabla y de gráfico. En el Ejemplo 15 la tabla y el gráfico correspondientes son:





¿Qué diferencia existe entre una tabla de distribución de probabilidades y una tabla de distribución de frecuencias?

3.2.2 Función de distribución

Muchas veces, en relación con variables aleatorias, interesa saber cuál es la probabilidad de que la v.a adopte valores menores o iguales que un determinado x_i . La respuesta a esta pregunta la ofrece la **función de distribución** o **función acumulada de probabilidades**.

Definición: Si X es una variable aleatoria y x un número real, la función de distribución de X , representada por $F(x)$, da la probabilidad de que X adopte valores menores o iguales que x . En símbolos:

$$F(x) = p(X \leq x) = \sum_{x_i \leq x} p(x_i)$$

La $F(x)$ debe cumplir las siguientes condiciones para ser una función de distribución de probabilidad:

- a) $0 \leq F(x) \leq 1$
- b) Si $a < b$ entonces $F(a) \leq F(b)$
- c) $F(\infty) = p(x \leq \infty) = 1$ y $F(-\infty) = p(x \leq -\infty) = 0$
- d) $p(a < X \leq b) = F(b) - F(a)$



La última condición específica que $p(a < X \leq b) = F(b) - F(a)$.
¿Cómo podría calcularse la $p(a \leq X \leq b)$?

Ejemplo 16

Volviendo al Ejemplo 15 de la variable aleatoria “cantidad de caras que se obtienen al tirar una moneda tres veces” la tabla presentada anteriormente se completa como sigue:

X	0	1	2	3
p(x)	1/8	3/8	3/8	1/8
F(x)	1/8	4/8	7/8	1

El valor, por ejemplo, 7/8 se corresponde con $F(2)$. Significa que la probabilidad de obtener 2 caras o menos al tirar una moneda 3 veces es 7/8.



¿La probabilidad acumulada al mayor valor de X siempre tiene que ser igual a 1? ¿Por qué?

3.2.3 Esperanza matemática y varianza

Se llama esperanza de la variable aleatoria discreta X , al número:

$$E(X) = \sum_{i=1}^n x_i p(x_i)$$

o

$$E(X) = x_1 p_1 + x_2 p_2 + \dots + x_n p_n$$

donde n representa la cantidad total de valores posibles de X ,

$x_1, x_2, \dots, x_n$ los valores de la variable aleatoria y

$p_1, p_2, \dots, p_n$ las probabilidades respectivas.

La esperanza de una variable aleatoria X también se representa por μ , y se llama media de la distribución. Por tanto, “esperanza de la variable aleatoria” y “media de la distribución” son expresiones equivalentes.

Para la variable aleatoria del Ejemplo 15 “número de caras al arrojar una moneda 3 veces” la esperanza matemática será:

$$\mu = E(X) = 0 \cdot 1/8 + 1 \cdot 3/8 + 2 \cdot 3/8 + 3 \cdot 1/8 = 1,5 \text{ caras.}$$

Es muy importante que se interprete correctamente este valor. Se dice que el número esperado de caras al arrojar una moneda tres veces es 1,5. Esto no significa, obviamente, que dicho valor se obtenga al realizar el experimento aleatorio una vez. El correcto significado es que, si el experimento aleatorio se repite un *número grande de veces*, se espera que en promedio se obtengan 1,5 caras por vez.

Sin embargo, el valor esperado no informa nada acerca del grado de dispersión de los resultados de una variable aleatoria. Es necesario entonces acompañar dicho valor con un indicador de variabilidad. El más importante es la **varianza**:

$$V(X) = \sum_{i=1}^n (x_i - E(X))^2 p(x_i)$$

o

$$V(X) = (x_1 - E(X))^2 \cdot p_1 + (x_2 - E(X))^2 \cdot p_2 + \dots + (x_n - E(X))^2 \cdot p_n$$

Para el cálculo práctico es más conveniente usar la siguiente expresión que es matemáticamente equivalente a la definición anterior (la demostración de esta equivalencia no se incluye en este material):

$$E(X^2) = \sum_{i=1}^n x_i^2 p(x_i)$$

o

$$V(X) = E(X^2) - (E(X))^2$$

donde $E[X^2] = x_1^2 \cdot p_1 + x_2^2 \cdot p_2 + \dots + x_n^2 \cdot p_n$

En el ejemplo anterior el cálculo de la varianza es:

$$V(X) = (0^2 \cdot 1/8 + 1^2 \cdot 3/8 + 2^2 \cdot 3/8 + 3^2 \cdot 1/8) - 1,5^2 = 3,57 - 2,25 = 1,31 \text{ caras}^2$$

Puesto que la varianza no queda expresada en las mismas unidades que la variable, se utiliza la raíz cuadrada de la varianza y a este número la llamamos desviación estándar.

$$\sigma = \sqrt{V(X)}$$

En nuestro ejemplo $\sigma = \sqrt{1,31} = 1,15$ caras.


El valor de la varianza o del desvío estándar se utiliza para complementar el de esperanza matemática cuando se trata de decidir en contextos de incertidumbre. Por ejemplo, si se debe decidir entre dos carteras de inversiones es claro que cualquier asesor recomendaría invertir en los contextos que presenten ganancias con mayor esperanza matemática. Pero si hubiera más de un contexto con igual (y máxima) esperanza, entonces será recomendable elegir el de menor varianza, ya que minimizará las fluctuaciones que podrán provocar momentos de mucha liquidez seguidos de momentos de escasez.

3.2.4 Propiedades de la esperanza matemática y varianza

Si X es una variable aleatoria cuya distribución de probabilidades es conocida, a menudo interesa estudiar otras variables aleatorias definidas en función de X y para ello son de suma utilidad algunas propiedades de la esperanza matemática y varianza:

- $E(aX) = a \cdot E(X)$
- $E(X + b) = E(X) + b$
- $V(aX) = a^2 \cdot V(X)$
- $V(X + b) = V(X)$

donde a y b son una constantes.



La $E(a) = a$ y la $V(a) = 0$ (siendo a una constante). ¿Por qué?

3.3 Variable aleatoria continua

Si la variable aleatoria puede tomar una cantidad infinita y no numerable de valores se la llama **continua**. Así, por ejemplo, son variables aleatorias continuas el tiempo que transcurre entre el ingreso de dos clientes a un local, el contenido de las botellas de gaseosas que son llenadas por una máquina, etc.


3.3.1 Función densidad de probabilidad

Como ahora los valores de una v.a. continua no son contables, no se puede hablar del i -ésimo valor de la v.a. X y por lo tanto $p(X_i = x_i)$ pierde su significado. Lo que se hace es sustituir la función $p(x)$ definida sólo para $x_1, x_2, \dots$ por una función $f(x)$ definida para todos los valores x del rango de X . Por lo tanto se da la siguiente definición de v.a. continua.

Se dice que X es una variable **aleatoria continua** si existe una función no negativa f , definida sobre todos los reales tal que para cualquier intervalo $(a;b)$ de números reales se cumple que:

$$p(a < X < b) = \int_a^b f(x)dx$$

O sea que la probabilidad de que X tome valores entre a y b se obtiene al integrar la función f sobre el intervalo $(a;b)$. En otras palabras, dicha probabilidad coincide con la medida del área debajo de la gráfica de $f(x)$ en el intervalo $(a;b)$.



A la función f la llamamos **función densidad de probabilidad**. Cabe destacar que un valor particular de f NO tiene interpretación en términos del cálculo de probabilidades. Sólo tienen sentido los valores de áreas debajo de la curva de la función densidad. De lo anterior se puede observar que esta función cumple dos condiciones:

- 1) $f(x) \geq 0$
- 2) $\int_{-\infty}^{+\infty} f(x)dx = 1$



¿La probabilidad de qué evento se está calculando en la segunda propiedad?

Observación:

Si se quiere calcular la probabilidad de que la variable aleatoria X tome exactamente el valor a se tiene:

$$p(a < X < a) = \int_a^a f(x)dx = 0$$

Es decir que la probabilidad en un punto es cero. Y por lo tanto

$$p(a \leq X \leq b) = p(a < X \leq b) = p(a \leq X < b) = p(a < X < b) = \int_a^b f(x)dx$$

Intuitivamente, puede concluirse que, si existe una infinita cantidad de valores que puede tomar la variable aleatoria... la probabilidad de que tome exactamente un valor sería igual a $1 / (\text{cantidad posible de valores})$. Este resultado tendería a 0 conforme aumente la cantidad de valores posibles.


3.3.2 Función de distribución acumulada

Sea X una v.a. continua. Se define la función de distribución acumulada de X como:

$$F(X) = p(X < x) = \int_{-\infty}^x f(t)dt$$

Además:

$$p(a < X < b) = \int_a^b f(x)dx = \int_{-\infty}^b f(x)dx - \int_{-\infty}^a f(x)dx = F(b) - F(a)$$



¿Cómo podría calcularse la $p(a \leq X \leq b)$?

Ejemplo 17

La demanda semanal de gas propano (en miles de litros) de una distribuidora en particular es una variable aleatoria X con función densidad de probabilidad dada por:

$$f(X) = \begin{cases} 2 - \frac{2}{x^2} & \text{si } 1 < X < 2 \\ 0 & \text{en otro caso} \end{cases}$$

Se puede comprobar que la función dada es una función densidad:

a) $f(X) \geq 0$ si X está comprendida entre 1 y 2.

$$b) \int_{-\infty}^{\infty} f(x) dx = \int_{-\infty}^1 0 dx + \int_1^2 (2 - \frac{2}{x^2}) dx + \int_2^{\infty} 0 dx = 0 + (2x + \frac{2}{x}) \Big|_1^2 + 0 = 1$$

Para hallar la probabilidad de que en una determinada semana la demanda esté comprendida entre 1200 y 1500 litros se debe calcular:

$$P(1,2 < X < 1,5) = \int_{1,2}^{1,5} (2 - \frac{2}{x^2}) dx = (2x + \frac{2}{x}) \Big|_{1,2}^{1,5} = 0,266$$

3.3.3 Esperanza y varianza

Para una v.a. discreta la $E(X)$ se definió como la suma de los $x_i \cdot p_i$. Si X es una v.a. continua con función densidad de probabilidad $f(x)$, se define $E(X)$ sustituyendo la sumatoria por integración.

$$E(X) = \int_{-\infty}^{\infty} x \cdot f(x) dx$$

En el ejemplo anterior se tiene:

$$E(X) = \int_{-\infty}^{\infty} x \cdot f(x) dx = \int_{-\infty}^1 x \cdot 0 dx + \int_1^2 x \cdot (2 - \frac{2}{x^2}) dx + \int_2^{\infty} x \cdot 0 dx = [0 + x^2 - 2 \ln |x| + 0]_1^2 = 1,61 \text{ miles de litros}$$

Esto significa que en promedio se espera que la demanda de propano sea de 1610 litros por semana.

3.4 Distribuciones conjuntas de probabilidades

En muchos casos el resultado de un experimento aleatorio puede estar expresado por dos o más valores observados en forma simultánea. Por ejemplo: podemos medir los ingresos y los gastos de un grupo de familias elegidas al azar; o la altura y el peso de un grupo de alumnos; horas de estudio y calificación obtenida en un examen; o suma de puntos y puntaje del dado de mayor puntaje al arrojar dos dados.

Si se necesita conocer la probabilidad de eventos en los que intervengan ambas variables no es suficiente con el conocimiento individual de cada una. Para ello se necesita la **distribución conjunta (o bivariada) de probabilidad**.

Ejemplo 18

Consideremos el experimento aleatorio que consiste en lanzar dos dados. El espacio muestral de este experimento consiste en 36 posibles pares:

$$S = \{(1,1) ; (1,2) ; ; (6,6)\}$$

Consideremos las siguientes variables aleatorias:

X: suma de los puntajes de los dados

Y: puntaje del dado de mayor puntaje

La variable X puede tomar los valores 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, o 12; y la variable Y los valores: 1, 2, 3, 4, 5 o 6. Para hallar la distribución conjunta de probabilidades de X e Y, debemos responder preguntas como: ¿cuál es la probabilidad de que la suma de los dados sea 5 y el mayor de ellos muestre un 3?

Al contar con el espacio muestral, la respuesta puede obtenerse directamente contando los eventos individuales en los cuales $X = 5$ e $Y = 3$, suponiendo todos los casos equiprobables. Por lo tanto:

$$P(X=5 \cap Y=3) = 2/36 \text{ ya que solamente los pares } (2,3) \text{ y } (3,2) \text{ cumplen con esa condición.}$$

Preguntas similares deben formularse para todos los demás pares de valores de X e Y. Estos resultados pueden presentarse en una tabla como la que se muestra a continuación.

X \ Y	2	3	4	5	6	7	8	9	10	11	12
1	1/36	0	0	0	0	0	0	0	0	0	0
2	0	2/36	1/36	0	0	0	0	0	0	0	0
3	0	0	2/36	2/36	1/36	0	0	0	0	0	0
4	0	0	0	2/36	2/36	2/36	1/36	0	0	0	0
5	0	0	0	0	2/36	2/36	2/36	2/36	1/36	0	0
6	0	0	0	0	0	2/36	2/36	2/36	2/36	2/36	1/36

Observación: La expresión $p(X=5 \cap Y=3)$ se denotará en adelante como $p(5,3)$.

Lo que se realizó al confeccionar la tabla precedente es definir una **función conjunta de probabilidades o función conjunta de masa de probabilidades $p(X,Y)$** . Esta función debe cumplir con las siguientes condiciones:

$$1) p(x,y) \geq 0 \text{ para todo par } (x,y)$$

$$2) \sum_x \sum_y p(x,y) = 1$$

3.4.1 Distribuciones marginales y condicionales

Cuando se estudian dos variables aleatorias en forma conjunta, también se utilizan las denominadas *distribuciones de probabilidades marginales*. Éstas son las funciones masa de probabilidad para cada una de las variables X e Y por separado. Para el ejemplo de los dados:

X	2	3	4	5	6	7	8	9	10	11	12
p(X)	1/36	2/36	3/36	4/36	5/36	6/36	5/36	4/36	3/36	2/36	1/36

Y	1	2	3	4	5	6
g(Y)	1/36	3/36	5/36	7/36	9/36	11/36

(En este caso, se usó p para referir a la función masa de probabilidad de la variable aleatoria X y g a la función de la variable aleatoria Y. Es sólo una cuestión de notación, podrían haberse usado también p_x y p_y para identificar a cada una de estas funciones).

Ambas distribuciones marginales suelen escribirse en los márgenes de la tabla en la que se expresan las distribuciones conjuntas y, como puede observarse, coincide con la suma de las probabilidades conjuntas de cada fila y cada columna como se muestra a continuación.

X \ Y	2	3	4	5	6	7	8	9	10	11	12	g(Y)
1	1/36	0	0	0	0	0	0	0	0	0	0	1/36
2	0	2/36	1/36	0	0	0	0	0	0	0	0	3/36
3	0	0	2/36	2/36	1/36	0	0	0	0	0	0	5/36
4	0	0	0	2/36	2/36	2/36	1/36	0	0	0	0	7/36
5	0	0	0	0	2/36	2/36	2/36	2/36	1/36	0	0	9/36
6	0	0	0	0	0	2/36	2/36	2/36	2/36	2/36	1/36	11/36
p(X)	1/36	2/36	3/36	4/36	5/36	6/36	5/36	4/36	3/36	2/36	1/36	36/36

Otro tipo de distribución que puede derivarse de la distribución conjunta es la *distribución de probabilidades condicionales*. Esta noción es análoga al concepto de probabilidad condicional, que para dos eventos A y B es:

$$P(B/A) = \frac{P(A \cap B)}{P(A)} \quad \text{si } P(A) \neq 0$$

Por lo tanto podemos escribir en notación de distribuciones de probabilidad conjunta:

$$p(X=x/Y=y) = \frac{p(x,y)}{g(y)} \quad \text{si } g(y) \neq 0 \quad \text{y} \quad p(Y=y/X=x) = \frac{p(x,y)}{p(x)} \quad \text{si } p(x) \neq 0$$

Volviendo al ejemplo de arrojar 2 dados, calculemos la probabilidad de que los puntajes sumen 5 dado que el mayor de ellos muestra un 3:

$$p(X=5/Y=3) = \frac{p(5,3)}{g(3)} = \frac{2/36}{5/36} = 2/5$$



¿Cuál es la probabilidad de que el mayor puntaje sea 4 si la suma de puntos es 8?

3.4.2 Variables aleatorias independientes

Al trabajar con distribuciones conjuntas de probabilidades, la dependencia o independencia de las variables es muy importante.

Recordemos que según lo estudiado en la sección 2.4.6, dos eventos A y B son independientes si se cumple:

$$P(A/B) = P(A) \quad \text{o} \quad P(B/A) = P(B) \quad \text{o} \quad \text{también} \quad P(A \cap B) = P(A) \cdot P(B)$$

Análogamente se dice que dos variables aleatorias son independientes si se verifica:

$$p(x/y) = p(x) \quad \text{o} \quad p(y/x) = g(y) \quad \text{o} \quad \text{también} \quad p(x,y) = p(x) \cdot g(y) \quad \text{para todo } x \text{ e } y$$

En nuestro ejemplo claramente X e Y no son independientes. Para comprobarlo consideremos el caso

$$p(5,4) = 2/36 \text{ (por qué?)}$$

De las distribuciones marginales resulta

$$p(5) = 4/36 \quad \text{y} \quad g(4) = 7/36$$

$$\text{Por lo tanto } p(5) \cdot g(4) = 4/36 \cdot 7/36 = 7/324 \neq 2/36$$

3.4.3 Covarianza

Análogamente a lo estudiado en el módulo de estadística descriptiva, se define el concepto de covarianza, pero para variables aleatorias:

$$\text{cov}(X,Y) = \sum_x \sum_y (x - \mu_X) \cdot (y - \mu_Y) \cdot p(x,y) \quad \text{donde } \mu_X = E(X) \text{ y } \mu_Y = E(Y)$$

En ocasiones este cálculo es muy engorroso. Pero existe una expresión equivalente para el cálculo de la covarianza (cuya demostración no se incluye en el presente módulo):

$$\text{cov}(X,Y) = E(X \cdot Y) - E(X) \cdot E(Y) \quad \text{donde } E(X \cdot Y) = \sum_x \sum_y x \cdot y \cdot p(x,y)$$

La covarianza permite tener una idea de la relación o variación conjunta entre las dos variables. Puede ser negativa, positiva o nula y su interpretación es análoga a la de covarianza de variables observadas.

Volviendo al Ejemplo 18 realicemos el cálculo de la covarianza entre las variables ahí consideradas:

$$E(X) = 2 \cdot 1/36 + 3 \cdot 2/36 + \dots + 12 \cdot 1/36 = 7$$

$$E(Y) = 1 \cdot 1/36 + 2 \cdot 3/36 + \dots + 6 \cdot 11/36 = 4,47$$

$$E(X \cdot Y) = 2 \cdot 1 \cdot 1/36 + 3 \cdot 1 \cdot 0 + \dots + 6 \cdot 12 \cdot 1/36 = 34,22$$

$$\text{cov}(X,Y) = 34,22 - 7 \cdot 4,47 = 2,93$$

Este valor positivo de la covarianza indica hay una relación lineal directa entre las variables. Esto quiere decir que ante un aumento de una de ellas se espera un aumento de la otra.

4 Distribuciones de probabilidad

4.1 Distribuciones discretas

Se han desarrollado muchos tipos diferentes de modelos matemáticos para representar diversos fenómenos discretos que ocurren en las ciencias sociales y naturales, en la investigación médica y en los negocios. A continuación, estudiaremos algunos de los más relevantes y usados.

4.1.1 Binomial

Una distribución de probabilidad discreta de suma utilidad para las descripciones de muchos fenómenos, es la distribución binomial. Esta distribución posee cuatro propiedades esenciales:

- Cada observación se puede considerar como seleccionada de una población infinita sin reemplazo o de una población finita con reemplazo.
- Cada observación se puede clasificar en una de dos categorías colectivamente exhaustivas y mutuamente excluyentes: éxito o fracaso.
- La probabilidad de que una observación se clasifique como éxito, p , es constante de una observación a otra. Por lo tanto, la probabilidad de fracaso, $1 - p$ (llamada q), es constante en todas las observaciones.
- El resultado de cualquier observación (éxito o fracaso) es independiente del resultado de cualquier otra observación.

La variable aleatoria propia de la distribución binomial es “número de éxitos obtenidos en una muestra de n observaciones”. Se pueden encontrar numerosas aplicaciones de este modelo, desde los juegos de azar (¿cuál es la probabilidad de sacar 2 caras al arrojar tres veces una moneda?) hasta el control de calidad de productos (¿cuál es la probabilidad de que en una muestra de 15 piezas producidas por una máquina no haya ninguna defectuosa si se sabe que dicha maquinaria produce un 5% de piezas defectuosas?).



¿Se cumplen las cuatro propiedades del modelo binomial en los ejemplos mencionados? ¿Será necesario considerar ciertos supuestos? (reflexione sobre las condiciones en que se realiza cada experimento aleatorio, desgaste de la máquina, materias primas utilizadas, etc.)

Para comprender el cálculo de probabilidades asociadas a este modelo consideremos un ejemplo simple. Se realizan tres llamadas desde una empresa de venta telefónica. Se sabe que la probabilidad de que en una llamada se concrete una venta es 0,2. Nos preguntamos cuál es la probabilidad de que en una de esas tres llamadas se lleve a cabo una venta.

En principio se puede simplificar el problema calculando la probabilidad de que *se realice una venta en la primera llamada*. Si llamamos V_i al evento “que se realice una venta en la i -ésima llamada” tendremos:

$$p(V_1 \cap \overline{V}_2 \cap \overline{V}_3) = 0,2 \cdot 0,8^2 \quad \longrightarrow \quad \text{¿por qué?}$$

Pero este evento no es exactamente el que responde a la pregunta original. Se debe considerar que la venta puede realizarse en la segunda o tercera llamada. En ese caso la probabilidad se debe calcular así:

$$p(V_1 \cap \overline{V_2} \cap \overline{V_3}) + p(\overline{V_1} \cap V_2 \cap \overline{V_3}) + p(\overline{V_1} \cap \overline{V_2} \cap V_3) = 0,2 \cdot 0,8^2 + 0,8 \cdot 0,2 \cdot 0,8 + 0,8^2 \cdot 0,2$$

Si la probabilidad que se desea calcular es la de que se concreten 2 ventas al realizar 5 llamados el razonamiento es similar, con el incremento de dificultad propio del aumento de llamadas a considerar. Para evitar tener que “armar” el cálculo en cada ocasión (considerando todas las combinaciones posibles), es muy útil recurrir a una formulación genérica.

Sea X la variable aleatoria “número de éxitos al realizar n pruebas independientes con probabilidad de éxito p en cada una”, el siguiente modelo matemático permite encontrar la probabilidad de que dicha v.a tome un valor k :

$$p(X=k) = \frac{n!}{k!(n-k)!} \cdot p^k \cdot (1-p)^{n-k}$$

donde n = tamaño de la muestra

p = probabilidad de éxito

Observación: La expresión $\frac{n!}{k!(n-k)!}$ puede también notarse como $\binom{n}{k}$ o ${}_nC_k$ y representa el número combinatorio de n elementos tomados de a k . El cálculo puede realizarse directamente en las calculadoras ingresando solamente los valores de n y de k .

En el ejemplo presentado, n (número de pruebas) = 3, la variable aleatoria X es “cantidad de ventas realizadas” y p (probabilidad de éxito) = 0,2. La probabilidad de fracaso se calcula como $q = (1-p)$, en este caso, 0,8. Dado que la cantidad de pruebas es 3, los posibles valores de X son 0, 1, 2 y 3.

Es importante remarcar que la variable definida siempre es “cantidad de éxitos” y que hace referencia a la probabilidad de éxito (según lo que se definió como éxito en la variable).

Ejemplo 19

Se ha lanzado un nuevo sabor de gaseosa al mercado. Un gran número de distribuidores están encargados de visitar a los negocios minoristas para ofrecer el producto. La probabilidad de que un distribuidor consiga vender la nueva gaseosa en una visita es 0,2. Si en una mañana de trabajo se realizan 10 visitas, ¿cuál es la probabilidad de que se efectivicen 3 ventas?

La variable aleatoria involucrada es X : “cantidad de ventas efectivizadas al realizar 10 visitas”. Si usamos la notación anterior se tiene que $n = 10$ y $p = 0,2$. Se desea averiguar la probabilidad de que la variable aleatoria valga 3. Entonces:

$$p(X=3) = {}_{10}C_3 \cdot 0,2^3 \cdot 0,8^7 = 0,201$$



Considerando la misma situación, ¿cuál es la probabilidad de que se realicen *al menos* 3 ventas? ¿y la probabilidad de que se efectivicen a lo sumo 3 ventas? ¿Y menos de 3 ventas? ¿y la probabilidad de que no se realice 1 venta? Analice cuidadosamente las diferencias entre las preguntas.

Dado que la variable que sigue una distribución binomial es una variable aleatoria, puede calcularse su valor esperado o esperanza matemática y su varianza. Puede demostrarse que, para esta distribución:

$$E(X) = n \cdot p \qquad V(X) = n \cdot p \cdot q$$

donde n es el número de pruebas, p la probabilidad de éxito de cada prueba y q ($1-p$) la probabilidad de fracaso.

4.1.2 Hipergeométrica

Tanto la distribución binomial como la hipergeométrica se refieren a la misma variable aleatoria: el número de éxitos en una muestra que contiene n observaciones (también llamadas pruebas). Lo que distingue a estas dos distribuciones de probabilidad es la forma en la que se obtienen los datos. Para la distribución binomial los datos de la muestra se obtienen *con* reemplazo o *sin* reemplazo en una población *infinita*. En cambio, para el modelo hipergeométrico los datos de la muestra se obtienen *sin* reemplazo de una población *finita*. Como consecuencia de esto, la probabilidad de obtener un éxito en cada una de las extracciones no es constante. Por el contrario, el resultado de una observación es afectado por los resultados de las observaciones previas.

Ejemplo 20

Supongamos que tenemos un lote de 15 llantas de las cuales 4 son defectuosas. Si se seleccionan 2 llantas al azar *con* reposición (modelo binomial) la probabilidad de que la primera llanta sea defectuosa es $p = 4/15$ y la probabilidad de que la segunda sea defectuosa también es $p = 4/15$, independientemente del resultado de la primera observación. Si en cambio la selección se realiza *sin* reposición, la probabilidad de que la primera llanta seleccionada sea defectuosa será $4/15$, pero la probabilidad de la segunda sea defectuosa *depende* de cuál fue el resultado de la primera. Si la primera fue defectuosa, la probabilidad de extraer nuevamente una defectuosa será $3/14$. En cambio, si la primera llanta no fue defectuosa la probabilidad de que la segunda lo sea es $4/14$.

(En este ejemplo, no tendría sentido pensar en una selección con reposición, ya que se correría el riesgo de seleccionar dos veces la misma llanta).

Sea X la variable aleatoria “número de éxitos al realizar n extracciones sin reemplazo de una población finita de tamaño N ”, el siguiente modelo matemático permite encontrar la probabilidad de que dicha v.a. tome un valor k :

$$p(X = k) = \frac{\binom{m}{k} \cdot \binom{N-m}{n-k}}{\binom{N}{n}}$$

donde n = tamaño de muestra

N = tamaño de la población

m = número de éxitos en la población

$N - m$ = número de fracasos de la población

Ejemplo 21

Cuando se descubre un cargamento de drogas ilegales la policía científica no analiza la totalidad de los paquetes hallados. Por el contrario, elige al azar un determinado número de ellos para realizar las pruebas toxicológicas correspondientes. Si se encontró un cargamento de 20 paquetes, pero 15 de ellos tienen drogas ilegales y los otros 5, sustancias legales. Si la policía científica analiza 4 paquetes, ¿cuál es la probabilidad de que sólo 1 contenga drogas ilegales?

La variable aleatoria involucrada es X: “cantidad de paquetes que contienen drogas ilegales al seleccionar una muestra de 4”. Usando la notación anterior tenemos que

$$N = 20$$

$$n = 4$$

$$m = 15$$

Se quiere averiguar la probabilidad de que la variable aleatoria asuma el valor uno. Entonces:

$$p(X = 1) = \frac{\binom{15}{1} \cdot \binom{5}{3}}{\binom{20}{4}} = 0,03$$



Considerando la misma situación, ¿cuál es la probabilidad de que *al menos* 1 paquete contenga drogas ilegales? ¿y la probabilidad de que a lo sumo 1 contenga drogas ilegales? ¿Y menos de 1? ¿Y la probabilidad de que 3 contengan drogas legales?

Analice cuidadosamente la diferencia entre las preguntas.

Estos modelos probabilísticos tienen múltiples aplicaciones. Una muy importante se encuentra en el proceso de muestreo. Cuando se desea realizar inferencia estadística, el proceso siempre comienza con la selección de una muestra de una población determinada. Dicho muestreo puede realizarse con reemplazo (es decir un individuo puede ser seleccionado más de una vez) o sin reemplazo (cada individuo puede ser seleccionado una sola vez). Esto tiene un correlato en los modelos estudiados.

4.1.3 Poisson

Otra distribución de probabilidad discreta muy usada es la distribución Poisson.

En este caso la variable aleatoria representa el número de eventos independientes que ocurren, a una velocidad constante, en el tiempo o en el espacio.

Veamos algunos ejemplos típicos de esta distribución:

- El número de personas que llega a una tienda de autoservicio en un tiempo determinado.
- El número de solicitudes de seguro procesadas por una compañía en un período específico.
- El número de fallas en una pieza de género.

La distribución Poisson es el modelo de probabilidad que más se utiliza para analizar problemas de listas de espera.

Las características de una distribución de Poisson son las siguientes:

- 1- Se debe tener un fenómeno dicotómico (ocurrencia o no de un determinado suceso).
- 2- Las pruebas que se realicen son independientes y la probabilidad de éxito se mantiene constante en todas ellas.
- 3- Los sucesos son poco comunes, por eso se le conoce como "Ley de los sucesos raros".
- 4- Los sucesos ocurren en un intervalo de tiempo o de espacio.
- 5- Se caracteriza por un parámetro λ , que es el número medio de ocurrencia del suceso aleatorio por unidad de tiempo o de espacio.

Sea X la variable aleatoria "número de sucesos que ocurren en un cierto intervalo de tiempo o espacio". El siguiente modelo matemático permite encontrar la probabilidad de que dicha v.a tome un valor k :

$$p(X = k) = \frac{e^{-\lambda} \cdot \lambda^k}{k!}$$

en donde λ es el número promedio de ocurrencias del mencionado evento en el período que se considera.

Ejemplo 22

El número de llamadas telefónicas que entran a una central de un edificio de oficinas es de 4 por minuto, en promedio. Calcular la probabilidad de que lleguen 3 llamadas en el período de un minuto.

La variable aleatoria es X : "número de llamadas entrantes en un minuto". Es importante precisar el valor de λ , que para este caso es de 4 llamadas por minuto. Se desea averiguar la probabilidad de que la variable aleatoria asuma el valor 3.

$$p(X = 3) = \frac{e^{-4} \cdot 4^3}{3!} = 0,195$$



Considerando la misma situación, ¿cuál es la probabilidad de que lleguen 50 llamadas en el período de media hora? ¿Cuál es la probabilidad de que entren *al menos* 3 llamadas en un minuto? Analice cuidadosamente la diferencia entre las preguntas.

4.2 Distribuciones continuas

Hasta el momento sólo se han presentado modelos matemáticos correspondientes a variables aleatorias discretas. A continuación, se presentan casos en que la variable aleatoria puede tomar cualquier valor que esté en un intervalo de valores.


4.2.1 Distribución Uniforme

La distribución Uniforme es el modelo continuo más simple. Corresponde al caso de una variable aleatoria que sólo puede tomar valores comprendidos entre dos extremos a y b , de manera que todos

los intervalos de una misma longitud (dentro de (a, b)) tienen la misma probabilidad de ocurrir. De la anterior definición se desprende que la función de densidad toma el mismo valor para todos los puntos dentro del intervalo (a, b) (y cero fuera del intervalo). Considerando que el área debajo de la gráfica de la función densidad es igual a 1, dicha función es:

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{si } a < x < b \\ 0 & \text{en otro caso} \end{cases}$$

Gráficamente:



Ejemplo 23:

Sea X un número aleatorio comprendido entre 0 y 5. Entonces X tiene una distribución:

$$f(x) = \begin{cases} \frac{1}{5} & \text{si } 0 < x < 5 \\ 0 & \text{en otro caso} \end{cases}$$

Si se desea calcular la probabilidad de que dicho número esté comprendido entre 2 y 4, entonces:

$$p(2 < x < 4) = \int_2^4 \frac{1}{5} dx = \frac{1}{5} \cdot (4 - 2) = 0,4$$

4.2.2 Distribución Normal

Una distribución de probabilidad continua que es muy importante es la distribución *normal* o *gaussiana*.

Existen varias razones por las cuales esta distribución ocupa un lugar tan preponderante en la estadística. Primero, tiene algunas propiedades que la hacen aplicables a un gran número de situaciones en las que es necesario hacer inferencia estadística a partir de la toma de muestras. Segundo, se ajusta a distribuciones de frecuencias reales observadas en muchos fenómenos, incluyendo características humanas. Tercero, proporciona una aproximación a diversas distribuciones de probabilidad discreta (binomial, hipergeométrica, Poisson).

Se dice que una variable aleatoria continua X tiene una distribución normal, si su función de densidad de probabilidad está dada por la siguiente expresión matemática:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \cdot e^{-1/2 \cdot \left(\frac{x-\mu}{\sigma}\right)^2} \quad \text{para } -\infty < x < \infty$$

donde:


e y π son constantes matemáticas

μ es la media o esperanza de la variable aleatoria X

σ es la desviación estándar

En símbolos se escribe: $X \sim N(\mu, \sigma)$ que se lee “la variable aleatoria X se distribuye normalmente con media μ y desvío σ ”.



Su representación gráfica es la siguiente curva:



Analicemos las propiedades geométricas de esta función

- 1.- La curva tiene forma campaniforme y es simétrica respecto a la media (μ) (moda, media y mediana coinciden)
- 2.- Es unimodal.
- 3.- El área bajo la campana es igual a 1.
- 4.- Presenta puntos de inflexión en los puntos de abscisas $\mu + \sigma$ y $\mu - \sigma$, donde cambia de concavidad (lo que determina que cuanto mayor sea σ más achatada sea la curva).
- 5.- Es asintótica al eje de abscisas.

En las siguientes figuras puede observarse que para σ fijo, el variar μ tiene el efecto de desplazar la curva hacia la derecha o la izquierda. En cambio, manteniendo μ constante, el cambio de σ tiene por efecto acercar o alargar del valor medio μ los puntos de inflexión, es decir, un apuntamiento o aplastamiento de la curva.



En las familias representadas por las distribuciones normales ocupa un lugar especial la distribución que tiene de media cero ($\mu = 0$) y por desviación típica la unidad ($\sigma = 1$). Esta distribución se llama la distribución normal estándar, o reducida.

Su función de densidad es:

$$f(z) = \frac{1}{\sigma\sqrt{2\pi}} \cdot e^{-1/2 \cdot z^2} \quad \text{para } -\infty < z < \infty$$


En este caso la gráfica de la densidad es simétrica con respecto al origen.

Si se quiere calcular la probabilidad de que la variable aleatoria Z tome valores comprendidos entre a y b se debe resolver la siguiente integral:

$$p(a < Z < b) = \int_a^b \frac{1}{\sigma\sqrt{2\pi}} \cdot e^{-1/2 \cdot z^2} dz$$

Esta integral no puede expresarse en términos de funciones elementales, por lo tanto se calcula para valores específicos de X mediante una aproximación numérica. Para no tener que repetir esos cálculos cada vez que se necesita averiguar una probabilidad, existen tablas con valores cuyo correcto manejo e interpretaciones son de suma importancia.

Una de las tablas mencionadas se muestra a continuación:



z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.0000	0.0040	0.0080	0.0120	0.0160	0.0199	0.0239	0.0279	0.0319	0.0359
0.1	0.0398	0.0438	0.0478	0.0517	0.0557	0.0596	0.0636	0.0675	0.0714	0.0753
0.2	0.0793	0.0832	0.0871	0.0910	0.0948	0.0987	0.1026	0.1064	0.1103	0.1141
0.3	0.1179	0.1217	0.1255	0.1293	0.1331	0.1368	0.1406	0.1443	0.1480	0.1517
0.4	0.1554	0.1591	0.1628	0.1664	0.1700	0.1736	0.1772	0.1808	0.1844	0.1879
0.5	0.1915	0.1950	0.1985	0.2019	0.2054	0.2088	0.2123	0.2157	0.2190	0.2224
0.6	0.2257	0.2291	0.2324	0.2357	0.2389	0.2422	0.2454	0.2486	0.2517	0.2549
0.7	0.2580	0.2611	0.2642	0.2673	0.2704	0.2734	0.2764	0.2794	0.2823	0.2852
0.8	0.2881	0.2910	0.2939	0.2967	0.2995	0.3023	0.3051	0.3078	0.3106	0.3133
0.9	0.3159	0.3186	0.3212	0.3238	0.3264	0.3289	0.3315	0.3340	0.3365	0.3389
1.0	0.3413	0.3438	0.3461	0.3485	0.3508	0.3531	0.3554	0.3577	0.3599	0.3621
1.1	0.3643	0.3665	0.3686	0.3708	0.3729	0.3749	0.3770	0.3790	0.3810	0.3830
1.2	0.3849	0.3869	0.3888	0.3907	0.3925	0.3944	0.3962	0.3980	0.3997	0.4015
1.3	0.4032	0.4049	0.4066	0.4082	0.4099	0.4115	0.4131	0.4147	0.4162	0.4177
1.4	0.4192	0.4207	0.4222	0.4236	0.4251	0.4265	0.4279	0.4292	0.4306	0.4319
1.5	0.4332	0.4345	0.4357	0.4370	0.4382	0.4394	0.4406	0.4418	0.4429	0.4441
1.6	0.4452	0.4463	0.4474	0.4484	0.4495	0.4505	0.4515	0.4525	0.4535	0.4545
1.7	0.4554	0.4564	0.4573	0.4582	0.4591	0.4599	0.4608	0.4616	0.4625	0.4633
1.8	0.4641	0.4649	0.4656	0.4664	0.4671	0.4678	0.4686	0.4693	0.4699	0.4706
1.9	0.4713	0.4719	0.4726	0.4732	0.4738	0.4744	0.4750	0.4756	0.4761	0.4767

2.0	0.4772	0.4778	0.4783	0.4788	0.4793	0.4798	0.4803	0.4808	0.4812	0.4817
2.1	0.4821	0.4826	0.4830	0.4834	0.4838	0.4842	0.4846	0.4850	0.4854	0.4857
2.2	0.4861	0.4864	0.4868	0.4871	0.4875	0.4878	0.4881	0.4884	0.4887	0.4890
2.3	0.4893	0.4896	0.4898	0.4901	0.4904	0.4906	0.4909	0.4911	0.4913	0.4916
2.4	0.4918	0.4920	0.4922	0.4925	0.4927	0.4929	0.4931	0.4932	0.4934	0.4936
2.5	0.4938	0.4940	0.4941	0.4943	0.4945	0.4946	0.4948	0.4949	0.4951	0.4952
2.6	0.4953	0.4955	0.4956	0.4957	0.4959	0.4960	0.4961	0.4962	0.4963	0.4964
2.7	0.4965	0.4966	0.4967	0.4968	0.4969	0.4970	0.4971	0.4972	0.4973	0.4974
2.8	0.4974	0.4975	0.4976	0.4977	0.4977	0.4978	0.4979	0.4979	0.4980	0.4981
2.9	0.4981	0.4982	0.4982	0.4983	0.4984	0.4984	0.4985	0.4985	0.4986	0.4986
3.0	0.4987	0.4987	0.4987	0.4988	0.4988	0.4989	0.4989	0.4989	0.4990	0.4990

Esta tabla da valores del área bajo la curva desde la línea central hasta cualquier línea vertical que pasa por un determinado valor de z .

Por ejemplo, para saber el área debajo de la curva entre 0 y 1,45, se debe ubicar la celda cuya fila está encabezada por el valor 1.4 y cuya columna está encabezada por 0,05.

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.0000	0.0040	0.0080	0.0120	0.0160	0.0199	0.0239	0.0279	0.0319	0.0359
0.1	0.0398	0.0438	0.0478	0.0517	0.0557	0.0596	0.0636	0.0675	0.0714	0.0753
0.2	0.0793	0.0832	0.0871	0.0910	0.0948	0.0987	0.1026	0.1064	0.1103	0.1141
0.3	0.1179	0.1217	0.1255	0.1293	0.1331	0.1368	0.1406	0.1443	0.1480	0.1517
0.4	0.1554	0.1591	0.1628	0.1664	0.1700	0.1736	0.1772	0.1808	0.1844	0.1879
0.5	0.1915	0.1950	0.1985	0.2019	0.2054	0.2088	0.2123	0.2157	0.2190	0.2224
0.6	0.2257	0.2291	0.2324	0.2357	0.2389	0.2422	0.2454	0.2486	0.2517	0.2549
0.7	0.2580	0.2611	0.2642	0.2673	0.2704	0.2734	0.2764	0.2794	0.2823	0.2852
0.8	0.2881	0.2910	0.2939	0.2967	0.2995	0.3023	0.3051	0.3078	0.3106	0.3133
0.9	0.3159	0.3186	0.3212	0.3238	0.3264	0.3289	0.3315	0.3340	0.3365	0.3389
1.0	0.3413	0.3438	0.3461	0.3485	0.3508	0.3531	0.3554	0.3577	0.3599	0.3621
1.1	0.3643	0.3665	0.3686	0.3708	0.3729	0.3749	0.3770	0.3790	0.3810	0.3830
1.2	0.3849	0.3869	0.3888	0.3907	0.3925	0.3944	0.3962	0.3980	0.3997	0.4015
1.3	0.4032	0.4049	0.4066	0.4082	0.4099	0.4115	0.4131	0.4147	0.4162	0.4177
1.4	0.4192	0.4207	0.4222	0.4236	0.4251	0.4265	0.4279	0.4292	0.4306	0.4319

Así entonces se tiene que:

$$P(0 < Z < 1,45) = 0,4265$$

Se debe notar que por la simetría de la curva, la tabla es válida también para valores negativos de Z:

$$p(-1,45 < Z < 0) = P(0 < Z < 1,45) = 0,4265$$

Una propiedad importante de la distribución normal es que si $X \sim N(\mu, \sigma)$ entonces la v.a. $Z = \frac{x-\mu}{\sigma}$ es una variable aleatoria normal estandarizada, es decir que $Z \sim N(0, 1)$. Esta importante propiedad permite resolver situaciones en las que intervengan variables aleatorias normalmente distribuidas con cualquier media y desvío.

Ejemplo 24:

Hay dos máquinas para cortar corchos destinados para usarse en botellas de vino. La primera produce corchos con diámetros que están normalmente distribuidos con media de 3 cm. y desviación estándar de 0,1 cm. La segunda máquina produce corchos con diámetros que siguen una distribución normal con media de 3,04 cm. y desviación estándar de 0,02 cm. Los corchos aceptables tienen diámetros entre 2,9 cm. y 3,1 cm. ¿Qué máquina tiene más probabilidad de producir un corcho aceptable?

Sean las variables aleatorias

X: "diámetro de un corcho producido por la máquina 1"

Y: "diámetro de un corcho producido por la máquina 2"

Entonces $X \sim N(3; 0,1)$ e $Y \sim N(3,04; 0,02)$. Calculamos cuál es la probabilidad de que la máquina 1 produzca un corcho aceptable.

$$p(2,9 < X < 3,1) = p\left(\frac{2,9-3}{0,1} < \frac{x-3}{0,1} < \frac{3,1-3}{0,1}\right) = p(-1 < Z < 1) = 2 \cdot p(0 < Z < 1) = 2 \cdot 0,3413 = 0,6826$$

Análogamente para la máquina 2:

$$p(2,9 < Y < 3,1) = p\left(\frac{2,9-3,04}{0,02} < \frac{y-3,04}{0,02} < \frac{3,1-3,04}{0,02}\right) = p(-7 < Z < 3) = p(-7 < Z < 0) + p(0 < Z < 3) = p(0 < Z < 7) + p(0 < Z < 3) = 0,5 + 0,4987 = 0,9987.$$

Entonces es más probable que la máquina 2 produzca corchos aceptables.

En muchas ocasiones es necesario averiguar valores de la variable aleatoria conocida una probabilidad, tal como se muestra en el siguiente ejemplo.

Ejemplo 25:

Consideremos la máquina 1 del ejemplo anterior. Se desea averiguar cuál es el mayor diámetro del 85% de corchos más chicos que produce.

Simbólicamente esta situación se puede escribir:

$$p(X < x_1) = 0,85 \text{ siendo } x_1 \text{ el valor buscado.}$$


A partir de esta igualdad se obtiene:

$$p\left(\frac{x-3}{0,1} < \frac{x_1-3}{0,1}\right) = 0,85$$

Si llamamos $k = \frac{x_1-3}{0,1}$ se trata entonces de utilizar la tabla para encontrar el valor de k tal que:

$$P(Z < k) = 0,85$$

Gráficamente, equivale a hallar el valor de k de modo que el área sombreada sea 0,85.



Para ello se busca en la tabla el valor de área más cercano a 0,35 (¿por qué?) y se toma el correspondiente valor de z.

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.0000	0.0040	0.0080	0.0120	0.0160	0.0199	0.0239	0.0279	0.0319	0.0359
0.1	0.0398	0.0438	0.0478	0.0517	0.0557	0.0596	0.0636	0.0675	0.0714	0.0753
0.2	0.0793	0.0832	0.0871	0.0910	0.0948	0.0987	0.1026	0.1064	0.1103	0.1141
0.3	0.1179	0.1217	0.1255	0.1293	0.1331	0.1368	0.1406	0.1443	0.1480	0.1517
0.4	0.1554	0.1591	0.1628	0.1664	0.1700	0.1736	0.1772	0.1808	0.1844	0.1879
0.5	0.1915	0.1950	0.1985	0.2019	0.2054	0.2088	0.2123	0.2157	0.2190	0.2224
0.6	0.2257	0.2291	0.2324	0.2357	0.2389	0.2422	0.2454	0.2486	0.2517	0.2549
0.7	0.2580	0.2611	0.2642	0.2673	0.2704	0.2734	0.2764	0.2794	0.2823	0.2852
0.8	0.2881	0.2910	0.2939	0.2967	0.2995	0.3023	0.3051	0.3078	0.3106	0.3133
0.9	0.3159	0.3186	0.3212	0.3238	0.3264	0.3289	0.3315	0.3340	0.3365	0.3389
1.0	0.3413	0.3438	0.3461	0.3485	0.3508	0.3531	0.3554	0.3577	0.3599	0.3621
1.1	0.3643	0.3665	0.3686	0.3708	0.3729	0.3749	0.3770	0.3790	0.3810	0.3830

Se tiene entonces que el valor de k es 1,04. Como $k = \frac{x_1 - 3}{0,1}$, $1,04 = \frac{x_1 - 3}{0,1}$. De esta igualdad $x_1 = 3,104$ que es el valor del diámetro buscado.

4.2.3 Aproximación normal de la distribución binomial de probabilidades

En la sección 4.1.1 se presentó la distribución binomial discreta. Recordemos que un experimento binomial consiste en una serie de n pruebas idénticas e independientes, cada una de las cuales tiene dos resultados posibles, éxito o fracaso. La probabilidad de éxito cada prueba es siempre la misma y se denota p . La variable aleatoria binomial es el número de éxitos en n pruebas y lo que se quiere saber es la probabilidad de obtener x éxitos en n ensayos.

La evaluación de una función de probabilidad binomial utilizando las fórmulas presentadas en la sección 4.1.1, se dificulta cuando el número de pruebas es muy grande. En los casos en que $np \geq 5$ la distribución normal proporciona una aproximación a las probabilidades binomiales que es fácil de usar. Cuando se usa la aproximación normal a la binomial, en la definición de la curva normal $\mu = np$ y $\sigma^2 = npq$.

Ejemplo 26:

Para ilustrar la aproximación normal a la binomial, suponga que una empresa sabe por experiencia que 10% de sus facturas tienen algún error. Toma una muestra de 100 facturas y desea calcular la probabilidad de que entre 10 y 25 de estas facturas contengan algún error. Veamos la resolución utilizando el modelo binomial. Según la notación presentada se tiene $n = 100$ y $p = 0,10$. La variable aleatoria es X : “número de facturas con errores en una muestra de 100”. Se desea averiguar:

$$p(X \leq 25) = \binom{100}{10} \cdot 0,1^{10} \cdot 0,9^{90} + \binom{100}{11} \cdot 0,1^{11} \cdot 0,9^{89} + \dots + \binom{100}{25} \cdot 0,1^{25} \cdot 0,9^{75}$$

Puede observarse que esta cuenta presenta gran dificultad a la hora de calcularla. Si, en cambio, aplicamos la aproximación normal en este caso se tiene

$$\mu = n \cdot p = 100 \cdot 0,10 = 10 \geq 5$$

$$\sigma = \sqrt{n \cdot p \cdot q} = \sqrt{100 \cdot 0,1 \cdot 0,9} = 9,47$$

Por lo tanto la probabilidad requerida se puede calcular como sigue:

$$p(10 \leq X \leq 25) = p\left(\frac{10-10-0,5}{9,47} \leq \frac{x-10}{9,47} \leq \frac{25-10+0,5}{9,47}\right) = p(-0,05 \leq Z \leq 1,64) = 0,0199 + 0,4495 = 0,4694$$

Observación: Al realizar la estandarización se incluye en el numerador un factor de corrección (igual a 0,5) que acerca el valor de la aproximación un poco más al valor real de la probabilidad que se está aproximando. Este factor se agrega “ampliando” el intervalo al que se le quiere calcular la probabilidad de ocurrencia.

Material de cátedra

Estadística

Números Índice

Autores

Mario Seffino

Silvina Etcheverría

**Facultad de Ciencias Económicas
Universidad Nacional del Centro de la Provincia de
Buenos Aires**



Tabla de contenido

1	Introducción	3
2	Números índice simples	4
3	Números índice complejos o de agregados	6
3.1	Números índice no ponderados	6
3.1.1	Números índice no ponderados de precios	7
3.1.2	Números índice no ponderados de cantidad y de valor	8
3.2	Números índice ponderados	8
3.2.1	Índice ponderado de precios. Método de Laspeyres	8
3.2.2	Índice de precios de Paasche	9
3.2.3	Índice ideal de Fisher	10
3.2.4	Índice ponderado con pesos fijos	11
4	Consideraciones importantes	11
5	Bibliografía	12

1 Introducción

En este cuadernillo se examinará una herramienta estadística muy utilizada denominada **Número Índice**. Los números índice se utilizan para comparar cierta magnitud en dos situaciones diferentes respecto al tiempo o al espacio y tomando a una de ellas como referencia. En las Ciencias Económicas, los números índice constituyen un instrumento básico para sintetizar las estadísticas económicas de tal modo que nos permitan expresar y describir el comportamiento de las variables económicas, como por ejemplo, el crecimiento económico de un país, la tasa de inflación de una economía o incluso, el cambio en la productividad de un factor de producción.

En este contexto, sin duda se encontrará familiarizado con algunos números índice como, por ejemplo, el **Índice de Precios al Consumidor** (IPC) que se publica mensualmente y mide la variación de precios de los bienes y servicios representativos del gasto de consumo de los hogares. Pero también existen muchos otros números índice como pueden ser el **Índice de Producción Manufacturero** (IPI) que mide la evolución del sector manufacturero o el **Indicador Sintético de la Actividad de la Construcción** (ISAC) que muestra la evolución del sector tomando como referencia los consumos aparentes de insumos requeridos en la construcción, entre otros.¹

¿Qué es un número índice?

Un número índice es un valor representativo que permite comparar cierta magnitud en dos situaciones diferentes respecto al tiempo o al espacio y tomando a una de ellas como referencia.

La compilación de números índice no es una innovación reciente. A un italiano llamado G.R. Carli se lo reconoce como el creador de los primeros números índice en el año 1764. Los incorporó a un informe que elaboró respecto de las fluctuaciones de precios en Europa desde 1500 a 1750. En Estados Unidos no se utilizaron sistemáticamente hasta 1900.

Ahora bien, ¿cuál es la importancia de un número índice? ¿Por qué convertir datos en números índice? Con frecuencia uno quiere comparar datos de períodos de tiempo diferentes. Por ejemplo, podríamos querer comparar el precio actual de un producto con el precio que tenía el mismo producto hace unos años atrás y de esa manera, saber en cuánto ha variado su valor. Asimismo, un trabajador podría querer saber cuál fue la evolución de su salario en un determinado período de tiempo, etc. Para efectuar este tipo de comparaciones se necesita determinar y definir el grado de cambio entre un período y otro y, comúnmente, los números índice son los que nos permiten medir esas diferencias.

Dicho esto, resulta oportuno preguntarse cómo se calculan los números índice y cómo se interpretan dependiendo de la finalidad y complejidad de las comparaciones. Básicamente,

¹ Los números índice mencionados en el párrafo son publicados periódicamente por el Instituto Nacional de Estadística y Censos de la República Argentina (INDEC). La metodología detallada para su cálculo podrá ser encontrada en: <https://www.indec.gob.ar/>

un número índice se calcula realizando el cociente de un valor actual entre un valor de referencia llamado base. Luego, se multiplica el número resultante por 100 para expresar el número índice como un porcentaje. Nótese que el número índice para el punto base es siempre 100. Asimismo, los números índice pueden clasificarse en números índice simples o complejos.

Un **número índice simple** se refiere a la variación de una sola variable en el tiempo o espacio. Por ejemplo, una persona puede querer averiguar la variación en el tiempo del precio o la cantidad vendida de los tomates, para lo cual el cálculo de un número índice simple sería suficiente. Sin embargo, frecuentemente uno quiere comparar la magnitud de un conjunto heterogéneo de elementos. Siguiendo con el ejemplo anterior, se podría querer conocer no sólo la evolución del precio de los tomates, sino también, la variación en el precio o en la cantidad del conjunto de frutas y verduras. En este caso, se necesita el cómputo de un **número índice complejo** (también llamado de agregados o compuesto) permitiendo resumir en una sola serie las fluctuaciones de un conjunto de elementos o variables generalmente relacionadas entre sí. El IPC mencionado anteriormente es un claro ejemplo de un número índice complejo ya que involucra información de muchos elementos como alimentos, gastos médicos, recreación, vestimenta, educación, honorarios, etc., y para diferentes regiones geográficas del país.

Los números índice complejos, a su vez, pueden ser clasificados en **números índice ponderados y no ponderados**. La principal diferencia entre estos es que a menudo, cuando calculamos un índice complejo, queremos asignarle una importancia mayor a los cambios producidos en alguna de las variables más que en otras. En este caso, se utilizan números índice ponderados. En el ejemplo de las frutas y verduras, se podría querer darle una mayor importancia a aquellos productos que más se venden o que más aumentaron en la verdulería, etc. Esta ponderación permite incluir más información mejorando la precisión en el cálculo realizado. El problema reside en decidir cuánto peso asignarle a cada una de las variables examinadas. Por el contrario, un número índice no ponderado considera que todos los elementos considerados tienen la misma importancia. Lógicamente, la mayor ventaja de un número índice no ponderado es su sencillez.

Por último, cabe aclarar que dependiendo de si el valor de referencia es fijo o no, se puede hablar de **números índice en serie** (con base fija) o de **números índice en cadena** (con base variable). Para el cálculo de estos últimos, generalmente se toma como valor de referencia al valor base inmediatamente anterior.

2 Números índice simples

Como se mencionó anteriormente, un número índice simple se usa para medir el cambio relativo de una sola variable entre dos períodos o lugares diferentes tomando a uno de ellos de referencia o base. Es decir,

$$\text{Índice simple} = \frac{\text{Dato del período actual}}{\text{Dato del período base}} \times 100$$

Veamos un ejemplo:

Una empresa automotriz ha registrado las siguientes ventas anuales (en unidades) entre 2010 y 2011:

Tabla 1.

Año	2010	2011	2012	2013
Unidades vendidas	215.362	244.361	258.746	273.551

Si queremos calcular el índice de ventas del año 2011 tomando como base el año 2010 debemos hacer:

$$\text{Índice de ventas} = \frac{244.361}{215.362} \times 100 = 113,47 (\%)$$

Esto quiere decir que en 2011 la cantidad de automóviles vendidos aumentó un 13,47% con respecto a 2010. Como el cociente se multiplica por 100, el índice resultante es, técnicamente, un porcentaje. Sin embargo, es habitual omitir el signo % al analizar los números índice. La Tabla 2 presenta los cálculos para el resto de los años del ejemplo. Se observa que en 2012 las ventas aumentaron un 20,14 % con respecto a 2010.

Tabla 2. Número índice simple

Año	Unidades vendidas	Índice simple (base 2010)
2010	215.362	$(215.362/215.362) \times 100 = 100,00$
2011	244.361	$(244.361/215.362) \times 100 = 113,47$
2012	258.746	$(258.746/215.362) \times 100 = 120,14$
2013	273.551	$(273.551/215.362) \times 100 = 127,02$


Un índice puede utilizarse también para hacer comparaciones con respecto a una dimensión espacial. Por ejemplo, la población de las provincias de Buenos Aires y Tierra del Fuego según datos del censo 2010 era respectivamente 15.625.083 y 127.205 personas. Podemos calcular un índice simple que compare la población de Tierra del Fuego con la Buenos Aires. En este caso, se tiene:

$$\frac{\text{Población de Tierra del Fuego}}{\text{Población de Buenos Aires}} \times 100 = \frac{127.205}{15.625.083} \times 100 = 0,8$$

Esto significa que la población de Tierra del Fuego representa un 0,8% de la población de Buenos Aires. O si se quiere, que la población de la primera es un 99,2% menor que la de la segunda. Generalmente, este tipo de índices es llamado “tasa de variación”.

Veamos un ejemplo más. Supongamos que el alquiler de un inmueble en 2014 fue de \$3500. El costo de dicho alquiler en 2019 aumentó a \$5700. ¿Cuál fue la variación del alquiler para 2019 tomando 2014 como período base?

$$\text{Índice simple} = \frac{\text{precio del año actual (2019)}}{\text{precio del año base (2014)}} \times 100 = \frac{5700}{3500} \times 100 = 162,85$$



¿Cómo es la interpretación de este valor?

En general:

$$\text{Índice simple} = \frac{\text{Dato del período actual}}{\text{Dato del período base}} \times 100$$

Asimismo, existen diferentes tipos de números índice simples dependiendo de lo que se quiera comparar. Un **número índice simple de precios** compara niveles de precios de un período a otro. Un **número índice simple de cantidad** evalúa cuánto varía la cantidad de una variable y un **número índice simple de valor** mide los cambios en el valor, es decir en dinero, de una variable a través de distintos períodos de tiempo. En otras palabras, el índice simple de valor combina los cambios en precio y cantidad para presentar un índice con más información. Resumiendo, se tiene lo siguiente:

$$\text{Índice simple de precio} = \frac{\text{Precio del período actual}}{\text{Precio del período base}} \times 100$$

$$\text{Índice simple de cantidad} = \frac{\text{Cantidad del período actual}}{\text{Cantidad del período base}} \times 100$$

$$\text{Índice simple de valor} = \frac{(\text{Precio} \times \text{Cantidad}) \text{ del período actual}}{(\text{Precio} \times \text{Cantidad}) \text{ del período base}} \times 100$$

3 Números índice complejos o de agregados

En muchas ocasiones se desea combinar varios conceptos y elaborar un índice para comparar la variación de un grupo compuesto de varios elementos que se relacionan entre sí. Por ejemplo, se desea elaborar un índice para elementos relacionados con el uso y mantenimiento de un automóvil. Los elementos podrían incluir llantas, cambios de aceite y combustible. O tal vez, interese un índice de educación universitaria el cual podría incluir el costo de material académico, de transporte, de vivienda y de alimentación. En estos casos, se requiere calcular índices más elaborados llamados números índice complejos o también llamados números índice de agregados o compuestos. Como se mencionó anteriormente, estos pueden ser ponderados y no ponderados dependiendo de si queremos asignarle una importancia mayor a alguno de los conceptos que componen el índice o no.

3.1 Números índice no ponderados

Es la forma más sencilla de un número índice complejo. Se denominan no ponderados porque a todos los valores considerados en la elaboración del número índice se le asigna la misma importancia. Un índice complejo no ponderado se calcula sumando todos los elementos del compuesto para el período dado o actual y dividiendo este resultado entre la suma de los mismos elementos del periodo base.

3.1.1 Números índice no ponderados de precios

Para el cálculo de un número índice complejo no ponderado de precios se tiene la siguiente expresión:

$$\text{Índice no ponderado de precios} = \frac{\sum P_i}{\sum P_0} \times 100$$

donde P_i es el precio de cada elemento en el año para el que se desea calcular el índice y P_0 es el precio de cada elemento en el año base. Consecuentemente, tanto en el numerador como en el denominador de la expresión anterior se tienen sumatorias de precios. Por ejemplo:

Tabla 3. Índice no ponderado de precios

Artículos	2015	2016	2017
Pan blanco (kilo)	0,80	0,92	1,02
Huevos (docena)	1,90	1,80	1,85
Leche (litro)	1,61	1,84	1,95
Jugo de naranjas (litro)	1,72	1,80	1,69
Café tostado (kilo)	6,70	6,95	7,13
$\sum P$	12,73	13,31	13,64
$\sum P_i / \sum P_0 \times 100$	$\frac{12,73}{12,73} \times 100 = 100,00$	$\frac{13,31}{12,73} \times 100 = 104,56$	$\frac{13,64}{12,73} \times 100 = 107,15$

Es decir, para el cálculo del índice no ponderado de precios para el año 2017 con base en 2015 se hizo lo siguiente: se sumaron los precios de todos los elementos de 2017 ($1,02 + 1,85 + 1,95 + 1,69 + 7,13 = 13,64$) y luego se dividió dicho resultado por la suma de los precios de todos los elementos del año 2015 ($0,80 + 1,90 + 1,61 + 1,72 + 6,70 = 12,73$). Por último, se multiplicó el resultado por 100, entonces: $13,64 \div 12,73 \times 100 = 107,15$. Esto quiere decir que los precios del conjunto de elementos analizados aumentaron un 7,15% en 2017 con respecto a 2015.



Para discutir: ¿qué problema encuentran en este índice? ¿La cantidad de litros de leche y de kilos de café son iguales en una familia tipo?

3.1.2 Números índice no ponderados de cantidad y de valor

Así como se mencionó anteriormente la posibilidad de calcular números índices simples tanto de precios como de cantidad o de valor, lo mismo puede hacerse para números índices complejos. En el apartado anterior ya nos referimos a un índice no ponderado de precios y a continuación se presentan las fórmulas para índices no ponderados de cantidad y de valor:

- **Índice no ponderado de cantidad** $= \frac{\sum Q_i}{\sum Q_0} \times 100$
- **Índice no ponderado de valor** $= \frac{\sum (P \times Q)_i}{\sum (P \times Q)_0} \times 100$

3.2 Números índice ponderados

Con frecuencia, cuando calculamos un índice complejo, queremos asignarle una mayor importancia a los cambios producidos en alguno de los conceptos que componen el índice más que a otros. Como se dijo anteriormente, esta ponderación permite incluir más información al cálculo y luego, el problema reside en decidir qué peso asignarle a cada uno de los conceptos involucrados.

Existen varios métodos para calcular un índice de precios ponderados pero los más utilizados son el de Laspeyres, el de Paasche y el de Fisher. Básicamente, los dos primeros difieren solamente en cuanto al período usado para la ponderación. El método de Laspeyres emplea ponderaciones del período base mientras que el método de Paasche utiliza ponderaciones del año actual. Por último, el de Fisher es la media geométrica de ambos.

3.2.1 Índice ponderado de precios. Método de Laspeyres

A fines del siglo XVIII, Etienne Laspeyres ideó un método para determinar un índice ponderado usando ponderaciones de período base. Dicho índice se calcula de la siguiente manera: primero se multiplica el precio del periodo actual por la cantidad del periodo base para cada uno de los elementos que componen el índice y después suma los valores resultantes. Luego se multiplica el precio del periodo base por la cantidad del periodo base también para cada uno de los elementos y, de nuevo, se suman los resultados. Por último, se divide la primera suma entre la segunda y se multiplica el resultado por 100.

Índice de precios de Laspeyres

$$IP_L = \frac{\sum P_i \times Q_0}{\sum P_0 \times Q_0} \times 100$$

Donde P_i refiere a precios del período actual, P_0 refiere a precios del período base y Q_0 refiere a la cantidad en el período base

Veamos un ejemplo: a los datos de precios de los cinco artículos de la tabla anterior se agregaron los datos de las cantidades para cada uno de los años.

Tabla 4. Índice de precios de Laspeyres

Artículos	2015		2016		2017	
	Precio	Cantidad	Precio	Cantidad	Precio	Cantidad
Pan blanco (kilo)	0,80	50	0,92	49	1,02	47
Huevos (docena)	1,90	26	1,80	27	1,85	26
Leche(litro)	1,61	102	1,84	99	1,95	97
Jugo de naranjas (litro)	1,72	40	1,80	39	1,69	42
Café tostado (kilo)	6,70	12	6,95	11	7,13	9

Determinemos el índice de precios de Laspeyres para el 2017 con base en 2015.

$$IP_L = \frac{\sum P_1 \times Q_0}{\sum P_0 \times Q_0} \times 100 =$$

$$= \frac{1,02 \times 50 + 1,85 \times 26 + 1,95 \times 102 + 1,69 \times 40 + 7,13 \times 12}{0,80 \times 50 + 1,90 \times 26 + 1,61 \times 102 + 1,72 \times 40 + 6,70 \times 12} \times 100 = \frac{451,16}{402,82} \times 100 = 112,00$$

Con base en este análisis, se concluye que el precio de este grupo de alimentos aumentó un 12% desde el 2015 al 2017. La ventaja de este método sobre el del índice agregado simple es que se considera la ponderación de cada uno de los artículos. En el índice agregado simple el café tenía una mayor participación en cambio en el de Laspeyres es la leche el de mayor representatividad debido a la incorporación de las cantidades en el cálculo.

3.2.2 Índice de precios de Paasche

El índice de Paasche, llamado así por Hermann Paasche, es otra alternativa para elaborar un índice complejo ponderado. El procedimiento es similar al de Laspeyres, pero en vez de usar como ponderaciones las cantidades del periodo base, simplemente se emplean las cantidades del año actual. Esto tiene la ventaja de usar las cantidades más recientes pero por otro lado, se necesita tener el dato para cada uno de los periodos a calcular el índice.

Índice de precios de Paasche

$$IP_P = \frac{\sum P_i \times Q_i}{\sum P_0 \times Q_i} \times 100$$

Donde P_i refiere a precios del período actual, P_0 refiere a precios del período base y Q_i refiere a la cantidad del período actual

Consideremos los datos de la Tabla 2 y calculemos el índice de precios de Paasche para 2017 con base en 2015:

$$IP_P = \frac{\sum P_i \times Q_i}{\sum P_0 \times Q_i} \times 100 =$$

$$= \frac{1,02 \times 47 + 1,85 \times 26 + 1,95 \times 97 + 1,69 \times 42 + 7,13 \times 9}{0,80 \times 47 + 1,90 \times 26 + 1,61 \times 97 + 1,72 \times 42 + 6,70 \times 9} \times 100 = \frac{420,34}{375,71} \times 100 = 111,88$$

Tal resultado indica que ha habido un incremento de 11,88% en el precio de esta canasta de bienes entre 2015 y 2017.

Si bien ambos métodos son similares, se debe aclarar que cada uno de ellos conlleva a tener ventajas y desventajas. Por un lado, el índice de Laspeyres se usa más frecuentemente ya que solamente se necesitan para su cálculo las cantidades de un solo período, es decir, las del período base. El Índice de Precios al Consumidor (IPC), quizás el más conocido y usado, es un ejemplo de un índice de Laspeyres. Otra ventaja es la posibilidad de comparar un índice con otro. El uso de un mismo ponderador nos permite hacer comparaciones directas. Sin embargo, esto que se considera como una ventaja lleva a la principal desventaja de este método. Al utilizar solamente las cantidades del período base, no toma en cuenta los posibles cambios que se producen en los patrones de consumo con el correr del tiempo. Es decir, este método supone que siempre se adquieren las mismas cantidades que en el período base y los productos comprados hace apenas unos años atrás, hoy podrían tener poca importancia.

Por otro lado, el método de Paasche es particularmente útil porque combina los efectos de los cambios de precio y los patrones de consumo. Así, es un mejor indicador de los cambios generales de la economía. Sin embargo, requiere el relevamiento de las cantidades de cada período para el cual se quiere calcular el índice. A menudo, recolectar la información de cantidades de cada período es un proceso costoso o directamente el dato no está disponible por lo que muchas cantidades de uso común no se tabulan cada año. A su vez, cada valor de un índice de precios de Paasche es el resultado de cambios en precios y cantidades respecto al período base. Como las medidas de cantidad utilizadas para un período suelen ser diferentes de las medidas de cantidad para otro período, es imposible atribuir la diferencia entre los dos índices solamente a los cambios de precios. En consecuencia, es difícil comparar índices de diferentes períodos calculados con el método de Paasche.

3.2.3 Índice ideal de Fisher

El índice de precios calculado por el método de Laspeyres tiende a ponderar en más los artículos cuyos precios han aumentado, dado que seguramente aquellos que aumenten de precio se consumirán en menor medida y su peso en la canasta de consumo vaya perdiendo importancia. Por el contrario, un índice de precios por el método de Paasche tiende a ponderar en más los artículos cuyos precios se han reducido, reflejando el comportamiento típico de la demanda: a menor precio se demanda mayor cantidad, y como el índice de Paasche toma en cuenta las cantidades actuales, la ponderación de los artículos que se han abaratado aumentará. En un intento por compensar estas fallas, Irving Fisher propuso un índice llamado Índice Ideal de Fisher. Consiste en calcular la media geométrica de los índices de Laspeyres y Paasche.

Índice Ideal de Fisher

$$IP_F = \sqrt{(\text{Índice de Laspeyres}) \cdot (\text{Índice de Paasche})}$$

Este índice parece ser teóricamente ideal porque combina las mejores características de sus predecesores. Sin embargo, casi no se usa en la práctica porque tiene los mismos problemas que el de Paasche ya que requiere información de cantidades para cada año.

Así como se mencionó anteriormente, tanto para números índice simples como para complejos no ponderados, también existe la posibilidad de calcular números índice de cantidad o de valor por los métodos de Laspeyres, Paasche o Fisher. En este caso, las respectivas fórmulas se presentan a continuación:

- **Índice de cantidades de Laspeyres** = $IQ_L = \frac{\sum Q_i \times P_0}{\sum Q_0 \times P_0} \times 100$
- **Índice de cantidades de Paasche** = $IQ_P = \frac{\sum Q_i \times P_i}{\sum Q_0 \times P_i} \times 100$
- **Índice de cantidades de Fisher** = $IQ_F = \sqrt{IQ_L \times IQ_P}$

3.2.4 Índice ponderado con pesos fijos

Otra técnica utilizada para asignar pesos a los elementos de un índice complejo es el método de agregados con peso fijo. Es parecido a los métodos de Laspeyres y Paasche, pero en lugar de utilizar pesos del periodo base o del periodo actual (cantidades), usa pesos tomados de un periodo representativo.

Los pesos representativos se conocen como pesos fijos. Estos pesos fijos y los precios base no tienen que corresponder al mismo periodo.

Calculamos un índice de precios de agregados con peso fijo multiplicando los precios del periodo actual por los pesos fijos y sumando los resultados. Luego, multiplicamos los precios del periodo base por los pesos fijos y sumamos los resultados. Por último, dividimos la primera suma entre la segunda y multiplicamos el cociente por 100 para convertirlo en un porcentaje relativo. La fórmula utilizada para calcular un índice de precios de agregados con pesos fijos se presenta a continuación

Índice con pesos fijos

$$IP_{PF} = \frac{\sum P_i \times Q_j}{\sum P_0 \times Q_j} \times 100$$

Donde P_i refiere a precios del período actual, P_0 refiere a precios del período base y Q_j refiere a los pesos fijos.

4 Consideraciones importantes

Al trabajar con números índice hay que tener en cuenta una serie de consideraciones relacionadas tanto con la construcción como así también con la interpretación de los números índice.

Dentro de las cuestiones relacionadas con la construcción de un número índice, se presentan las siguientes:

- **Selección de elementos relevantes:** al construir un número índice hay que tener en claro previamente qué se quiere analizar con dicho indicador y en base a ello incluir solo aquellos elementos que sean relevantes para el análisis. Por ejemplo, cuando se quiere analizar la variación de precios entre un período y otro para los consumidores, la construcción del índice de precios respectivo debe incorporar a aquellos bienes y servicios representativos del consumo de las familias.
- **Selección de ponderadores apropiados:** en las secciones previas de este cuadernillo se explicó algunos índices ponderados. En este sentido, los pesos seleccionados deben representar la importancia relativa de los diferentes elementos. Asimismo, se tiene que tener en cuenta que lo que es apropiado en un período puede volverse inapropiado en otro. Esta consideración debe tenerse en mente al comparar valores de índices calculados en tiempos muy diferentes.
- **Selección de un periodo base:** en general, el período base seleccionado debe ser un período normal, es decir, el período seleccionado no debe estar en un pico o una depresión de una fluctuación.

Además de los problemas relacionados a la construcción de un número índice, se debe tener en cuenta ciertas consideraciones al momento de interpretarlos. A saber:

- **Generalización de un índice específico:** a menudo se tiende a generalizar las conclusiones obtenidas por la interpretación de un número índice específico. Por ejemplo, el IPC intenta describir la variación de los precios al consumidor y su generalización a otros campos de la economía no sería lo adecuado.
- **Falta de conocimiento de la metodología empleada:** previamente a la interpretación de un número índice, uno debe familiarizarse con la metodología empleada en su construcción.
- **Paso del tiempo:** no hay que olvidarse que los factores relacionados con un índice tienden a cambiar con el tiempo, sobre todo las ponderaciones de las cuales hemos hablado anteriormente. Es por esto, que a menos que se hagan los cambios correspondientes en dichas ponderaciones, la validez del índice será cada vez menos confiable.

5 Bibliografía

Anderson, David R. y Sweeney, Dennis J. (2008). *“Estadística para administración y economía”*. Cengage Learning Editores. 1056 páginas.

Berenson, M. L.; Levine, D. M. (1998). *“Estadística para administración y economía”*. Ed. Interamericana, 6ª Edición.

Levin, Richard T. y Rubin, David S. (2004). *“Estadística para administración y economía”*. Pearson Educación, México. Séptima edición. 952 páginas.

Levine, David. M.; Krehbiel, Timothy. C.; Berenson, Mark. L. (2006). *“Estadística para administración”*. México: Pearson Educación, 4º Edición. 619 páginas.

Material de cátedra

Estadística

Módulo IV:

Muestreo

Autores

María Rosa Dos Reis

Mario Seffino

Daniel Amores

Facultad de Ciencias Económicas
Universidad Nacional del Centro de la Provincia de
Buenos Aires



Tabla de contenido

1	Introducción	2
2	Tipos de muestreo	2
3	Consideraciones en el diseño del muestreo.....	3
4	Muestreo Probabilístico.....	4
5	Tipos de diseño de muestreo Probabilístico	5
6	Tipos de diseño de muestreo No Probabilístico	9
7	Bibliografía.....	11

1 Introducción

Cuando estamos cocinando pasta, y queremos saber si se encuentra “al dente” o lista para su consumo, tomamos una unidad y la probamos. Si nuestro paladar determina que es así, damos por sentado que toda la demás pasta está cocida y la servimos. No tendría sentido probar toda la pasta, ya que terminaríamos comiendo al lado de la olla.

En el ámbito empresarial, si se está inspeccionando la calidad de una bobina de un motor, el encargado de hacerlo no revisará todas las bobinas fabricadas por la empresa en el día (suponiendo que sean 1000), pues el tiempo no le alcanzaría para hacerlo. Lo mejor que podría hacer es tomar una **muestra representativa** e inferir que las demás cumplen (o no) con los requerimientos solicitados.

En otro caso, si un jefe del sector de *marketing* le pide a su asistente evaluar las ventas del último mes, es muy posible que la empresa cuente con la totalidad de los datos y no se requiera el uso de una muestra; se podrá trabajar con el total de la población, acción que se denomina **censo**.

De lo anterior se desprende que, según los requerimientos, el tiempo que se disponga, la posibilidad de destrucción de los elementos que se analizan, la necesidad de reducir costos, o si la población es finita o infinita, será necesario/posible trabajar con todos los elementos de la población (censo), o solo con algunos de ellos (muestra).

Recordemos que la población no sólo se refiere a personas, sino a todos los elementos escogidos para su estudio. La muestra es una parte de la población, una porción que se desea analizar para inferir el comportamiento de una determinada característica de esa población. Recordemos que un **estadístico** es una característica de la muestra, mientras que un **parámetro** es una característica de la población.

2 Tipos de muestreo


Existen dos métodos para seleccionar muestras de poblaciones: el **muestreo aleatorio o probabilístico** y el **muestreo no probabilístico o no aleatorio**.

En el muestreo de probabilidad o probabilístico, todos los elementos de la población tienen la oportunidad de ser escogidos para la muestra; es decir todo individuo tiene una **probabilidad conocida** de quedar incluido en la muestra. Al realizar inferencias estadísticas no es necesario que todas las probabilidades sean iguales, si la probabilidad de selección es conocida, será posible ajustar en relación con probabilidades desiguales mediante algún método de ponderación.

En el muestreo no probabilístico, se emplea el conocimiento del experto y la opinión personal para identificar a los elementos de la población que deben incluirse en la muestra. Una muestra seleccionada por muestreo de juicio se basa en la experiencia que alguien ha tenido con la población objetivo. Con un muestreo para el cual no puede calcularse la probabilidad, podemos obtener una muestra efectivamente muy representativa, pero no tenemos las condiciones para determinar los riesgos de error implicados.

Para destacar la importancia de seleccionar uno u otro tipo de muestreo, se recuerdan los siguientes conceptos:

Figura 1: Población y Muestra



Si se trabaja con todos los elementos de la población, mediante el uso de estadística descriptiva se arribará a conclusiones sobre esa población.

Si en cambio se utiliza una muestra, en caso de que sea probabilística, se usarán herramientas de la **estadística inferencial** para obtener conclusiones sobre la población. Si se elige un muestreo no probabilístico, las conclusiones serán sólo sobre esa muestra, usando herramientas de la **estadística descriptiva**.

3 Consideraciones en el diseño del muestreo

Si se desea extraer una muestra para poder inferir conclusiones acerca de la población, es de suma importancia la manera en que se la diseña.

Lo primero que se debe establecer es el **objetivo** que se desea analizar. Por ejemplo, la potencia de un motor, la atención de un cliente, la calidad de un tornillo para amurar cuadros, etc. Es el punto de inicio, determinar claramente los objetivos de la investigación.

Posteriormente se seleccionarán las variables que se estudiarán. Por ejemplo, si el objetivo es estudiar la atención de un cliente en un banco, una variable sería el tiempo de espera. En esta fase, lo que se plantea es qué características se medirán, qué herramienta de medición se usará para analizar el objetivo (tiempo, duración, etc.).

Luego, se deberá determinar el tamaño de la muestra. ¿Cuántas bobinas se probarán?, ¿cuántos clientes serán entrevistados? Obviamente, cuanto más grande sea la muestra, más representativa será de la población (si es probabilística), pero a su vez más costoso será obtenerla, lo que puede ser contradictorio con uno de los fines de toda muestra, que es reducir el costo de lo que se analiza. Lo importante en este punto es encontrar un equilibrio entre la utilidad que puede brindar el tamaño de esa muestra y el costo de usar ese tamaño.

Un punto significativo en el diseño de una muestra es que las demás variables que no son consideradas deben mantenerse relativamente estables, pues una variación importante en una o varias de ellas, puede hacer variar significativamente el resultado de la variable que se está analizando. Por ejemplo, si el objetivo es analizar la satisfacción de un cliente bancario, se puede tomar como variable el tiempo de espera en fila de caja. En este caso, otra variable como es la altura del mes debe ser considerada, pues los primeros días, ante los vencimientos de obligaciones, el movimiento es mayor que durante la segunda quincena del mes. Así, si se tiene en cuenta sólo la variable tiempo de espera en fila para medir la satisfacción, los que asisten los primeros días se verían menos satisfechos que los que asisten a fin de mes.

Según Hair, Bush y Ortinau (2010), otras cuestiones a tener en cuenta en la determinación del diseño de muestreo más apropiado incluyen los siguientes factores:

- **Grado de precisión:** el grado de precisión variará de un proyecto a otro, en especial en el momento de evaluar los costos u otras consideraciones. Si el investigador está interesado en hacer predicciones acerca de los miembros de la población objetivo, entonces deberá emplear un método de muestreo probabilístico. Si en lugar de ello, sólo le interesan unos resultados preliminares acerca de la población objetivo, los métodos no probabilísticos pueden ser los adecuados.
- **Recursos:** se deben tener en cuenta las limitaciones de recursos financieros y humanos, posiblemente haya que descartar algunos métodos de muestreo que consumen más tiempo y son más complejos de realizar.
- **Marco de tiempo:** si hay que cumplir con fechas límites para realizar la investigación seguramente se elegirán métodos más sencillos.
- **Conocimiento de la población objetivo:** en muchos casos no se dispone de un listado de la población objetivo, teniendo que elegir por un método de muestreo no probabilístico.
- **Alcance de la investigación:** el alcance del proyecto de investigación, si es internacional, nacional, regional o local, influirá en la elección del método de muestreo. En general, cuánto más amplio es el alcance más complejo se vuelve el muestreo para asegurar la representatividad de la población.
- **Necesidades de análisis estadístico:** la necesidad de proyecciones estadísticas basadas en los resultados a veces determina el método de muestreo. Otra cuestión importante que surge es la determinación del tamaño de muestra, el cual tiene un efecto directo sobre la calidad de los resultados y la precisión estadística.

4 Muestreo Probabilístico

En una muestra aleatoria conocemos la probabilidad de que un elemento de la población se incluya o no en la muestra. Como resultado de lo anterior, es posible determinar objetivamente las estimaciones de las características de la población que resultan de una muestra dada.

Los métodos de muestreo probabilístico se basan en el principio de “equiprobabilidad”, es decir, todos los elementos o individuos tienen la misma probabilidad de ser elegidos, para formar parte de una muestra, y por lo tanto, todas las muestras de tamaño n tienen la misma probabilidad de ser elegidas.

Como se estableció precedentemente, sólo este tipo de muestreo asegura la representatividad de la muestra extraída, siendo el más recomendable para la práctica estadística. Es un muestreo objetivo, como la obtención de unidades es realizada al azar, no depende de la “subjetividad” del experto que diseña la muestra.

5 Tipos de diseño de muestreo Probabilístico

Muestreo Aleatorio Simple (SRS - *Simple Random Sampling*):

El muestreo aleatorio simple (MAS) selecciona una muestra mediante métodos que permiten que cada posible muestra de n elementos, tenga una igual probabilidad de ser seleccionada y que cada elemento de la población N total tenga una oportunidad igual de ser incluido en la muestra.

La técnica de obtención de la muestra consiste en seleccionar n elementos de una población N , de manera aleatoria y sin reposición, es decir, una vez que se seleccionó el elemento n_1 , este no vuelve a ser considerado. Este método es sumamente útil cuando existe homogeneidad de la población a estudiar, es decir, que los elementos tengan características iguales o similares.


Para asegurar que el método de extracción sea realmente aleatorio hay que verificar que todos los individuos, incluidos los atípicos y los que son difíciles de localizar, tengan efectivamente la misma posibilidad de aparecer en la muestra. Para ello hay que garantizar que cada individuo figure en la lista y que aparezca solamente una vez.

Resumimos las características del muestreo aleatorio simple:

- Cada muestra de tamaño n tiene la misma probabilidad de ser seleccionada.
- Cada elemento de la población N tiene la misma probabilidad de ser seleccionado.
- Método de extracción aleatorio de elementos de la muestra (tablas de números aleatorios, marcación aleatoria de dígitos, etc.).
- Se pueden obtener cálculos de la población sin sesgos.
- Requiere conocer todos los elementos de la población.

La siguiente figura muestra el caso de un muestreo aleatorio simple en donde se seleccionan n elementos de una población N .

Figura 2: Muestreo aleatorio simple



Muestreo Aleatorio Sistemático (SYMRS – *Systematic Random Sampling*):

En el muestreo sistemático (MS), los elementos son seleccionados de la población dentro de un intervalo uniforme que se mide con respecto al tiempo, al orden o al espacio.

El muestreo sistemático difiere del muestreo aleatorio simple en que cada elemento tiene igual oportunidad de ser seleccionado cuando se elige el punto de inicio, pero cada muestra no tiene una posibilidad igual de ser seleccionada.

El muestreo sistemático también tiene ventajas. Aun cuando este tipo de muestreo puede ser inapropiado en el caso de que los elementos entren en un patrón secuencial, este método puede requerir menos tiempo y, algunas veces, tiene como resultado un costo menor que el método de muestreo aleatorio simple.

Una limitación de este tipo de muestreo es que puede introducirse un error en el proceso de muestreo. Por ejemplo: si se deseara estudiar la contaminación sonora en pleno centro de la ciudad, y se decidiera hacer una toma de 100 muestras durante 5 minutos los días domingos a la mañana, la probabilidad de que el resultado esté por debajo de los niveles permitidos es alta, pues el tránsito un día domingo es inferior a un día laborable.

Una manera de medir el intervalo es, en caso de que la población sea finita, dividir el número de la población sobre el tamaño de la muestra: N/n . Así, si el tamaño de la población N es 250, y se determina una muestra $n=10$, el intervalo C será $250/10 = 25$, es decir, si al azar se selecciona un primer número 8, la segunda muestra será la que se ubique en $8+25 = 33$, el tercero $33+25 = 58$, y así hasta completar el $n=25$.

En caso de que la población sea infinita, el valor del intervalo C es arbitrario, basado en la experiencia del investigador.


Resumimos las características del muestreo aleatorio sistemático:

- Requiere que la población se ordene de alguna manera y conocer el número de unidades de muestreo.
- Es menos costoso y más rápido.
- Se seleccionan las unidades de muestreo de acuerdo con su posición utilizando un intervalo de salto (tamaño de la población / tamaño de la muestra deseada)

- Elegir aleatoriamente el punto de partida.
- Riesgo de patrones ocultos en los datos.

La siguiente figura muestra un ejemplo de un muestreo aleatorio sistemático en donde los n elementos de la muestra son seleccionados dentro de un intervalo uniforme que se mide con respecto al tiempo, al orden o al espacio.

Figura 3: Muestreo aleatorio sistemático



Muestreo Estratificado (STRS – *Stratified Random Sampling*):

Para utilizar el muestreo estratificado, dividimos la población en grupos relativamente homogéneos, llamados estratos. Los estratos son homogéneos en su interior pero heterogéneos entre sí. Es importante que los estratos se definan de tal modo que cada individuo figure en uno y sólo en uno de ellos.

El muestreo estratificado resulta apropiado cuando la población ya está dividida en grupos de diferentes tamaños y deseamos tomar en cuenta esta condición.

Cada estrato funciona de manera independiente, pudiendo aplicarse en cada uno de ellos muestreo aleatorio simple o muestreo sistemático, para lo que se exige un conocimiento detallado de la población.

La asignación del tamaño de la muestra a cada uno de los estratos recibe el nombre de afijación, que se puede realizar de tres maneras:

- a) Afijación Simple:** a cada estrato le corresponde igual número de elementos muestrales. Así, si se determina un tamaño de muestra $n=30$, y son 3 los estratos, de cada uno le corresponde $n_j = 10$ ($30/3$). En este tipo de afijación, se ven favorecidos los estratos con menor población. Siguiendo con el ejemplo anterior, y suponiendo que el primer estrato tiene 50 elementos, el segundo 80 y el tercero 120, la muestra de $n = 30$ representa, en el primero, el 20% de su población, mientras que en el último el 8.33%.

b) Afijación proporcional: corrige el defecto del sistema anterior, asignándole más peso a aquellos estratos con mayor cantidad de elementos. En otras palabras, la asignación se realiza de acuerdo al peso o tamaño de la población de cada estrato. El tamaño de muestra n_h de cada estrato se determina de la siguiente manera:

$$n_h = \frac{n}{N} * N_h$$

Lo resolvemos con el ejemplo anterior: son 3 estratos, cuyos tamaños son $N_1 = 50$, $N_2 = 80$, y $N_3 = 120$. Con un tamaño de muestra total $n=30$, y una población de $N = 250$ ($50+80+120$), se calcula el tamaño de n_h para cada estrato. Así:

$$n_1 = \frac{30}{250} * 50 = 6 ; n_2 = \frac{30}{250} * 80 = 9.6 \approx 10 ; n_3 = \frac{30}{250} * 120 = 14.4 \approx 15$$

Al estrato uno le corresponde una muestra de 6 unidades, al 2 de 10 y al 3 de 15. Nótese que la suma del tamaño de las muestras de cada estrato n_1 , n_2 y n_3 debe ser mayor o igual al del tamaño total n ($6 + 10 + 15 = 31$). De esta manera, a mayor tamaño del estrato, mayor tamaño de muestra.

c) Afijación óptima: en este caso, el tamaño de la muestra de cada estrato no sólo es proporcional a su población, sino que además considera el desvío estándar correspondiente. Corrige la falta de homogeneidad que puede presentarse dentro de un mismo estrato (subpoblaciones), pero tiene escasa aplicación práctica ya que no suele conocerse el valor del desvío estándar.

Resumimos las características del muestreo aleatorio estratificado:

- Se divide a la población en subgrupos homogéneos llamados estratos.
- Hay variación de un grupo a otro.
- Se seleccionan muestras aleatorias de cada estrato.
- Se combinan las muestras de cada estrato en una sola muestra de la población objetivo.
- La asignación del tamaño de la muestra a cada uno de los estratos puede ser proporcional o no proporcional al tamaño de la población.

Muestreo por Conglomerados

El muestreo por conglomerados (MC) se utiliza cuando las unidades de la población presentan alguna forma de agrupamiento, que permite elegir grupos en lugar de individuos. De esta forma, el acceso a la muestra queda facilitado considerablemente, al quedar reunidos los individuos que la constituyen en una serie de grupos. Al realizar el muestreo, seleccionaríamos aleatoriamente una serie de grupos o conglomerados, tratando de reunir el número total de individuos que pretendemos incluir en la muestra. Por ejemplo, se podría dividir a una ciudad en varios distritos electorales y seleccionar luego 10 distritos como muestra.

Este procedimiento no requiere construir censos o listados completos de los elementos de la población, que son sustituidos en este caso con censos de conglomerados. En realidad, el muestreo por conglomerados no es más que la aplicación de los muestreos aleatorios simples, sistemáticos o por estratos al caso en que la unidad de muestreo no son individuos sino grupos de individuos. Este tipo de diseño es muy utilizado en las ciencias sociales.


Tanto en el muestreo estratificado como en el de conglomerados, la población se divide en grupos bien definidos. Usamos el muestreo estratificado cuando cada grupo tiene una pequeña variación dentro de sí mismo, pero hay una amplia variación de un grupo a otro. Usamos el muestreo de conglomerados en el caso opuesto, cuando hay una variación considerable dentro de cada grupo, pero los grupos son esencialmente similares entre sí.

Resumimos las características del muestreo por conglomerados:

- Las unidades de muestreo se dividen en subpoblaciones mutuamente excluyentes y colectivamente exhaustivas, llamadas conglomerados.
- Hay variaciones dentro de cada grupo pero los grupos son similares entre sí.
- Los conglomerados son seleccionados aleatoriamente (por ejemplo, mediante muestreo aleatorio simple). Una vez seleccionado el conglomerado, en general se eligen todas las unidades de muestreo.
- Muestreos de área: conglomerados por designaciones geográficas.
- Una de las principales desventajas es que los conglomerados a menudo son homogéneos, lo ideal es que las personas de un conglomerado sean heterogéneas como la población.
- Es un método rentable y fácil de ejecutar.

La siguiente figura muestra el caso de un muestreo por conglomerados, en donde la población está dividida en 20 conglomerados y se toman los elementos de 5 conglomerados como muestra.

Figura 4: Muestreo aleatorio por conglomerados



6 Tipos de diseño de muestreo No Probabilístico

Una característica general que tienen los diseños de tipo No Probabilístico es que los resultados no son generalizables a la población objetivo definida, y resulta difícil evaluar con exactitud la representatividad de la muestra.

A continuación, se presentan las características particulares de cada uno de los tipos de muestreo No Probabilístico:

Muestreo por conveniencia

- Las muestras se extraen sobre la base de la comodidad.
- Supone que la población es homogénea y que los individuos seleccionados son semejantes a la población definida.
- Permite acceder a un gran número de individuos en tiempos relativamente cortos.

Ejemplo: las entrevistas por intercepción a las personas en los centros comerciales.

Muestreo por juicio, discrecional o intencional

- Se elige a los individuos porque el investigador cree que cumplen con los requisitos del estudio, de acuerdo a su propio criterio o juicios preestablecidos (“casos típicos”).
- Este tipo de muestreo se puede realizar en tiempos mínimos de ejecución. Resulta ser más efectivo cuando hay un número restringido o limitado de individuos que cumplen con ciertas características esperadas por el investigador en la población objetivo.
- Generalmente, la realización de otro tipo de muestreo pueda resultar mucho más costosa.
- Supone de fondo que las opiniones del grupo selecto son representativas de la población objetivo.
- El juicio del investigador depende del conocimiento y experiencia que tiene en el tema, por ende, si este juicio es correcto, la muestra por juicio será mejor que la generada por el muestreo por conveniencia.
- La desventaja es que los resultados pueden estar sesgados por la forma de selección de la muestra y, no se puede evaluar la fiabilidad del experto.

Ejemplo: selección de ciudades representativas de nuestro país en términos de mejor calidad de vida.

Muestreo por cuota

- Selección de los participantes en perspectiva conforme a cuotas pre-especificadas de características demográficas (edad, género, ingresos), actitudes (satisfacción, insatisfacción) o comportamientos específicos (cliente regular, esporádico).
- El propósito es asegurar que los subgrupos pre-especificados de la población queden representados en el muestreo.

- Reduce el sesgo de selección de los trabajadores de campo.
- Las cuotas pueden ser determinadas por la naturaleza de los objetivos de la investigación.
- El tamaño de la cuota es subjetivo.

Ejemplo: se seleccionan clientes de un comercio de comidas rápidas por cuotas de edades, el investigador se basa en estudios anteriores que dicen que el 50% de sus clientes son individuos de entre 25 y 55 años, por lo tanto, querrá que ese subgrupo constituya el 50% de la muestra total.

Muestreo por bola de nieve

- Consiste en identificar y calificar un conjunto de individuos iniciales, los cuales, a su vez, ayudan al investigador a identificar individuos adicionales (por ejemplo, por recomendación).
- Es un método razonable para identificar a individuos que son miembros de poblaciones objetivo definidas en forma única, y que además son pequeñas y de acceso difícil.
- La lógica fundamental de este método es que los grupos exclusivos de personas tienden a formar sus propios círculos sociales únicos.
- Se puede producir sesgo en el estudio, si hubiera diferencias significativas entre las personas que se conoce en ciertos círculos sociales y las que no.
- Brinda mejores resultados a un costo mucho más bajo.

Ejemplo: Si se quieren estudiar las actitudes de comunidades que permanecen socialmente “ocultas”, tales como los individuos que aportan dinero a instituciones sociales en forma de beneficencia.

7 Bibliografía

Anderson, David R. y Sweeney, Dennis J. (2008). *“Estadística para administración y economía”*. Cengage Learning Editores. 1056 páginas.

Berenson, M. L.; Levine, D. M. (1998). *“Estadística para administración y economía”*. Ed. Interamericana, 6ª Edición.

Levin, Richard T. y Rubin, David S. (2004). *“Estadística para administración y economía”*. Pearson Educación, México. Séptima edición. 952 páginas.

Levine, David. M.; Krehbiel, Timothy. C.; Berenson, Mark. L. (2006). *“Estadística para administración”*. México: Pearson Educación, 4ª Edición. 619 páginas.

Bibliografía Adicional

Baranger, Denis. (1992). *"Construcción y análisis de datos: Introducción al uso de técnicas cuantitativas en la investigación social"*. Editorial Universitaria. Universidad Nacional de Misiones.

Blalock, Hubert. (1986). *"Estadística Social"*. Fondo de Cultura Económica. México.

Chou, Ya Lun. (1977). *"Análisis Estadístico"* - Ed. Interamericana.

Hair, J.; Bush, R.; Ortinau, D. (2010). *"Investigación de mercado en un ambiente de información digital"*. Cuarta Edición. Mc Graw Hill.

Huff, Darrell. (1965). *"¿Cómo mentir con Estadísticas?"*. Gráficas Sagitario. Barcelona. 158 páginas.

Mendenhall, William; Beaver, Robert J. y Beaver, Barbara M. (2009). *"Introduction to probability and statistics"*. Cengage Learning, 13 edición. 746 páginas.

[illegible]